

分类号 _____

密 级 _____

UDC _____

昆明理工大学

硕士专业学位论文

三相逆变器故障信号特征提取及故
障诊断方法研究

研 究 生 姓 名 _____ 刘瑶

指导教师姓名、职称 _____ 吴玉虹 教授

学 科 专 业 通信工程(含宽带网络、移动通信等)

研 究 方 向 _____ 电力电子电路故障诊断

论 文 工 作

起 止 日 期 _____ 2023 年 9 月~2025 年 5 月

论 文 提 交 日 期 _____ 2025 年 5 月

摘要

随着新能源技术的快速发展,三相逆变器在现代电力系统中发挥着至关重要的作用。然而,逆变器在长期运行过程中,容易受到功率器件老化、负载波动以及外部环境因素的影响,导致功率开关管故障,进而影响电网稳定性和系统的安全运行。因此,研究高效、精准的故障诊断方法,对于提升新能源系统的可靠性具有重要的工程价值和现实意义。

传统故障诊断方法存在特征提取能力不足、抗噪性能差等局限性,尤其在复杂工况和强噪声干扰环境下,诊断精度较低。为了解决这一问题,本文提出了一种基于并行二维卷积神经网络(Parallel Two-Dimensional Convolutional Neural Network, P2D-CNN)的智能故障诊断方法,旨在提升故障识别的准确性和抗噪能力。首先,基于 MATLAB/Simulink 仿真平台搭建三相逆变器模型,并采集 22 种不同工作状态下的 A 相电压信号,构建完整的故障数据集。随后,采用 STFT、GAF 和 MTF 三种信号转换方法,将一维时域信号转换为二维图像,从时频域和状态域角度提取故障特征,从而增强数据的特征表达能力。

在此基础上,构建 P2D-CNN 模型,该模型采用双通道并行结构,分别提取 STFT、GAF 和 MTF 方法转换后的故障特征,并在融合层对特征进行整合,以提升模型对不同类型故障的识别能力。为进一步优化特征提取效果,引入 CBAM 注意力机制,构建 P2D-CNN-CBAM 模型,通过通道注意力和空间注意力的联合作用,使得网络能够更精准地关注关键故障特征,同时抑制冗余信息,从而提高模型的分类精度并增强抗噪能力。

实验结果表明,所提出的方法在不同信噪比条件下均表现出优越的性能。尤其在低信噪比环境下,P2D-CNN-CBAM 的平均分类准确率较 P2D-CNN 基础模型提升 5.23%,展现了更强的抗噪性能和泛化能力。通过对比不同特征组合的诊断效果,发现 STFT-GADF 组合能够提供更全面的时频特征,使诊断的精度达到最优水平。与传统基于卷积神经网络方法相比,该方法在故障诊断精度和抗干扰能力方面均有显著优势,为三相逆变器故障诊断提供了一种高效、可靠的解决方案。

关键词: 故障诊断; 三相逆变器; 二维图像转换; 并行二维卷积神经网络; CBAM 注意力机制

Abstract

With the rapid development of new energy technologies, three-phase inverters play a crucial role in modern power systems. However, during long-term operation, inverters are prone to power switch failures due to aging power devices, load fluctuations, and external environmental factors, which can affect the stability of the power grid and the safe operation of the system. Therefore, researching efficient and accurate fault diagnosis methods is of significant engineering value and practical significance for improving the reliability of new energy systems.

Traditional fault diagnosis methods have limitations in feature extraction capability and noise resistance, particularly when faced with complex operating conditions and strong noise interference, leading to low diagnostic accuracy. To address this issue, this thesis proposes an intelligent fault diagnosis method based on a Parallel Two-Dimensional Convolutional Neural Network (P2D-CNN) aimed at improving fault recognition accuracy and noise resistance. First, a three-phase inverter model is built using the MATLAB/Simulink simulation platform, and A-phase voltage signals under 22 different operating conditions are collected to construct a complete fault dataset. Subsequently, three signal transformation methods: STFT, GAF, and MTF are applied to convert one-dimensional time-domain signals into two-dimensional images, from both time-frequency and state-domain perspectives, in order to extract fault features and enhance the feature representation ability of the data.

On this basis, the P2D-CNN model is constructed, which adopts a dual-channel parallel structure to separately extract fault features from the STFT, GAF, and MTF transformations, and integrates these features in a fusion layer to enhance the model's ability to recognize different types of faults. To further optimize feature extraction, the CBAM attention mechanism is introduced to build the P2D-CNN-CBAM model. This model enables the network to more precisely focus on key fault features through the combined effect of channel and spatial attention, while suppressing redundant information, thereby improving classification accuracy and enhancing noise resistance.

Experimental results show that the proposed method performs superiorly under different signal-to-noise ratio (SNR) conditions. In particular, in low SNR

environments, the average classification accuracy of the P2D-CNN-CBAM model improves by 5.23% compared to the P2D-CNN base model, demonstrating stronger noise resistance and generalization ability. By comparing the diagnostic effects of different feature combinations, it is found that the STFT-GADF combination provides more comprehensive time-frequency features, resulting in the optimal diagnostic accuracy. Compared with traditional convolutional neural network-based methods, the proposed approach demonstrates significant advantages in both fault diagnosis accuracy and anti-interference capability, providing an efficient and reliable solution for three-phase inverter fault diagnosis.

Keywords: Fault Diagnosis; Three-Phase Inverter; Two-Dimensional Image Transformation; Parallel Two-Dimensional Convolutional Neural Network; CBAM Attention Mechanism

目录

摘 要.....	I
Abstract.....	III
第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 三相逆变器故障诊断的研究现状	2
1.2.1 基于信号的方法.....	3
1.2.2 基于模型的方法.....	5
1.2.3 基于知识的方法.....	6
1.2.4 基于并行神经网络的方法.....	7
1.2.5 本文研究范围与主要内容.....	8
1.3 章节安排.....	9
第二章 三相逆变器原理分析与特征图像构建	11
2.1 三相逆变器的工作原理.....	11
2.2 三相逆变器的故障分析及故障分类	13
2.3 三相逆变器的故障仿真.....	14
2.3.1 开路故障仿真.....	14
2.3.2 开路故障分析.....	15
2.4 特征图像构建方法.....	18
2.4.1 短时傅里叶变换.....	18
2.4.2 格拉姆角场.....	19
2.4.3 马尔可夫转移场.....	20
2.5 本章小结.....	21
第三章 P2D-CNN 故障诊断模型设计	23
3.1 引言.....	23
3.2 P2D-CNN 模型结构设计.....	23
3.3 P2D-CNN 模型结构模块化设计.....	26
3.3.1 输入层.....	26
3.3.2 卷积层.....	26
3.3.3 激活层.....	27
3.3.4 池化层.....	30

3.3.5 Dropout 层	31
3.3.6 全连接层.....	31
3.4 本章小结.....	32
第四章 基于 P2D-CNN 的逆变器故障诊断方法	35
4.1 引言.....	35
4.2 数据集构成与组合策略.....	35
4.2.1 数据集构成.....	35
4.2.2 数据集组合策略.....	38
4.3 故障诊断过程与性能分析	39
4.3.1 故障诊断过程.....	39
4.3.2 模型训练结果与性能评估.....	40
4.4 模型鲁棒性分析与对比实验	46
4.4.1 不同信噪比下的实验结果.....	46
4.4.2 模型对比分析.....	47
4.5 本章小结.....	48
第五章 基于 P2D-CNN-CBAM 的逆变器故障诊断方法	49
5.1 引言.....	49
5.2 P2D-CNN-CBAM 模型结构设计	49
5.3 CBAM 注意力机制原理与融合策略.....	51
5.4 P2D-CNN 与 P2D-CNN-CBAM 模型对比分析	52
5.5 本章小结.....	53
第六章 总结与展望	55
6.1 全文总结.....	55
6.2 后续展望.....	55
致谢.....	57
参考文献.....	59
附录 A 攻读硕士学位期间的学术成果.....	65
附录 B 攻读硕士学位期间参与的科研项目.....	67

第一章 绪论

1.1 研究背景及意义

在当前科技飞速进步的环境中,电力电子技术已广泛渗入至人们的日常生活和工业生产中。自 1975 年第一只晶闸管问世以来,电力电子设备的应用范围不断拓展,并在多个行业中发挥关键作用。作为直流电(DC)与交流电(AC)转换的核心部件,逆变器在家用电器、工业设备及高安全性、高可靠性要求的场景中占据重要地位。因此,研究高效的逆变器故障诊断方法不仅具有重要的理论价值,同时对实际工程应用也具有深远意义^[1]。

故障诊断技术结合了检测技术和计算机识别算法,对系统故障的外部特征进行分析,识别不同的故障模型并精确定位故障位置,从而实现故障诊断,甚至具备故障预测的能力^[2]。快速识别与定位故障不仅能提高工业生产系统的安全性、可靠性和运行效率,还能有效降低潜在损失,推动产业可持续发展。

研究数据显示,在工业制造环境下,电力电子设备出现故障的情况中,大约 38%是在变流系统内部,其中逆变器故障的比例高达 82.5%^[3]。因此,为保证工业设备正常运行、提高生产效率,需要加强变流系统监控与故障诊断技术的研发。逆变器作为变流系统的核心部分,需要承受较高的电热应力和电磁干扰^[4]。此外,它的运行状态还会受到交流侧输入的波动和直流侧负载的变动所影响,这进一步增加了出现故障的风险。并且逆变器内部元件参数不确定、运行工况复杂以及外界干扰等也是引起逆变器可靠性下降的重要原因之一。这些变量可能导致设备的老化或破损^{错误!未找到引用源。},进而对工业生产的稳定性产生负面影响,并给日常工作和生活带来不良后果。

逆变器的核心电路由数个功率开关管所构成。功率器件一旦出现问题就会影响系统运行稳定性、可靠性及安全性等重要指标,甚至导致整个系统失效。根据工业的调查研究数据,逆变器中的功率器件是最容易出现故障的部分,其故障率高达 60%^[5],其次是电容器和门极驱动器^[7]。文献[8]将功率开关管出现的故障分类为短路和开路两种类型。在短路故障的情况下,初始阶段通常会引发强烈的大电流冲击,在极短时间内可能造成严重损害。因此,及时检测并迅速实施有效的保护措施显得尤为必要^[9]。为了增强系统的安全防护,当电流异常上升时,熔断器会快速熔断,将短路问题转变为开路问题,进而降低系统受损的风险。因此,

在研究功率开关管故障时，短路问题经常被当作是开路故障来进行深入探讨^[10]。

相比于短路故障，开路故障不会立即引发大电流冲击或造成严重损害，也不会使系统立即停机，设备仍可持续运行状态。因此，当系统发生开路故障时，逆变器通常仍能继续工作，以保障负载的正常供电。然而，逆变器在开路状态下的运行稳定性将受到影响，其他支路的电流与电压可能会超出其规定的范围。若未能及时识别并处理故障，容易导致保护装置误动作；若长期处于故障状态且未及时修复，还可能引发更为严重的二次故障，造成更大的系统损失^[11]。因此，针对逆变器功率开关管的开路故障进行高效的诊断研究，具有重大的工程意义和应用价值。

近几年，随着计算能力的提升、大数据技术的广泛应用以及相关算法的不断优化，深度学习作为一种新兴的智能分析手段，在图像识别和自然语言处理等多个领域取得了显著进展。同时，该技术在工业过程中的异常状态监测方面也得到了深入研究与广泛应用^[12]。相较于传统的故障诊断方法，深度学习具有以下突出优势：（1）具备更强的非线性特征建模能力；（2）能够自动提取数据中的深层逻辑与特征模式；（3）对环境噪声干扰具有较高的鲁棒性^[13]。因此，本文将深度学习技术与电气仿真方法相结合，对三相逆变器故障诊断方法展开深入研究，旨在提高故障识别准确性和增强系统运行的稳定性。

1.2 三相逆变器故障诊断的研究现状

逆变器故障诊断技术自上世纪末期兴起，伴随电力电子技术与设备的不断发展，已逐渐成为保障设备安全运行的重要手段。其基本原理是通过分析逆变器故障发生前后的运行状态参数，并与正常工况进行对比，以识别故障类型、定位故障位置及评估其严重程度。基于诊断结果，可采取相应的响应措施，实现故障的早期检测与处理，从而确保设备的安全稳定运行，维护系统的稳定性，并有效减少因故障引发的经济损失。

逆变器故障诊断的基本流程主要包括以下三个阶段：

信号采集：选取能够有效反映逆变器运行状态，且可通过传感器测量的关键参数作为故障信号。常见的参数包括电流、电压和温度等，这些参数可提供充分的信息，为故障诊断提供可靠的数据支持。

信号处理：对采集到的原始信号进行预处理，并提取关键故障特征，如幅值、相位、有效值、平均值等。经过信号处理后的故障信息能够更准确地表征逆变器

的故障状态，为后续的故障识别提供必要的输入数据。

故障识别：根据已提取的故障特征，运用合适的故障诊断技术，对逆变器可能出现的故障类型进行识别，并实现故障的准确定位和诊断。

现阶段，逆变器故障诊断的研究方法主要可划分为三大类：基于信号的方法，基于模型的方法和基于知识的方法^[14]。图 1.1 展示了常见的故障诊断方法。




图 1.1 常见的故障诊断方法

1.2.1 基于信号的方法

基于信号的方法通过监测设备运行状态下的输出信号变化，提取能够反映设备健康状态的特征信息，并利用信号模式与故障种类之间的映射关系，实现故障识别与分类。在逆变器的开路故障检测中，该方法通常依赖于电压、电流等关键参数的时域、频域或时频分析，对异常波形进行提取和建模，以确定故障的具体类别和位置。常见的信号分析方法包括傅里叶变换、小波变换、Park 矢量法以及主元分析等。

傅里叶变换通过将时域信号转化为频域信号，使特征值的提取更加直观，为后续特征分析与故障诊断提供了理论基础。文献[15]提出了一种将 FFT 与改进的 T-S 模糊神经网络相结合的诊断模型，以应对逆变器在负载扰动和测量噪声影响下可能出现的故障边界模糊及特征交叠问题。该模型利用 FFT 提取逆变器各类开路故障的三相输出电流特征，并结合规则自分裂技术和模糊 C 均值聚类算法，提高模型的泛化能力于诊断准确率。此外，该模型采用自适应 Levenberg-Marquardt 算法优化 T-S 网络参数，提高了模型的收敛性和训练速度。文献[16]提出了一种基于 FFT 与进化神经网络的逆变器故障诊断方法。该方法利用 FFT 提取三相逆变器输出电流的低频谐波分量，并结合遗传算法、蚁群优化算法以及反

向传播算法训练神经网络，构建了一个轻量且高效的网络诊断模型。该方法能够有效抵抗噪声干扰，减少特征提取过程中的冗余变量，提高诊断精度。

由于傅里叶变换在处理不连续或突发信号时表现欠佳，法国地球物理学家 Morlet 在 20 世纪 80 年代初提出了小波理论。小波变换在时间和频率域均具有良好的局部化特性，能够精确地分解信号的时变特征，适用于突发信号和非平稳信号的分析，因此在逆变器故障诊断中得到了广泛应用。文献[17]提出了一种创新的故障自诊断技术，融合了同步挤压小波变换（SWT）与随机共振（SR）。该方法在高噪声环境下，首先利用随机共振进行降噪，再采用 SWT 进行模态分解，精确提取故障信息的模态分量。通过综合分析这些模态分量，能够准确识别逆变器的故障类型。文献[18]提出了一种结合小波包变换与支持向量机（SVM）的逆变器故障诊断模型。该方法首先对故障信号进行小波包分解，并重构各频段的小波包能量以构建特征向量，随后将这些特征向量输入 SVM 进行分类，通过交叉验证优化模型，实现对不同类型的 IGBT 开路故障的准确识别。

Park 矢量法利用 Park 变换，将三相信号转换为两相信号，并以转换后的两相信号作为故障检测的输入特征。文献[19]提出了一种基于平均电流 Park 矢量法的 NPC 三电平逆变器的故障检测技术。该方法分析了传统平均电流法的局限性，并提出了一种改进策略，采用 Park 变换处理三相输出电流，利用滑动窗口捕获单周期电流信号。通过分析逆变器拓扑结构及开关管故障时输出电流的变化趋势，使用迭代算法逼近真实值，并确定平均电流 Park 矢量的阈值，最后通过计算相角和模值并与预设阈值进行对比，实现故障诊断。文献[20]对基于平均电流 Park 矢量法的 NPC 三电平逆变器故障检测策略进行了深入探讨。该方法采用 Park 变换处理三相输出电流，提取 Park 矢量轨迹特征，并通过分析特征变化趋势，确定逆变器故障的类型及位置。

主元分析（Principal Component Analysis, PCA）是一种数据降维技术，用于简化数据结构，提取关键特征信息。在逆变器故障诊断中，PCA 能够有效地减少特征维度，提高故障诊断效率。文献[21]针对核主元分析法中的“淹没”问题，提出一种改进策略。该方法通过计算各变量对故障统计量的贡献值，引入贡献值权重矩阵，对逆变器故障特征进行加权，以减少数据处理量并提高故障检测的准确性。

基于信号处理的故障诊断方法依赖于大量传感器数，其表现会受到数据质量、信号处理能力及特征选择策略的影响。为了提高诊断精度，需要对采集的信号进

行预处理,降低噪声干扰,并提取关键故障特征。在实际应用中,通常结合信号处理技术与自适应学习算法,借助计算机强大的计算能力和智能算法,以提升故障检测的效率。

1.2.2 基于模型的方法

基于模型的故障诊断方法依赖于精准的数学模型,其核心原理是分析系统模型与实际运行状态之间的误差,以识别故障的发生及其具体类型。首先,根据实验对象建立准确的数学模型,获得系统在正常状态下的先验信息。然后,检测系统的实时运行状态,获取关键参数。最后,基于先验信息和状态参数,设计相应的故障诊断算法,计算并分析残差值,以实现故障诊断^[22]。

观测器法通过构建系统观测器对系统状态进行估算,并计算估算值与实际测量值之间的残差,以提取故障信号特征,实现故障检测与诊断。通过对残差变化的分析,可以有效地检测和诊断故障^[23]。常见的观测器模型有:自适应观测器^[24]、龙伯格观测器^[25]和滑模观测器^[26]等。其中,自适应滑模观测器因其结构简单,易于实现的特点,被广泛应用于控制理论与故障诊断领域。文献[27]提出了一种基于自适应滑模观测器的逆变器开路故障方法。该研究构建了逆变器在正常运行与故障状态下的混合逻辑动态模型,并设计了一种可精确估算正常工况下三相电流值的自适应滑模观测器。利用电流残差来构建故障定位变量,可精准确定故障位置,实现单管和双管开路故障的有效诊断。文献[28]提出了一种基于区间滑动观测器的故障诊断技术,结合 IGBT 在正常运行和故障状态下的电流方向,构建了混合逻辑的动态模型。该方法不仅加速了观测器的收敛过程,还减少了抖动现象,从而提升故障诊断系统的稳定性和可靠性。文献[29]针对三相电压源逆变器的多开关管故障,提出了一种基于自动阈值调节的检测技术。该方法通过计算平均极间电压与误差完成故障检测,并融入了自适应阈值调节策略,提高系统对噪声干扰的抵抗能力,增强故障检测的精准度和鲁棒性。文献[30]基于混合逻辑动态模型,提出了一种融合观测器与自动阈值调节的诊断方法,利用电流残差作为诊断变量,实现对开关管故障的精确诊断。

参数估计法的核心思想是通过比较实测数据与理论计算结果之间的误差,识别系统运行状态异常,进而推断故障类型并定位故障^[31]。文献[32]提出了一种基于瞬时功率模型与自适应控制的实时参数计算方法。该方法能够精准构建系统数学模型,并实现有效的故障诊断。文献[33]提出了一种基于复数参数估算的故障检测技术,采用最小二乘估计法计算逆变器输出信号的频谱残差,并通过监测函

数变化趋势，实时检测逆变器故障。参数估计法的优势在于其实时性，能够动态感知系统状态变动，并提供精准的故障检测结果。

尽管基于解析模型的故障检测方法在理论上可实现较高的诊断精度，但其表现高度依赖于待诊断模型的准确性。在实际工业应用中，系统通常表现出复杂的动态行为，并伴随着环境噪声、器件老化和负载变化等不确定因素，这使得构建全面且精准的数学模型极具挑战性。

1.2.3 基于知识的方法

基于知识的故障诊断方法主要依赖于故障特征提取和智能算法，通过对故障样本数据的训练，不断优化模型参数，最终利用优化后的模型实现故障诊断。常见的方法包括支持向量机法、神经网络法、专家系统法等^[34]。

支持向量机（Support Vector Machine, SVM）是一种常用于分类和回归分析的监督学习方法，其核心思想是在特征空间中构建最优超平面，以最大化不同类别数据点之间的间隔，从而实现高效分类。文献[35]提出了一种融合小波变换与多分类支持向量机的在线识别技术，主要用于 IGBT 的故障诊断。该方法首先对故障电流信号进行小波分解，构建特征向量，并利用多分类 SVM 训练模型。实验表明，该模型结构简洁，具有较高的故障识别准确率和良好的泛化能力。文献[36]提出了一种高效的三电平逆变器故障诊断方法，结合改进的自适应噪声完备集合经验模态分解-模糊熵（ICEEMDAN-FE）与 SVM，以三相负载电压作为测试信号，通过 Concordia 变换降低特征维度，利用 ICEEMDAN 提取关键特征，并通过主成分分析（PCA）进行降维处理，最终将处理后的特征输入 SVM 进行训练与分类。该方法具备出色的抗噪能力、快速诊断速度和高诊断准确率。

专家系统（Expert System）基于已有的故障知识库与推理机制，对采集到的运行数据进行分析，从而判断系统运行状态并识别故障类型。该方法依赖于专家规则、决策树或模糊逻辑推理模型，通过模拟人类专家的诊断过程，对故障特征进行匹配和分类。理论上，专家知识库应涵盖所有潜在故障及其相应的解决方案^[37]。文献[38]提出了一种融合神经网络与专家系统的逆变器故障诊断方法，并设计了包含故障预警单元的分层专家系统。该系统通过分析逆变器故障的仿真数据，验证了方法的有效性，为逆变器故障的诊断提供了一种新思路。

神经网络（Neural Network）是机器学习和深度学习领域广泛应用的智能算法，具有出色的自学习能力和泛化能力，特别适用于大规模数据集的处理。由于神经网络无需建立精确数学模型，因此在逆变器故障诊断中得到了广泛应用^[39-41]。

文献[42]提出了一种用于船舶电网中的逆变器故障诊断模型，基于一维卷积神经，考虑了逆变器故障对有限船舶电网的影响。为了减少过拟合问题，模型采用了全局平均池化层和全连接层的组合结构，并通过 Softmax 层验证故障诊断性能。文献[43]提出了一个创新性的逆变器开关管开路故障诊断模型，结合经验模态分解（EMD）和误差反向传播神经网络（BPNN），对 IGBT 单管和双管开路故障数据进行深入分析。通过改进的互补集合经验模态分解（CEEMD），解决了传统 EMD 中的模式混合问题，得到优化后的 CEEMD-BPNN 模型。文献[44]提出了一种基于人工神经网络（ANN）优化训练算法的快速故障诊断策略，显著提高了级联型多电平逆变器系统（CHMLIS）的故障诊断精度和工作效率。文献[45]针对逆变器的多类型故障诊断问题，结合生成对抗网络（CGAN）与长短期记忆网络（LSTM），构建故障诊断模型，并在 dSPACE 半实物平台上进行测试，验证了该方法对逆变器多种类型故障的识别能力。文献[46]提出了一种基于一维卷积神经网络（1D-CNN）的故障检测模型，通过 Simulink 模块生成仿真数据进行训练和测试，并验证了该模型在不同噪声影响下的鲁棒性。

卷积神经网络（Convolutional Neural Network, CNN）在逆变器故障诊断中得到了广泛应用。与传统的卷积神经网络相比，1D-CNN 在处理一维数据时更加有效，而传统卷积神经网络在图像识别领域有着独特的优势^[47]。为了充分发挥 CNN 的空间特征提取能力和深度学习的自适应性，本文提出了一种方法：将一维时序数据转化为二维图像，利用深度学习模型对二维图像进行特征提取，提升逆变器故障诊断的效率和准确率。该方法结合了 CNN 的空间特征提取优势与深度学习的端到端学习优势，能够实现更高效的逆变器故障诊断。

1.2.4 基于并行神经网络的方法

随着深度学习技术的发展，传统单通道神经网络在复杂工况下的特征提取能力逐渐暴露出局限性，特别是在处理复杂、动态变化的故障信号时，单一信号处理模式往往难以捕捉到多维信息，从而影响故障诊断的准确性和鲁棒性。为克服单一信号处理模式的不足，近年来学者们开始探索并行神经网络架构在故障诊断中的应用。通过多分支网络并行处理异构特征，双通道并行 CNN 能够充分挖掘各信号源中的有效信息，进而增强特征表达的完备性，从而提升了故障诊断的准确性和鲁棒性。

在逆变器故障诊断领域，传统的信号分析法和基于模型的算法虽然为诊断提供了有效工具，但在面对噪声干扰、设备老化和负载变化等复杂环境时，仍然面

临一些挑战。信号分析法依赖于精确的特征提取与模型训练，然而在复杂动态信号的处理过程中，其精度和鲁棒性可能受到限制^[48]；基于模型的方法虽然能够提供较高的故障检测精度，但通常需要依赖精确的数学模型和系统参数，这在实际应用中受到诸多因素的影响。相比之下，基于知识的方法虽然能够借助专家经验和规则推理进行故障诊断，但其适应性较差，尤其在处理大规模动态数据时，诊断效果常常受限。

双通道并行 CNN 的优势在于能够同时处理来自多个信号源的数据，并将这些信息融合以提取更全面的特征，从而显著提高故障诊断的准确性和鲁棒性。近年来的研究表明，双通道并行 CNN 在故障诊断中的性能优于传统方法，特别是在复杂和动态环境下。文献[49]采用格拉姆角场将电压和电流信号转换为二维图像，并结合并行卷积神经网络进行训练，实现了逆变器开关管健康状态的高精度诊断。文献[50]提出了并联卷积神经网络模型，通过并行处理不同特征的数据，成功提取了多端直流输电线路的故障诊断精度。文献[51]结合了格拉姆角场与双通道并行卷积神经网络，提出了一种基于图像数据的高效逆变器故障诊断方法，为该领域提供了新的解决思路。

P2D-CNN 通过将不同信号的多维特征进行并行处理，创新性地将电压信号转化为二维图像，显著提高了故障诊断的准确性、实时性和鲁棒性。这一方法克服了传统单通道方法的局限，填补了现有技术在处理复杂故障模式和动态工况时的空白，具有广泛的应用前景和实际价值。

1.2.5 本文研究范围与主要内容

本研究聚焦于三相逆变器中功率开关管开路故障的智能诊断问题，研究对象聚焦于三相逆变器中的 IGBT 单管及双管开路故障。相较于短路故障，开路故障通常不会立即引起系统停机，具有一定的隐蔽性，且传统保护机制难以及时响应，若长期未被检测，极易诱发系统稳定性下降乃至继发性故障，进而影响电力电子系统的可靠性和安全性。因此，围绕开路故障开展高精度、强鲁棒性的故障诊断研究，具有重要的工程意义与应用价值。

本文的主要研究内容包括以下四个方面：

（1）故障信号采集与仿真建模

基于 MATLAB/Simulink 仿真平台搭建完整的三相逆变器系统，设计 22 种典型工况，采集 A 相电压信号构建故障数据集，涵盖正常状态、单管故障及多类双管开路故障；

（2） 二维图像转换与特征提取方法设计

针对开路故障信号的非平稳特性，分别采用短时傅里叶变换（Short-Time Fourier Transform, STFT）、格拉姆角场（Gramian Angular Field, GAF）与马尔可夫转移场（Markov Transition Field, MTF）对一维时域信号进行图像化转换，实现从时频域与状态空间多个维度提取高区分度的特征表达；

（3） 并行卷积神经网络模型建构与优化

提出基于双通道并行卷积神经网络（Parallel Two-Dimensional Convolutional Neural Network, P2D-CNN）的故障诊断模型，分别对不同图像特征进行通道分支提取与融合；进一步引入通道注意力与空间注意力机制（Convolutional Block Attention Module, CBAM），构建 P2D-CNN-CBAM 模型，以提升在低信噪比等复杂工况下的特征感知能力与诊断准确性；

（4） 模型性能评估与对比验证

在不同信噪比条件下对所提模型进行系统评估，并与传统 2D-CNN 方法进行性能对比。全面验证其在诊断准确率、抗噪声能力与泛化性能方面的优势。

1.3 章节安排

本文提出了一种基于双通道并行卷积神经网络(Parallel Two-Channel Convolutional Neural Network, P2D-CNN)的三相逆变器故障诊断方法。首先，基于逆变器的工作原理，使用仿真平台对三相逆变器进行了建模与模拟，从而获取不同工况下的故障数据，为后续的 P2D-CNN 模型训练和测试提供关键的数据支持。其次，采用二维图像转换方法，将不同工况下的电压信号转换为二维图像，作为 P2D-CNN 模型的输入。最后，利用 P2D-CNN 模型进行实验验证，评估该方法的故障识别准确性与可行性。

本文共分为六个章节，主要研究内容如下：

第 1 章 绪论：本章通过整理与分析相关文献，首先概述三相逆变器故障诊断的研究背景及其重要性；随后，综述当前主流的故障诊断方法，包括基于信号处理、数学模型和智能算法的方法，并分析各自的优势与局限性。此外，探讨深度学习在故障诊断中的潜在价值，明确本研究的方法及核心内容，并对论文总体框架及章节布局进行简要介绍。

第 2 章 三相逆变器原理分析与特征图像构建：本章详细介绍三相逆变器的基本结构与工作原理，分析典型的开路故障类型，并基于 MATLAB/Simulink 平

台构建三相逆变器故障仿真模型，获取各类故障状态下的输出电压信号；同时，设计将原始时域信号转换为二维图像的方法，为后续模型输入提供图像化特征基础。

第 3 章 P2D-CNN 诊断模型设计：详细介绍模型各层的设计思路与参数配置，并对卷积层、激活层、池化层、Dropout 层与全连接层的功能与作用进行逐层说明，完成基础故障诊断模型的构建。

第 4 章 基于 P2D-CNN 的故障诊断方法：本章构建基于 P2D-CNN 的逆变器故障诊断方法，利用 MATLAB/Simulink 仿真获取不同故障状态下的电压信号，并采用 STFT、GAF、MTF 方法转换为二维图像，提取关键特征。随后，训练 P2D-CNN 模型对故障类型进行分类，并在不同噪声水平下评估其诊断性能。实验结果表明，该方法能够有效提升故障识别的准确性和鲁棒性，并优于传统 2D-CNN 模型。

第 5 章：基于 P2D-CNN-CBAM 的逆变器故障诊断模型：针对 P2D-CNN 模型在复杂环境下特征提取能力不足的问题，本章引入 CBAM 注意力机制，构建 P2D-CNN-CBAM 故障诊断模型。该模型通过通道注意力和空间注意力增强特征学习能力，提高低信噪比条件下的分类精度。实验通过不同信噪比的 STFT-GADF 数据集，对比分析了 P2D-CNN 与 P2D-CNN-CBAM 的诊断性能，验证其在复杂工况下的优势。

第 6 章：总结与展望：本章对全文的主要研究内容进行总结，并讨论目前研究的局限性。此外，针对现阶段方法的不足，提出未来的研究方向与改进方案，以进一步提高逆变器故障诊断的智能水平与工程实用性。

第二章 三相逆变器原理分析与特征图像构建

2.1 三相逆变器的工作原理

三相逆变器的核心功能是在控制电路的调控下，把直流电能转化为可调频率和电压的交流电源^[52]。利用脉冲宽度调制技术（Pulse Width Modulation, PWM），可以将原始的方波信号转换为接近正弦波的输出信号。为了进一步改善输出波形的平滑性，电路中通常引入滤波电感，以实现更加平滑的正弦波输出^[53]。与传统的 PWM 技术相比，SVPWM 具有更高的直流电压利用率、更低的谐波失真以及更优的动态响应特性。因此，本文采用 SVPWM 技术作为调控策略，用于触发绝缘栅双极型晶体管（Insulated Gate Bipolar Transistor, IGBT）的开关操作，从而提升逆变器的输出性能、转换效率和稳定性。以电压型三相逆变器为例，其电路结构如图 2.1 所示。




图 2.1 电路结构图

在三相逆变器正常运行的情况下，同一桥臂的上下功率开关管交替导通，其中上桥臂与下桥臂的开关管触发角相差 180° ，而三相之间的触发角依次相差 120° 。由于每个功率器件都要承受电压和电流冲击，导致三相之间存在显著的能量交换。因此，在运行过程中，始终保持三只功率开关管导通，以确保逆变器稳定运行。当三相功率开关管关断时，需要采用相应的控制策略，确保其稳定导通，以实现电路的有效调节。在三相逆变器中，功率开关管的导通模式主要有两种不同的组合方式：一种是两个上桥臂加一个下桥臂的组合，另一种是两个下桥臂加一个上桥臂的组合。不同的导通模式会导致不同的相位切换。每一次的换流操作都是在相同相位的上下桥臂之间完成，因此，这种换流方式被称为纵向换流^[54]。

三相逆变器的工作状态通常可归纳为六种基本模式，每种状态对应不同的桥臂功率开关器件组合。这六种工作状态决定了逆变器的输出电压特性，其具体表

现如图 2.2 三相逆变器的六种工作状态：




图 2.2 三相逆变器的六种工作状态

三相逆变器的开关状态可用三位二进制数表示（例如 100），其中：

- 1 表示上桥臂导通，输出高电平；
- 0 表示下桥臂导通，输出低电平。

根据三个桥臂的开关状态组合，可获得六种有效的非零电压矢量($U_1 - U_6$)和两种零电压矢量 (U_0 和 U_7)。

六种非零开关状态及其对应的输出电压矢量如表 2.1 所示：

表 2.1 六种非零开关状态及其对应的输出电压矢量			
状态编号	开关状态 (ABC)	输出电压矢量 (U_A, U_B, U_C)	空间矢量方向
U_1	100	$(U_{dc}, -U_{dc}/2, -U_{dc}/2)$	0°
U_2	110	$(U_{dc}/2, U_{dc}/2, -U_{dc}/2)$	60°
U_3	010	$(-U_{dc}/2, U_{dc}, -U_{dc}/2)$	120°
U_4	011	$(-U_{dc}, U_{dc}/2, U_{dc}/2)$	180°
U_5	001	$(-U_{dc}/2, -U_{dc}/2, U_{dc})$	240°
U_6	101	$(U_{dc}/2, -U_{dc}, U_{dc}/2)$	300°

两种零电压矢量如

表 2.2 所示：

表 2.2 两种零电压矢量			
状态 编号	开关状态 (ABC)	输出电压矢量 (U_A, U_B, U_C)	输出电压矢量 (U_A, U_B, U_C)
U_0	000	(0,0,0)	任意方向
U_7	111	(0,0,0)	任意方向

2.2 三相逆变器的故障分析及故障分类

本文的主要研究对象为电压型三相逆变器。在三相逆变器系统中，功率开关管、续流二极管以及控制电路构成核心组件，同时也是故障高发区域。这些组件发生故障可能会对影响设备的安全运行和系统的可靠性。

针对功率开关管的短路故障，目前已有成熟的保护电路方案，通常采用熔断器或其他保护机制，在短路故障发生时迅速切断电路，将其转化为开路故障，以降低系统损害。对于涉及双管及以上的故障，更换整个变换器通常是更为经济且可靠的解决方案，无需进一步的故障诊断。因此，本文的研究重点集中在三相逆变器单管故障及双管故障的诊断方法。

根据发生故障的功率开关管数量及其所在位置，可对三相逆变器故障类型进行分类，如表 2.3 所示：

表 2.3 三相逆变器故障类型分类	
故障类型	具体故障位置
正常状态	无
单管故障	$T_1, T_2, T_3, T_4, T_5, T_6$
同桥臂双管故障	$T_1T_3, T_1T_5, T_3T_5, T_2T_4, T_2T_6, T_4T_6$
同相位双管故障	T_1T_2, T_3T_4, T_5T_6
交叉桥臂双管故障	$T_1T_4, T_1T_6, T_3T_2, T_3T_6, T_5T_2, T_5T_4$

在三相逆变器的正常工作过程中，可以通过输出电压信号检测系统的运行状态。逆变器通过控制功率开关管的导通与关断，实现直流电向交流电的转换，以满足不同负载需求。当功率开关管处于导通状态时，电路进入正常运行模式，此时输出电压表现为周期性的正弦波形。

以 A 相的输出电压为例，在逆变器正常运行状态下，输出电压波近似于正弦波。然而，当三相逆变器发生开路故障时，其输出电压特性将发生变化，表现

为三相电压的不均衡。以 A 相的功率开关管 T_1 发生开路故障为例，其电路拓扑结构如图 2.3 所示。




图 2.3 T_1 故障时电路运行图

在 0.1s 时，功率管 T_1 发生断路故障。由于 T_1 无法导通，A 相输出电压将进入断续状态，无法输出正向电压。此时，A 相的电压仅能通过下桥臂开关管 T_4 控制，导致 A 相仅能输出负电压，电压波形出现严重失真。因此，在 T_1 断路故障发生后，A 相无法正常输出正向，仅能维持负向电压输出。

T_1 断路故障引起的电压三相不平衡：在三相逆变器正常工作时，每个时刻应至少有三个开关管同时导通，以确保输出电压的三相平衡，并维持电流的正常回流。例如，可以是上桥臂中一个开关管与下桥臂中两个开关管共同导通，或者是上桥臂中两个开关管与下桥臂中的一个开关管共同导通。然而，当 T_1 发生断路故障时，上桥臂的电压回路无法正常闭合，导致 A 相无法输出正向电压。在这种情况下，A 相只能依赖于下桥臂开关管 T_4 进行导通来，使其仅能输出负向电压，从而破坏电压波形的对称性。由于 A 相电压的异常，逆变器的输出电压发生不平衡，导致三相电压之间的失衡。这种电压不平衡可能对逆变器的正常运行造成严重的影响，包括：降低系统的运行效率，增加电网谐波含量以及导致设备过热或损坏等。因此，及时检测并诊断逆变器的开路故障对于保障设备的稳定运行至关重要。

2.3 三相逆变器的故障仿真

2.3.1 开路故障仿真

在 MATLAB/Simulink 环境下，构建了一个基于三相逆变器电路拓扑的仿真模型，并采用 SVPWM 技术对六个功率开关管进行控制，以更准确地模拟逆变器在实际运行中的动态特性。搭建的三相逆变器系统模型如图 2.4 所示。仿真参数如表 2.4。




图 2.4 三相逆变器系统模型

表 2.4 仿真参数

参数	数值
直流电压 V_{dc}	800V
三相电压有效值 V_0	220V
开关频率 f_s	10kHz
滤波电感 L	40mH
滤波电容 C	30uF
负载 R	10Ω

2.3.2 开路故障分析

在 MATLAB/Simulink 环境下，构建了三相逆变器电路仿真模型，并将逆变器输出的电压信号作为故障诊断的分析对象。为研究逆变器在不同工况下的电压特性，选取其逆变器运行时间 0.10s 至 0.30s 内的波形数据进行分析。




图 2.5 逆变器正常工作状态下 A 相电压波形

如图 2.5 所示, 该图展示了逆变器在正常工作状态下 A 相的电压波形。




图 2.6 单管故障时的 A 相电压波形




图 2.7 同桥臂双管故障时的 A 相电压波形

图 2.6 展示了三相逆变器在单管故障情况下的 A 相电压波形。图 2.7 展示了同桥臂双管故障发生时的 A 相电压波形图。图 2.8 为同相位双管故障情况下的 A 相电压波形图。图 2.9 则对应交叉桥臂双管故障时的 A 相电压波形图。




图 2.8 同相位双管故障时的 A 相电压波形




图 2.9 交叉桥臂双管故障的 A 相电压波形

通过比对检测到的电压波形，得出以下结论：：

(1) 单管开路故障：当 T1,T3,T5 出现故障时，输出波形的正半周消失，而负半周出现畸变，并伴随幅值增大；当 T2,T4,T6 发生故障时，输出波形的负半

周消失，而正半周出现畸变，同样伴随幅值增大。(2) 同桥臂双管开路故障：在该故障模式下，受损桥臂对应相的输出波形同时丧失正半周和负半周，使得整体波形趋近于零，几乎无电压输出。其余两相的波形会发生畸变，并且幅值有所增大。(3) 同相位双管开路故障：当该故障模式下，受损相的输出波形可能会失去正半周或负半周，但相比于同桥臂双管故障，其影响相对较轻。其他亮相的波形可能会发生畸变，但不会完全丧失输出。(4) 交叉桥臂双管开路故障：在该故障模型下，故障相的输出波形可能会出现正半周或负半周的缺失。同时，另一相的波形也可能受到影响，出现明显的畸变，破坏整个系统的电压平衡。

以上分析可以看出，在某些特定的故障情况下，逆变器 A 相输出的电压波形呈现出类似的特性，仅凭人工观察难以准确识别具体故障类型。因此，应用可靠的数据处理技术来提取故障特征，对于提高故障诊断的准确性和分类效果显得尤为关键。

2.4 特征图像构建方法

为实现对三相逆变器故障信号中关键特征的充分提取，并提升后续模型对非线性、非平稳信号的学习与识别能力，本文引入三种典型的一维信号二维图像转换方法：短时傅里叶变换（Short-Time Fourier Transform, STFT）、格拉姆角场（Gramian Angular Field, GAF）与马尔可夫转移场（Markov Transition Field, MTF）。通过对原始电压波形的图像化处理，将故障信息嵌入更高维度的特征空间，为并行卷积神经网络的图像输入提供多样化、结构化的数据支撑。

2.4.1 短时傅里叶变换

短时傅里叶变换（short-term Fourier transform, STFT）是一种专门为处理非平稳信号设计的时频分析技术，核心目标是将一维时域信号转换为二维时频图像，并从二维图像中提取信号的时域和频域详细信息。其基本思想是对非平稳信号进行时频分析，以揭示信号在不同时间位置上的频率成分^[56]。因此，STFT 可看作是时间和频率的二维函数，能够同时在时域和频域上描述信号的变化。其计算公式如下：

$$STFT(t, f) = \int_{-\infty}^{\infty} x(\tau) \cdot \omega(\tau - t) \cdot e^{-j2\pi f\tau} d\tau \quad (2.1)$$

其中， $\omega(\tau - t)$ 是窗函数，用于截取信号的局部片段， t 是时间变量， f 是频率变量。

STFT 转换的具体过程如下：

首先，将原始的一维时域信号 $x(t)$ 划分为多个短时间段，通过一个窗函数 $\omega(t)$ 对信号进行局部化处理。并在每个时间窗口内对信号进行傅里叶变换，得到该时间段的频率成分，最终形成一个时频域的二维矩阵，并生成时频图。时频图以时间为横轴、频率为纵轴，颜色的强度表示能量的大小。图 2.10 正常工作情况下 A 相电压波形及其转换后的 STFT 图像展示了 A 相电压在正常工作情况下的波形及其对应的 STFT 转换结果。




图 2.10 正常工作情况下 A 相电压波形及其转换后的 STFT 图像

STFT 的优势在于能够同时提供时间和频率信息，适用于非平稳信号分析。然而 STFT 的时间和频率分辨率受窗口函数长度的影响，较长的窗口会提高频率分辨率但会降低时间分辨^[57]。因此，合理选择窗口函数长度对于精确分析信号特征至关重要。时间和频率分辨率计算如下：

$$F = \begin{cases} \frac{N_{\omega}}{2} + 1, N_{\omega} \text{ is odd} \\ \frac{N_{\omega} + 1}{2}, N_{\omega} \text{ is even} \end{cases} \quad (2.2)$$

$$T = \left\lfloor \frac{N_x - N_o}{N_{\omega} - N_o} \right\rfloor \quad (2.3)$$

其中， N_x 是待处理信号的长度， N_{ω} 是窗函数的长度， N_o 是窗函数平移期间的重叠长度， $\lfloor \cdot \rfloor$ 表示向下取整运算。

2.4.2 格拉姆角场

格拉姆角场（Gramian Angular Field, GAF）是一种用于将一维时间序列映射为二维图像的方法，能够最大限度地保留原始信号特征，避免特征丢失。其基本原理是：先将一维数据从笛卡尔坐标系转为极坐标系，利用三角函数获取时间相关性，并将这些信息从左上到右下排列，最后生成 GAF 图像。

定义时间序列 $X = (x_1, x_2, \dots, x_n)$ ，其中， N 为时间点总数， i 为时间点， $i \in [1, n]$ 。GAF 变换流程如下：

首先，将原始的一维时间序列 $X = (x_1, x_2, \dots, x_n)$ 归一化到区间 $[-1, 1]$ ，得到

归一化后的时间序列 $\tilde{X} = (\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_n)$ 。归一化公式为：

$$\tilde{x}_i = \frac{x_i - \min(X)}{\max(X) - \min(X)} \cdot 2 - 1 \quad (2.4)$$

其中， $\min(X)$ 和 $\max(X)$ 分别表示时间序列 X 的最大值和最小值。

再将归一化后的时间序列 $\tilde{X}$ 映射到极坐标系。具体来说，将每个数据点 $\tilde{x}_i$ 转换为极坐标角度 ϕ_i ，并将时间戳 t_i 转换为半径 r_i 。转换公式为：

$$\phi_i = \arccos(\tilde{x}_i), \quad r_i = \frac{t_i}{N} \quad (2.5)$$

其中， t_i 是时间戳， N 为时间序列的长度，用于正则化极坐标空间。

在极坐标映射后，通过计算每两点之间的三角弦函数值，生成格拉姆矩阵。GAF 包含两种形式：格拉姆角和场（Gramian Angular Summation Field, GASF）和格拉姆角差场（Gramian Angular Difference Field, GADF）。它们的定义分别为：

$$GASF = \cos(\phi_i + \phi_j), \quad GADF = \sin(\phi_i - \phi_j) \quad (2.6)$$

其中， ϕ_i 和 ϕ_j 是极坐标角度。

GAF 的特点在于其双射性和时间关系的保留，能够将时间序列的时间依赖性编码为图像，从而更集中地表达信号特征。在故障信号分析中，GAF 图像能够直观地反映信号的动态变化，例如幅度变化较慢时呈现颜色相近的连通区域，而幅度快速变化时则出现水平或垂直线。相较于传统的一维时间序列分析方法，GAF 在特征提取和时间依赖性保留方面具有显著优势，为后续故障诊断提供了高质量的特征输入，正常工作情况下 A 相电压波形及其转换后的 GAF 图像如图 2.11 所示：




图 2.11 正常工作情况下 A 相电压波形及其转换后的 GAF 图像

2.4.3 马尔可夫转移场

马尔可夫转移场（Markov Transition Field, MTF）是一种用于将一维时间序

列映射为二维图像的转换方法，通过构建时间序列的马尔可夫转移矩阵，捕捉信号的动态特性^[58]。具体过程如下：

首先，将时间序列 $X = (x_1, x_2, \dots, x_n)$ 分箱为 Q 个区间，每个区间代表一个状态。再计算状态转移矩阵 W ，公式为：

$$W_{ij} = P(x_t \in q_i | x_{t-1} \in q_j) \quad (2.7)$$

其中， q_i 和 q_j 是分箱后的状态。

构建 MTF 矩阵，公式为：

$$MTF_{ij} = W_{q(x_i), q(x_j)} \quad (2.8)$$

其中， $q(x_i)$ 表示 x_i 所属的状态。MTF 矩阵从左上角到右下角编码了时间序列的状态转移信息。

MTF 能够捕捉时间序列的随机性和状态变化，适用于描述信号的动态特性。在故障信号分析中，MTF 图像能够直观地反映信号的状态转移模式^[59]。正常工作情况下 A 相电压波形及其转换后的 MTF 图像如图 2.12 所示




图 2.12 正常工作情况下 A 相电压波形及其转换后的 MTF 图像

2.5 本章小结

本章围绕三相逆变器的工作原理与故障特性进行了系统性分析。首先，介绍了逆变器的基本结构及其在 SVPWM 控制策略下的运行机制，明确了各功率器件的导通关系与电压输出模式。随后，针 IGBT 开路故障的典型类型，包括正常状态、单管、同桥臂双管、同相位双管和交叉桥臂双管故障，建立了故障仿真模型，并采集了 A 相电压信号，在时域上对故障引起的电压波形失真、相位不对称和幅值畸变等现象进行了深入分析。

在此基础上，为更有效提取电压信号中的关键故障特征，引入 STFT、GAF 与 MTF 三种典型的一维信号二维图像转换方法，分别从时频局部性、相位相关性及状态转移模式三个维度对故障信号进行了图像化转换。转换后的图像样本展示出明显的结构差异性，具备良好的模式可分性，为后续特征分析与识别提供了更丰富的信息表达形式。

本章内容完成了从逆变器建模、故障工况构建到信号图像转换的全过程，为深入理解故障信号的结构特征提供了理论与数据基础。

第三章 P2D-CNN 故障诊断模型设计

3.1 引言

卷积神经网络（Convolutional Neural Network, CNN）因其卓越的特征自动提取能力与端到端建模优势，近年来已广泛应用于故障诊断领域，特别适用于处理复杂工况下的非线性信号识别任务。然而，传统 CNN 模型通常采用单通道结构进行特征输入，仅能处理单一类型的输入特征，难以同时融合来自不同维度、不同特征空间的信息。当输入数据存在显著的异构性和多模态特征时，单通道结构往往表现出特征利用率低、识别精度不足以及泛化能力有限等问题。

针对上述问题，本文在前期基于 STFT、GAF 和 MTF 三种方法对故障电压信号进行二维图像化处理的基础上，构建了一种双通道并行卷积神经网络（Parallel Two-Dimensional Convolutional Neural Network, P2D-CNN）。该模型采用双输入分支结构，分别对不同图像类型进行特征提取，并在融合层进行特征融合，旨在充分挖掘多模态图像在时频域、相位域与状态演化维度上的互补性，从而增强模型的特征表达能力与故障判别能力。

3.2 P2D-CNN 模型结构设计

在三相逆变器故障诊断中，传统基于一维时域或频域信号的分析方法在特征提取方面存在明显局限，尤其在面对信号非平稳性强、噪声干扰大、特征分布复杂的工况时，难以准确识别故障模式，影响诊断精度。随着图像转换技术的发展，STFT、GAF 以及 MTF 方法为电压信号提供了更丰富的二维表达形式，极大增强了对时频结构、相位信息和演化规律的描述能力。然而，仅依赖单通道输入的传统卷积神经网络（CNN）在处理这类图像时，存在特征利用率低、通道间信息干扰大等问题，难以充分发挥图像特征的判别优势。

为此，本文提出一种基于并行二维卷积神经网络（Parallel 2D Convolutional Neural Network, P2D-CNN）的故障诊断模型。该模型通过构建双通道并行卷积分支结构，将不同类型图像分别输入两个独立分支，进行特征提取与处理。每个分支独立学习输入图像的空间分布特征和语义结构，有效提升了通道内特征表达的一致性与完整性。随后在融合模块中对两分支特征进行整合，进一步增强模型对复杂图像间特征差异与关联性的表达能力。

与传统 CNN 模型相比，P2D-CNN 在结构上具有以下几个优势：

（1）增强特征独立性：通过双分支并行提取特征，避免多类图像特征混合带来的信息干扰；（2）提升融合表达能力：采用元素级加权融合方式整合两通道输出，兼顾特征独立性与互补性；（3）引入正则化机制提高鲁棒性：结合 BN 层与 Dropout 层优化训练过程，降低过拟合风险；（4）结构紧凑，计算高效：模型参数适中、层次清晰，适用于具有实时诊断需求的工业场景。

P2D-CNN 模型由五个功能模块组成：输入层、并行卷积路径、特征融合模块、全连接层与输出分类器。各模块功能分明、结构统一，构成完整的特征提取与分类流程，其整体结构如图 3.1 所示。




图 3.1 P2D-CNN 网络模型结构

从 P2D-CNN 的结构可以看出，该模型采用双通道并行架构，整体由两个相同的分支组成。由于各分支的输入数据特征不同，在训练过程中，各分支学习的信息也有所差异。这种结构使得 P2D-CNN 能够充分学习各分支的故障特征，并在融合层进行特征整合，从而获取更丰富的特征信息，提高模型的故障分类精度。

卷积层中的卷积核大小设定为 3×3 ，步长为 1，并采用全 0 填充，以保持特征图的空间尺寸不变。在卷积层中添加批量归一化(Batch Normalization, BN)层，以优化网络的训练过程，使其能够支持更大的学习率和更灵活的参数初始化，并提高网络的收敛速度和整体性能。卷积层选用 ReLU 函数作为激活函数，目的是为了提升网络在非线性表达方面的能力。在完成卷积运算之后，进入池化层，采用最大池化，池化窗口的内核设定为 2×2 ，步长为 2，以降低特征图的空间维度，同时保留关键信息。经过“卷积+池化”操作后，添加 Dropout 层，并将 Dropout

的参数设定为 0.5，即在每次训练迭代过程中随机舍弃 50% 的神经元，以防止部分特征占据主导地位，降低过拟合风险，并提升模型的泛化能力。在完成特征提取后，采用 Flatten 层对特征图进行展平，并进行特征融合。融合方式采用逐元素相加操作，将双通道的展平特征进行加和，以整合不同转换方法提取的特征信息。最终采用全连接层，神经元数量设定为 22，并采用 Softmax 分类器将全连接层的输出转换为概率分布，从而完成故障类别的分类任务。该网络的整体结构与参数设定如表 3.1 所示。

表 3.1 网络结构及参数

层类型	参数	输出维度	相连接层
Input_1		$64 \times 64 \times 3$	
Input_2		$64 \times 64 \times 3$	
Conv_1	卷积核大小: 3×3 数量: 8 步长: 1	$64 \times 64 \times 8$	Input_1
Conv_2	卷积核大小: 3×3 数量: 8 步长: 1	$64 \times 64 \times 8$	Input_2
BN_1		$64 \times 64 \times 8$	Conv_1
BN_2		$64 \times 64 \times 8$	Conv_2
ReLU_1		$64 \times 64 \times 8$	BN_1
ReLU_2		$64 \times 64 \times 8$	BN_2
Maxpooling_1	池化窗口 2×2 : 步长: 2	$31 \times 31 \times 8$	ReLU_1
Maxpooling_2	池化窗口 2×2 : 步长: 2	$31 \times 31 \times 8$	ReLU_2
Dropout_1	Dropout=0.5	$31 \times 31 \times 8$	Maxpooling_1
Dropout_2	Dropout=0.5	$31 \times 31 \times 8$	Maxpooling_2
Flatten_1		7688	Dropout_1
Flatten_2		7688	Dropout_2
Addition		7688	Flatten_1, Flatten_2
Fully Connected	神经元数量: 22	22	Addition
Softmax	神经元数量: 22	22	Fully Connected

3.3 P2D-CNN 模型结构模块化设计

为提高模型结构的可解释性与设计的层次化清晰度, 本文将所构建的 P2D-CNN 模型划分为多个功能结构模块, 并分别对其进行参数配置与功能优化。整体模型由输入层、卷积层、激活层、池化层、Dropout 层和全连接层等典型结构单元组成, 各模块围绕图像特征尺寸、特征提取需求与分类精度进行针对性设计与调优。本节将依次介绍各结构模块在 P2D-CNN 模型中的配置方式与功能作用。

3.3.1 输入层

输入层是 P2D-CNN 模型的起始模块, 负责接收由 STFT、GAF 以及 MTF 图像转换方法生成的二维故障特征图像。考虑到图像来源具有多样性、尺寸不统一等问题, 模型统一设定输入图像的尺寸为 64×64 像素, 通道数为 3。考虑到不同图像类型所承载的特征维度存在差异, 模型采用双通道并行输入架构, 分别对应两种图像特征类型。两个输入支路在结构上保持对称、在参数上独立, 能够分别从不同角度提取故障图像的空间分布与演化特征, 有效增强模型对图像多样性的适应能力。

为提升网络训练的数值稳定性, 所有输入图像在进入网络前均进行归一化处理, 使像素值归一至 $[0,1]$ 区间。该处理不仅加快了模型的收敛速度, 也有助于抑制梯度波动。此外, 为保障图像在网络传播过程中的空间结构不被破坏, 输入图像的尺寸和通道数严格依据图像转换方法的输出设置, 并与后续卷积层的感受野设计紧密匹配。该输入层设计在保证结构统一性的同时, 也为深层特征提取与后续特征融合奠定了良好的数据基础。

3.3.2 卷积层

卷积层是 P2D-CNN 模型中实现图像特征提取的关键模块, 主要通过局部感受野机制对输入图像中的边缘、纹理与空间结构等多层次特征进行逐级提取与抽象^[60]。在本模型中, 双通道结构的每个分支均独立配置卷积模块, 用于分别对不同类型图像输入进行特征建模, 确保通道间特征表达的独立性与完整性。二维卷积的基本结构如图 3.2 所示。

卷积层的基本运算公式如下:

$$x_j^l = f\left(\sum_{i \in M_j} x_i^{l-1} * k_{ij}^l + b_j^l\right) \quad (3.1)$$

其中, f 为非线性激活函数; l 为网络层数; x_j^l 为第 l 层的第 j 个特征图; x_i^{l-1} 为卷积层 $l-1$ 的输出; k_{ij}^l 为卷积核的权值; b_j^l 偏置项; M_j 为输入的二维图像数据集; $*$ 表示卷积运算。




图 3.2 二维卷积的基本结构

卷积层的设计需要综合考虑卷积核的大小、步长和填充方式 (padding) 等关键参数。卷积核的大小决定了每个局部区域的感受野, 较小的卷积核, 可以提取边缘、纹理等细节特征, 而较大的卷积核则能够捕捉更大的区域信息。步长 (stride) 控制卷积核在图像上的移动步幅, 较大的步长会缩小输出特征图的尺寸, 降低计算成本, 但可能会丢失部分细节信息。较小的步长能够保留更多的细节空间, 但会增加计算量。填充方式则用来控制特征图的尺寸变化, 避免信息损失。零填充可以在输入图像周围补零, 使卷积操作后输出尺寸保持不变, 无填充直接执行卷积操作, 输出特征图尺寸通常会缩小。

在本研究中, P2D-CNN 模型的每个分支仅设置一层卷积结构, 卷积核大小为 3×3 , 步长为 1, 采用对称的零填充 (padding=1), 以保持特征图的空间尺寸不变。该结构在简化网络参数数量的同时, 确保了对局部图像特征的有效提取, 为后续的特征融合与分类提供了良好的特征基础。

3.3.3 激活层

激活函数的作用是在神经网络中引入非线性特性, 使模型能够学习和表达复杂的特征, 提高分类与回归任务的性能^[61]。在 P2D-CNN 模型中, 卷积操作完成后紧接着引入激活函数, 以增强网络对非线性故障特征的建模能力, 并提升网络在复杂特征空间中的判别效果。

在深度神经网络的训练过程中, 激活函数的选择对梯度传播、收敛速度以及泛化能力具有重要的影响。合理的激活函数不仅可以增强模型的稳定性, 还能有效缓解梯度消失或梯度爆炸问题, 提高网络的计算效率^[62]。常见的激活函数可分

为饱和激活函数和非饱和激活函数，两者在梯度计算与收敛速度方面存在明显差异。饱和激活函数能够将输入值映射到有限区间，但可能导致梯度消失，从而影响深层网络的训练，如：Sigmoid, Tanh。非饱和激活函数能够加速梯度计算，提高网络的学习能力，同时缓解梯度消失问题，包括 ReLU、RReLU、PreLU 等。

Sigmoid 函数可将输入数据映射到[0,1]区间，其定义如下：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (3.2)$$

Sigmoid 函数如图 3.3 所示。




图 3.3 Sigmoid 函数

Sigmoid 函数的优点是能够将输出压缩到[0, 1]区间，常用于二分类问题。

Tanh 函数：Tanh 函数的输出区间为[-1, 1]，它是 Sigmoid 函数的一个改进，定义如下：

$$\tanh(x) = \frac{2}{1 + e^{-2x}} - 1 \quad (3.3)$$

Tanh 函数如图 3.4 所示。




图 3.4 Tanh 函数

与 Sigmoid 函数相比，Tanh 函数的输出范围较大，其输出以 0 为中心，能够更好地应对梯度消失问题。

ReLU 函数是一种广泛应用的非饱和激活函数，其定义为：

$$f_{ReLU}(x) = \begin{cases} \max(0, x), & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (3.4)$$

ReLU 函数如图 3.5 所示。

ReLU 的优点在于：1) 非饱和特性可以缓解梯度消失问题；2) 计算效率高，收敛速度快；3) 可以使网络更稀疏，减少参数间的冗余，从而防止过拟合^[63]。

综合计算效率与模型鲁棒性考虑，本文采用 ReLU 函数作为激活函数，以提高训练速度和性能。在 P2D-CNN 中，ReLU 的引入不仅提升了特征表达的稀疏性，还有效强化了模型对图像局部显著区域的响应能力，从而提高在复杂工况下的识别准确率与鲁棒性。




图 3.5 ReLU 函数

为了进一步优化网络的性能，本文在卷积层和激活函数之间引入了批归一化（Batch Normalization, BN）层，目的是优化训练流程并加快收敛速度。BN 层的运算过程如下：

计算均值：

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i \quad (3.5)$$

计算方差：

$$\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2 \quad (3.6)$$

归一化处理：

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \quad (3.7)$$

尺度和偏移变换：

$$y_i = \gamma \hat{x}_i + \beta = BN_{\gamma, \beta}(x_i) \quad (3.8)$$

其中， γ 和 β 是可学习的 c 参数， ε 是为了防止除零而加入的微小常数。

3.3.4 池化层

池化层（Pooling Layer）作为卷积神经网络中的下采样模块，主要用于减少特征图的空间维度，缓解过拟合风险，并提升特征的平移不变性与局部鲁棒性。在 P2D-CNN 模型中，每个卷积分支在卷积与激活操作之后均引入池化层，以压缩特征表示、降低计算复杂度，同时增强网络对局部扰动的容忍能力。

与卷积层不同，池化层的操作不依赖于学习参数，而是通过固定规则，对输入特征图进行处理。池化层基本原理如图 3.6 所示。




图 3.6 池化层基本原理

池化层通过对局部区域进行降采样，保留了关键特征的同时压缩特征图尺寸，从而减少计算开销。池化操作主要包括两种常见形式：最大池化和平均池化。

最大池化：最大池化通过选取池化窗口内的最大值来表示该区域的特征，这种方法能够突出特征图中的最显著特征，常用于提取图像中的关键部分如边缘和纹理。最大池化的数学表示为：

$$y^{(l)} = \max[x_{ij}^{(l)}] \quad (3.9)$$

其中， $x_{ij}^{(l)}$ 为池化窗口内的每个元素， $y^{(l)}$ 为池化层的输出。最大池化能够帮助网络对局部变形（如平移、旋转）具备更强的鲁棒性，适用于图像分类和特征提取等任务。

平均池化：平均池化则是计算池化窗口内所有值的平均值，并作为该区域的代表特征。该方法能够减少特征图中的细节信息，提供较为平滑的输出，常用于那些对图像细节要求不高的应用。平均池化的数学表示为：

$$y^{(l)} = \frac{1}{m \times n} \left[\sum_{i=0}^m \sum_{j=0}^n x_{ij}^{(l)} \right] \quad (3.10)$$

其中， $m \times n$ 为池化窗口的大小， $x_{ij}^{(l)}$ 为池化区域内的每个元素， $y^{(l)}$ 为池化

后的输出。相比最大池化，平均池化能够平滑图像，减小噪声影响，尤其适用于需要提取全局信息的任务。

本研究在 P2D-CNN 模型中选用最大池化作为下采样方式，旨在突出局部区域的显著特征，增强模型对图像细节和局部变形的鲁棒性。最大池化不仅有效压缩了特征图尺寸，降低计算复杂度，还为后续的特征融合与分类提供了更加紧凑、关键的特征表示，提升了模型的整体性能与稳定性。

3.3.5 Dropout 层

在深度神经网络的训练过程中，随着网络层数的增加，模型容易产生过拟合现象，尤其在特征维度较高或训练样本有限的情况下更为明显。为提升模型的泛化能力，本文在 P2D-CNN 模型的最大池化层和全连接层之间加入了 Dropout 层作为正则化手段。图 3.7 所示展示了 Dropout 层的操作机制。

从图 3.7 可以看出，在训练过程中，Dropout 会根据预定的比例对部分隐藏神经元进行随机屏蔽，并阻断对应的输入和输出连接。屏蔽作用仅在当前训练过程中生效，在下一次训练时，神经元的屏蔽状态将重新按照相同的比例随机确定。

在本研究中，Dropout 的概率设置为 0.5，意味着每次训练迭代中有一半的特征神经元将被临时屏蔽。这一设计有效缓解了特征冗余导致的过拟合问题，并提升了模型在验证集和测试集上的泛化表现。




图 3.7 Dropout 层原理

3.3.6 全连接层

全连接层在 P2D-CNN 模型中承担着特征压缩、融合与分类输出的关键作用。不同于传统结构中多层全连接的线性堆叠方式，本文将全连接层分别置于融合操作的前后，以更充分地利用每个卷积分支提取的特征信息，增强融合表达的层次

性与判别力。

全连接层是对卷积层和池化层提取的高维特征进行整合,并生成最终的预测结果。在全连接层中,每个神经元都与上一层的所有神经元相连,以确保充分的信息传递和特征融合,这使得它能够充分利用网络中提取到的各类特征。全连接层的目标是通过对各特征的加权求和,得到最终的分类输出。

在分类任务中,特别是多类别分类任务,全连接层的输出通常通过 Softmax 函数进行标准化,使得每个输出值都表示某一类别的概率,且所有类别的概率之和为 1。Softmax 函数的数学表达式为:

$$h_{\theta}(x_i) = \begin{bmatrix} p(y_i = 1)|x_i; \theta \\ p(y_i = 2)|x_i; \theta \\ \dots \\ p(y_i = k)|x_i; \theta \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x_i}} \begin{bmatrix} e^{\theta_1^T x_i} \\ e^{\theta_2^T x_i} \\ \dots \\ e^{\theta_k^T x_i} \end{bmatrix} \quad (3.11)$$

其中, $p(y_i = k)$ 表示网络输出为类别 k 的概率; θ 为 Softmax 分类器的参数; x_i 是输入数据; $1/(\sum_{j=1}^k e^{\theta_j^T x_i})$ 表示输出的概率归一化。

在双通道卷积模块中,每个通道的池化输出首先通过一层独立的全连接层进行降维处理,输出维度统一设置为 512,用于提取通道内的深层语义特征。该操作保留了各通道的特征表达独立性,为后续信息融合提供了更具判别力的子特征表示。随后,两个通道的全连接输出通过 Add 操作进行元素级加权融合,生成统一的融合特征向量。该融合特征再输入第二个全连接层进行进一步压缩与映射,输出维度设置为 22,用于完成故障分类前的特征重构与语义整合。最终,融合后的特征向量送入 Softmax 分类器,输出节点数 22,对应 22 类典型开路故障类型,输出结果为一组归一化的概率分布。模型训练过程中采用交叉熵损失函数作为优化目标,通过最小化预测分布与真实标签之间的差异,引导网络参数的迭代更新,实现对多类别故障的精确识别。

3.4 本章小结

本章围绕 P2D-CNN 故障诊断模型的结构设计与关键模块实现进行了系统阐述。首先,从整体架构角度介绍了模型所采用的双通道并行输入结构,明确了其在提升图像特征利用效率与保留通道独立性方面的设计动机。模型通过引入特征级融合策略,有效整合了不同图像转换方法下提取的故障信息,增强了特征表示的鲁棒性与判别性。

随后,分别对输入层、卷积层、激活层、池化层、Dropout 层和全连接层等

核心结构模块进行了逐一分析，详细说明了各模块的参数配置、结构功能以及在整个网络中的协同作用。特别是在卷积结构深度控制、池化下采样与正则化机制设计方面，模型充分考虑了计算效率与表达能力之间的平衡关系。

综上，P2D-CNN 模型通过模块化结构实现了特征提取的层次化表达与结构间的有效衔接，兼顾了通道独立建模与信息融合的需求。各功能模块之间协同配合，在保持模型紧凑性的同时，增强了对图像特征的表征能力与结构稳定性，为模型整体性能的实现提供了坚实的架构支持。

第四章 基于 P2D-CNN 的逆变器故障诊断方法

4.1 引言

在完成 P2D-CNN 模型结构设计的基础上,为验证其在三相逆变器开路故障诊断中的有效性与适应性,本章围绕模型在不同输入特征、故障工况及干扰条件下的表现开展系统实验分析。依托 MATLAB/Simulink 平台所构建的三相逆变器故障仿真模型,采集输出端 A 相电压信号,并结合多种图像转换方法生成二维图像数据集,以评估所提模型对复杂非平稳电压信号的特征提取与模式识别能力。

本章将重点测试 P2D-CNN 模型在不同图像组合输入条件下的分类准确率,并进一步分析其在不同信噪比条件下的鲁棒性表现。同时,将所提模型与传统二维卷积神经网络(2D-CNN)进行对比,综合评估双通道融合结构在识别精度、抗干扰能力与特征表达效率等方面的性能优势。

4.2 数据集构成与组合策略

4.2.1 数据集构成

逆变器故障实验采用图 2.4 所示的三相逆变器模型,故障信号共涵盖 22 种标签类型,包括正常工作状态,单个 IGBT 故障、同桥臂两个 IGBT 故障、同相位两个 IGBT 故障和交叉桥臂两个 IGBT 故障^[64]。

在 MATLAB/Simulink 仿真模型中模拟了 22 种工作状态,获取不同工作状态下 A 相电压数据,并以每个工频周期(0.02s)为单位进行分割,确保周期内数据的完整性,随后其转化为对应的 STFT、GASF、GADF 和 MTF 图像。每种故障状态下采集的 A 相电压数据包含 200000 个数据点,按照每 2000 个数据点进行分段提取,每段数据作为一个样本,得到每种状态下 100 段样本。每段样本对应一张二维图像,因此每种工作状态可生成 100 张二维图像,22 种工作状态共生成 2200 张二维图像。接着将这 2200 张二维图像按照 7:1:2 的比例随机划分为训练集、验证集和测试集,以确保每个数据集的样本具有代表性和多样性。因此,每种一维时域信号转换为二维图像后,1540 张二维图像作为训练集、220 张二维图像作为验证集、440 张二维图像作为测试集。为了减少一维时序信号到二维图像的转换时长、减轻计算负担并提高网络训练的速度,所有转换后的二维图像分辨率统一设定为 $64 \times 64 \times 3$ 。

考虑到在实际工程环境中,传感器收集的信号数据常受噪声的影响,为验证本文方法的抗噪声干扰能力,在三相逆变器的输出电压信号中分别叠加了信噪比为 40dB、30dB、20dB、10dB 和-5dB 的高斯白噪声^[65]。其中,将信噪比为 40dB 噪声数据集作为基准数据集,其余噪声数据集用于对比分析。

为直观展示不同图像转换方法在表达故障特征方面的差异性,本文选取五种故障类型下的 A 相电压波形,并将其分别转换为 STFT、GASF、GADF 及 MTF 图像,以观察图像结构与信号变化间的映射关系。以下从四种图像生成方式出发,结合图示进行分析说明:

根据第二章介绍的 STFT 原理,该方法具有良好的时频局部化能力,能够同时揭示信号在时间和频率两个维度上的变化规律。当故障信号变化缓慢时,STFT 图像中的频谱分布相对平滑;而信号发生突变时,图中某些频段会出现明显的能量聚集。其主要优势包括:(1)能有效捕捉非平稳信号的局部动态特征;(2)通过选择合适窗函数平衡时间与频率分辨率;(3)频谱能量分布清晰,有助于后续模型的特征提取与判别学习。图 4.1 展示了五种故障状态下的 A 相电压波形及其对应的 STFT 图像。




图 4.1 不同故障类型时 A 相电压波形及其对应的 STFT 图像

根据第二章对 GAF 原理的介绍,GAF 图像以时间序列的角度信息构建矩阵结构,使序列的变化趋势沿主对角线展开,并以颜色梯度表示不同时间段的状态关系。根据计算方式不同,GAF 可进一步分为 GASF 与 GADF:前者通过角度余弦关系反映信号的全局变化趋势,后者通过角度差值描述局部变化幅度。图 4.2

与图 4.3 分别展示了五种故障状态下 A 相电压波形对应的 GASF 与 GADF 图像。从中可以观察到，不同故障状态下图像结构显著不同，呈现出良好的可分性。




图 4.2 不同故障类型时 A 相电压波形及其对应的 GASF 图像




图 4.3 不同故障类型时 A 相电压波形及其对应的 GADF 图

根据第二章介绍的 MTF 原理，MTF 通过计算时间序列中不同状态的转移概率，构建出二维图像，其图像关于副对角线对称，能够有效保留时序数据在不同时间步长间的相关性。在故障信号的变化较为缓慢的情况下，MTF 图像中会出现颜色相似的大面积连通区域，而当信号振幅短时间内发生剧烈变化时，则会出现水平或垂直线。MTF 具有以下优点：(1)能够捕捉不同步长间的状态转移关系，保持原始信号的时序依赖性；(2)通过将一维信号映射至二维空间，提高特征表达

能力，减少信息损失；(3)通过颜色梯度展现状态转移的概率分布表，为 CNN 进行特征学习和分布提供有利条件。图 4.4 展示了五种故障状态下的 A 相电压波形及其对应的 MTF 图像。




图 4.4 不同故障类型时 A 相电压波形及其对应的 MTF 图

4.2.2 数据集组合策略

不同图像转换方法在特征表达上具有一定的互补性。例如，STFT 能清晰反映信号的频率分布与局部变化，而 GASF、GADF 更强调时间序列整体趋势与相对变化关系，MTF 则侧重于时序状态之间的转移结构。单一图像形式往往难以同时兼顾信号的时频信息、趋势结构与序列依赖性，导致模型训练过程中特征利用不充分，限制了分类性能的进一步提升。

为充分挖掘不同图像特征间的互补关系，本文在 P2D-CNN 模型结构基础上引入双通道图像输入机制，将两种不同类型的图像分别输入至并行卷积分支，实现特征的独立建模与融合学习。该策略不仅能够提升模型的特征提取多样性，还增强了对复杂故障模式的判别能力，同时在保持网络结构紧凑的前提下，提升了模型的分类性能与鲁棒性。

选择合适的图像组合方式对于提升故障诊断效果具有重要意义。STFT、GASF、GADF 和 MTF 四种转换方法分别从时频域分布、时序结构和状态转移关系等不同角度对电压信号进行建模，合理组合能够增强输入数据的表达多样性，并提升模型对不同特征维度的学习能力。本文分别对六组组合方式进行了设计与实验评估，其优势可总结如下：

STFT-GASF: STFT 提取信号的频域特征, GASF 捕捉时间序列的正向变化趋势, 二者结合可同时反映时频特性与序列结构, 提升对动态变化的识别能力;

STFT-GADF: 结合 STFT 的频谱分布与 GADF 的反向趋势信息, 能更好地揭示故障过程中的趋势反转特征;

STFT-MTF: 将 STFT 的局部频率特征与 MTF 的时序状态转移结构结合, 有助于提升对复杂故障演化模式的适应能力;

GASF-GADF: 分别代表时间序列的正向与反向演化特性, 结合后可实现双向时序特征建模;

GASF-MTF: GASF 表征全局趋势, MTF 补充时域状态变化, 融合后兼顾整体趋势与局部动态;

GADF-MTF: 聚焦于信号的反向动态和状态转移特性, 适用于复杂工况下的细粒度故障判别。

上述组合均在统一的图像输入尺寸、样本划分与训练参数设置下进行实验, 确保结果具备公平性与可比性。通过图像融合策略的设计与组合性能的比较分析, 可为后续特征输入方案优化与模型结构改进提供依据。

4.3 故障诊断过程与性能分析

4.3.1 故障诊断过程

P2D-CNN 模型在三相逆变器开路故障诊断中的应用流程包括实验平台的搭建、训练参数的设定, 以及多种图像组合方式下的模型训练与性能测试。该过程为后续的分类效果评估与对比分析提供了基础支撑。

模型训练与实现在 MATLAB R2023a 环境下完成, 运行平台为 Windows 10 操作系统, 处理器为 Intel Evo i5, 内存容量为 16GB。实验过程依托 MATLAB 中的 Deep Learning Toolbox 与 Image Processing Toolbox 完成图像数据加载、网络结构构建、模型训练与性能评估等关键操作。

模型训练参数设置与模型结构设计阶段保持一致。图像输入尺寸统一设为 $64 \times 64 \times 3$, 优化器采用 Adam, 初始学习率设为 0.01, 批次大小 (Batch Size) 为 128, 训练轮数设为 100, 损失函数为交叉熵损失函数 (Cross-Entropy Loss)。训练过程中以验证集准确率为性能指标, 采用早停机制, 自动保存在验证集上表现最优的网络权重。

为提升故障诊断的准确性与鲁棒性, P2D-CNN 模型在多个不同图像数据集

组合下进行训练。每次训练任务中，从第 4.2.2 节介绍的六种数据集组合中选择一种，并将生成的二维图像作为双通道输入送入 P2D-CNN 模型中进行特征提取与分类训练。整个模型的故障诊断过程如图 4.5 所示，体现了图像转换、组合输入、特征融合与分类输出的完整流程。




图 4.5 P2D-CNN 的逆变器故障诊断过程

整个故障诊断过程大致包括以下四个环节：首先，基 MATLAB/Simulink 平台构建三相逆变器仿真电路，并注入多类开路故障以模拟真实工况；其次，从逆变器输出端采集典型电压信号，并进行周期截取与标准化处理；随后采用 STFT、GASF、GADF 和 MTF 等图像转换方法，将一维时域信号转换为二维图像表示；接着，将组合后的双通道图像输入至 P2D-CNN 模型进行训练与特征学习，并在测试集上输出分类结果，实现对各类故障状态的准确识别与自动判别。

4.3.2 模型训练结果与性能评估

在完成 P2D-CNN 模型的训练后，进行多组图像组合方式下的故障诊断性能评估，通过对测试集的分类实验，统计并分析模型的准确率与混淆矩阵等关键指标。每组实验都采用相同的网络结构、训练参数和图像输入尺寸，确保结果具有可比性与一致性。

4.3.2.1 STFT 与 GAF 数据集的训练结果

首先，使用第三章中设计的 P2D-CNN 结构对 STFT-GASF 数据集进行训练，设置训练迭代次数为 100，并记录训练集与验证集的准确率与损失率变化曲线。为验证模型的有效性，进行了 10 次重复训练，最终得到了 STFT-GASF 数据集的

训练准确率曲线与损失率曲线，如图 4.6 所示。

从图中可以看出，P2D-CNN 模型在 STFT-GASF 数据集上的训练过程稳定，准确率在 100 次迭代后保持较高水平，损失值迅速下降并趋于平稳。验证集的准确率在 65 次迭代后趋于稳定，并最终达到较高水平，损失值同步下降并保持较低水平。训练集与验证集的准确率曲线在后期接近，未出现明显的过拟合现象。如图 4.7 展示了该数据集的混淆矩阵，测试准确率为 95.68%，大多数类别的预测结果与真实标签高度一致，表明模型在该数据集上的分类效果良好。




图 4.6 STFT-GASF 准确率和损失率曲线




图 4.7 STFT 与 GASF 数据集的混淆矩阵

在保持网络参数不变的情况下，对 STFT-GADF 数据集进行训练，并记录训练过程中的准确率与损失率曲线，训练结果如图 4.8 所示。

基于 STFT-GADF 数据集的 P2D-CNN 模型训练过程稳定，准确率在 100 次迭代后保持较高水平，损失值迅速下降并趋于平稳。验证集的准确率在 65 次迭代后趋于稳定，并最终达到较高水平，损失值同步下降并保持较低水平。训练集与验证集的准确率曲线在后期接近，未出现明显的过拟合现象。图 4.9 展示了该数据集的混淆矩阵，测试准确率为 95.91%，大多数类别的预测结果与真实标签

高度一致，说明模型在该数据集上的分类效果良好。




图 4.8 STFT-GADF 准确率和损失率曲线




图 4.9 STFT 与 GADF 数据集的混淆矩阵

4.3.2.2 STFT-MTF 数据集的训练结果

在保持网络参数不变的情况下，对 STFT-MTF 数据集进行训练，并在训练过程中记录模型的准确率与损失率曲线，如图 4.10 所示。




图 4.10 STFT-MTF 准确率和损失率曲线

从图中可以看出，基于 STFT-MTF 数据集的 P2D-CNN 模型训练过程稳定，

准确率在 100 次迭代后维持在较高水平，损失值快速下降并趋于平稳。验证集的准确率在 65 次迭代后趋于稳定，并最终达到较高水平，损失值同步下降并保持较低水平。训练集与验证集的准确率曲线在后期接近，未出现明显的过拟合现象。混淆矩阵图 4.11 显示，测试准确率为 95.23%，大多数类别的预测结果与真实标签高度一致，模型在该数据集上的分类效果良好。




图 4.11 STFT-MTF 数据集的混淆矩阵

4.3.2.3 MTF-GAF 数据集的训练结果

在保持网络参数不变的情况下，对 GASF-MTF 数据集进行训练，并在训练过程中记录模型的准确率与损失率曲线,结果如图 4.12 所示。




图 4.12 GASF-MTF 准确率和损失率曲线

从图中可以看出，基于 GASF-MTF 数据集的 P2D-CNN 模型训练过程稳定，准确率在 100 次迭代后保持在较高水平，损失值迅速下降并趋于平稳。验证集的准确率在 65 次迭代后趋于稳定，并最终达到较高水平，损失值同步下降并保持较低水平。训练集与验证集的准确率曲线在后期接近，未出现明显的过拟合现象。

混淆矩阵图 4.13 显示，测试准确率为 95.45%，大多数类别的预测结果与真实标签高度一致，模型在该数据集上的分类效果良好。




图 4.13 GASF-MTF 数据集的混淆矩阵

在保持网络参数不变的情况下，对 GADF-MTF 数据集进行训练，并在训练过程中记录模型的准确率与损失率曲线，结果如图 4.14 所示。




图 4.14 GADF-MTF 准确率和损失率曲线




图 4.15 GADF-MTF 数据集的混淆矩阵

从图中可以看出，基于 GADF-MTF 数据集的 P2D-CNN 模型训练过程稳定，准确率在 100 次迭代后维持在较高水平，损失值迅速下降并趋于平稳。验证集准确率在 65 次迭代后趋于稳定，并最终达到较高水平，损失值同步下降并保持较低水平。训练集与验证集的准确率曲线在后期接近，整体趋势一致，未出现明显

的过拟合现象。

混淆矩阵图 4.15 显示，测试准确率为 95%，大多数类别的预测结果与真实标签高度一致，模型在该数据集上的分类效果较好。

4.3.2.4 GASF-GADF 数据集的训练结果

在保持网络参数不变的情况下，对 GASF-GADF 数据集进行训练，并在训练过程中记录模型的准确率与损失率曲线，结果如图 4.16 所示。

从图中可以看出，基于 GASF-GADF 数据集的 P2D-CNN 模型训练过程中收敛稳定，准确率在 100 次迭代后保持在较高水平，损失值在初期迅速下降，并在 50 次迭代后趋于平稳。验证集的准确率在前期存在波动，但在 65 次迭代后逐渐稳定，并最终达到较高水平，同时损失值持续下降并保持较低水平。训练集与验证集的准确率曲线在后期接近，整体趋势一致，未出现明显的过拟合现象。




图 4.16 GASF-GADF 准确率和损失率曲线

混淆矩阵图 4.17 显示，测试准确率达到 95.68%，大多数类别的预测结果与真实标签高度一致。




图 4.17 GADF-GASF 数据集的混淆矩阵

4.4 模型鲁棒性分析与对比实验

在实际应用中，传感器采集的信号通常会受到环境噪声的影响，这使得故障诊断面临不同信噪比条件下的挑战。为验证 P2D-CNN 模型的鲁棒性，本实验设置了五种典型的信噪比水平，代表了电力电子设备在不同工业环境中的噪声干扰情况。

具体而言，40dB 与 30dB 的信噪比反映了理想的实验室环境或受控测试条件，噪声干扰较低；20dB 对应了工业现场常见的中等电磁干扰背景；10dB 模拟了传感器稳定性下降或电磁干扰增强等复杂现场环境；而-5dB 则代表了设备老化、线路故障或数据采集系统异常等极端恶劣的条件，此时信号功率低于噪声功率，是故障诊断任务中的最具挑战性场景。该信噪比设置覆盖了从理想至极端的典型工况，能够全面评估 P2D-CNN 模型在复杂环境下的适应能力与稳定性。

4.4.1 不同信噪比下的实验结果

为了检验本研究方法在抵抗噪声方面的有效性，对不同信噪比的数据集进行实验，并采用与上文信噪比 40dB 的噪声数据集相一致的训练模型和参数进行训练。不同信噪比的计算过程如下：信噪比（SNR）定义为信号功率与噪声功率之间的对数形式。

$$SNR = 10 \log_{10} \left(\frac{P_{signal}}{P_{noise}} \right) \quad (4.1)$$

其中， P_{signal} 是信号的功率， P_{noise} 是噪声的功率。通过调整噪声功率，可以得到不同的信噪比值。将不同信噪比数据集的诊断结果进行对比，结果如图 4.18 所示，展示了不同信噪比下数据集的识别准确率情况。




图 4.18 不同信噪比数据集的准确率对比

由图 4.18 可知,在信噪比为 40dB-20dB 的情况下,STFT-GADF、STFT-GASF、STFT-MTF、GADF-GASF、GADF-MTF 和 GASF-MTF 六种方法的识别准确率相对稳定,均保持在 93%以上,波动范围较小,表明这些方法在低噪声环境下具有较强的鲁棒性。然而,当信噪比降低至 10dB 时,部分方法的识别准确率出现不同程度的下降,尤其在 -5dB 的高噪声环境下,STFT-GASF、STFT-MTF 和 GASF-MTF 的准确率下降较为显著,分别降至 73.86%、77.27%和 79.09%。相比之下,STFT-GADF、GADF-MTF 和 GADF-GASF 在 -5dB 条件下的准确率仍保持在 80%以上,其中 STFT-GADF 的识别准确率最高,为 85.91%。

4.4.2 模型对比分析

为验证本文所提 P2D-CNN 模型的优势,选取 2D-CNN 模型进行对比实验分析,包括:STFT-2D-CNN 模型、GASF-2D-CNN 模型、GADF-2D-CNN 模型和 MTF-2D-CNN 模型。通过对比这些模型诊断准确率和诊断对比时间,可以更全面地评估本文所提 P2D-CNN 模型的性能优势。实验结果对比如图 4.19 所示:

由图 4.19 中数据可知,单输入方法中,GADF 的准确率最高,为 94.55%,但识别时间最长。GASF、MTF 和 STFT 的准确率分别为 93.18%、93.86%和 93.64%,识别时间均在 43.54s 至 44.07s 之间。相比之下,并行双输入方法 STFT-GADF 的准确率达到 95.91%,较单输入方法提升了至少 1.36%,但识别时间增加至 76.02s。

综上所述,本文所提 P2D-CNN 模型在保持较高诊断准确率的同时,虽然识别时间略有增加,但相较于传统单输入 2D-CNN 模型,准确率提升显著,最高提升达 1.36%,充分验证了其在三相逆变器故障诊断任务中性能更优、诊断更可靠的优势。




图 4.19 实验结果对比

4.5 本章小结

本章研究了 P2D-CNN 模型在三相逆变器开路故障诊断任务中的表现，并通过实验验证了该模型在不同信噪比条件下的鲁棒性。同时，本文还将 P2D-CNN 与传统的 2D-CNN 进行了对比，分析了其在分类准确、计算效率的优势。

实验结果表明，P2D-CNN 模型在低信噪比 ($SNR \leq 10dB$) 环境下仍能保持较高的准确率，表现出较强的噪声抑制能力，验证了模型在复杂工业环境中的适应性。与 2D-CNN 相比，P2D-CNN 不仅在训练过程中收敛速度更快，分类准确率更高，还在噪声干扰和复杂工况下展现了更好的鲁棒性。

第五章 基于 P2D-CNN-CBAM 的逆变器故障诊断方法

5.1 引言

在故障诊断任务中,深度学习模型分类性能依赖于其特征提取能力。P2D-CNN 能够有效利用二维图像的时频特征进行故障识别,但仍存在对关键特征关注不足的问题,特别是在低信噪比环境下,特征提取易受到噪声干扰,导致分类精度下降。针对这一问题,本章在 P2D-CNN 的基础上引入注意力机制,提出了 P2D-CNN-CBAM 模型。

注意力机制通过自适应地增强重要特征并抑制无关信息,提高模型对故障特征的聚焦能力,从而增强复杂环境下的特征表达能力和分类鲁棒性。本章采用 CBAM 注意力机制,该模块结合通道注意力和空间注意力,对输入特征进行双重优化,以提升模型在复杂环境下的鲁棒性和故障分类性能。为验证该模型的有效性,本文基于不同信噪比的 STFT-GADF 数据集,分别对 P2D-CNN 和 P2D-CNN-CBAM 模型的故障诊断能力进行对比实验,并分析注意力机制的作用。本章的研究旨在优化 P2D-CNN 模型的特征提取能力,提高其在噪声环境中的诊断精度,为逆变器故障检测提供更加可靠的解决方案。

5.2 P2D-CNN-CBAM 模型结构设计

在第三章所构建的 P2D-CNN 模型中,双通道结构能够有效融合多种图像转换方式所提取的二维特征,并在一定程度上提升了逆变器开路故障的分类准确率。然而,该模型在特征提取过程中对各区域与通道信息的处理是均等的,难以区分重要与冗余特征,尤其在故障信号较为微弱或受噪声干扰较严重的情况下,模型对关键特征的关注能力有限,影响了最终的诊断效果。

为了进一步增强模型的特征选择能力与表达能力,在 P2D-CNN 的基础上引入卷积注意力模块(Convolutional Block Attention Module, CBAM),构建融合注意力机制的双通道并行二维卷积神经网络混合模型 P2D-CNN-CBAM。该模型在双通道并行卷积路径中嵌入 CBAM 模块,通过引导网络自动聚焦于高价值特征区域与通道,强化对微弱故障模式的响应,提升模型在复杂工况下的分类鲁棒性。

如图 5.1 所示, P2D-CNN-CBAM 模型整体结构依然采用双通道输入方式,分别接收两种图像转换方法生成的二维图像。每个通道由输入层、卷积层、激活

层、池化层和 Dropout 层构成基础特征提取路径，在池化后引入 CBAM 模块。特征提取完成后，各通道输出的特征图经展平（Flatten）处理后，通过 Addition 操作进行融合，并依次输入至融合前的全连接层（FC-512）、融合后的全连接层（FC-22），最终通过 Softmax 分类器输出 22 类故障类别的概率分布。




图 5.1 P2D-CNN-CBAM 网络的整体架构

相较于第三章中的 P2D-CNN 模型，本结构的主要优化在于将 CBAM 模块嵌入卷积路径内部，能够动态调整特征通道与空间响应的权重，提升模型对不同图像组合中关键特征的选择能力。该结构在保持计算复杂度可控的同时，有效提高了模型对故障模式的区分能力和抗干扰能力。

P2D-CNN-CBAM 模型在设计上不仅保持了原 P2D-CNN 的多模态特征融合优势，还通过引入轻量化注意力机制，实现了特征提取阶段的信息压缩与增强。该结构为后续的注意力机制模块分析与实验验证奠定了基础。

5.3 CBAM 注意力机制原理与融合策略

P2D-CNN-CBAM 模型在 P2D-CNN 双通道结构的基础上引入了注意力机制，以提升模型对故障区域和判别特征的感知能力。考虑到逆变器开路故障的特征在图像中往往表现为局部微弱扰动，且存在噪声干扰、特征分布稀疏等问题，传统的等权卷积操作容易在提取过程中淹没这些关键特征。因此，为了增强模型的特征聚焦能力，本文在每个卷积分支的池化层之后嵌入了 CBAM 模块，使模型在通道和空间两个维度上对特征进行有针对性的权重调整。

CBAM 模块由通道注意力机制（Channel Attention）和空间注意力机制（Spatial Attention）两部分顺序组成，分别对应模型中特征图的信息维度重要性建模与空间区域选择性强化。在 P2D-CNN-CBAM 模型中，CBAM 被插入至每个通道的卷积+池化操作后，Flatten 展平前。此时特征图已完成局部模式提取，具备一定语义表达，但仍包含大量冗余与非判别性区域。通过 CBAM 的动态加权机制，网络能够自适应地提升对具有判别性特征通道和显著空间区域的响应，从而在后续的特征融合与分类过程中生成更加清晰且具区分度的表征信息。

（1）通道注意力机制

在双通道卷积路径中，每一路的卷积层输出包含多个通道维度的特征图，各通道分别编码了输入图像在不同感受域下的响应特征。然而，在逆变器故障图像中，并非所有通道特征都具有相同的重要性，部分通道可能仅包含边缘信息或背景噪声。本文采用通道注意力机制对各通道的重要性进行建模与加权，从而突出具有判别价值的特征响应。

具体实现方式为：对输入特征图 $F \in R^{H \times W \times C}$ 经过全局平均池化（Global Average Pooling, GAP）和全局最大池化（Global Max Pooling, GMP）的处理，分别获得到了两个通道的描述符 z_{avg} 和 z_{max} 。随后，将这两个通道描述符分别输入共享的全连接层和激活函数，生成通道权重 M_c ：

$$M_c(F) = \sigma \left(W_1 \left(W_0(z_{avg}) \right) + W_1 \left(W_0(z_{max}) \right) \right) \quad (5.1)$$

其中， W_0 和 W_1 为全连接层的权重矩阵。

在 P2D-CNN-CBAM 模型中，该模块位于池化层之后，确保输入特征已具备初步结构性表达，通道注意力模块可据此学习哪些特征模式在诊断任务中具有高权重，例如某类故障频带、波形变形纹理等。

（2）空间注意力机制

通道加权完成后，仍需进一步关注图像中“哪些区域”最具判别价值，尤其是

在故障信号幅度较弱、局部扰动较小的条件下，直接学习空间显著区域对于特征定位尤为关键。空间注意力机制正是通过压缩通道信息，引导模型聚焦于图像中的关键空间区域。

具体做法为：针对通道注意力模块输出的特征图 F ，沿通道维度分别执行全局平均池化和全局最大池化，得到两个特征图 $z_{avg} \in R^{H \times W \times 1}$ 和 $z_{max} \in R^{H \times W \times 1}$ 。将两者拼接并通过卷积层生成空间权重 M_s ，其计算公式为：

$$M_s(F) = \sigma \left(f^{7 \times 7}([z_{avg}; z_{max}]) \right) \quad (5.2)$$

其中， $f^{7 \times 7}$ 表示核大小为 7×7 的卷积操作。

在 P2D-CNN-CBAM 中，该模块紧接通道注意力模块之后。注意力图的输出可强化局部扰动显著的区域，如波形突变点、异常振幅区段等，从而提升模型对微小故障区域的响应能力。

（3）模块嵌入与融合策略

CBAM 模块的整体输出由通道注意力与空间注意力顺序组合完成，计算过程如下：

$$F' = M_s(M_c(F) \cdot F)(M_c(F) \cdot F) \quad (5.3)$$

在 P2D-CNN-CBAM 模型中，每个卷积分支在“池化层→CBAM→Flatten”之间嵌入一个完整的 CBAM 模块，使其在特征展平前完成重要区域与维度的增强操作。由于该模块轻量、参数少，在不显著增加计算开销的前提下，实现了高质量的特征选择与抑制，为双通道特征融合提供了更具判别力的特征基础。CBAM 的引入不仅提升了模型对图像中关键信息的聚焦能力，也增强了整体网络在不同工况、不同图像组合下的适应性与鲁棒性。

5.4 P2D-CNN 与 P2D-CNN-CBAM 模型对比分析

为全面评估 P2D-CNN-CBAM 模型在逆变器开路故障诊断任务中的性能表现，本文选取五种不同信噪比条件下的 STFT-GADF 数据集进行实验，并与前文提出的 P2D-CNN 模型进行分类准确率与计算开销的对比分析。训练流程与参数配置与前述模型保持一致，以确保实验的科学性与可重复性。实验结果如表 5.1 所示。

实验结果表明，在不同信噪比水平下，P2D-CNN-CBAM 的分类准确率均高于 P2D-CNN，尤其是在较低信噪，比如 10dB 和 -5dB 情况下，优势更加明显。在 40dB、30dB 和 20dB 的高信噪比条件下，P2D-CNN-CBAM 的准确率相较于

P2D-CNN 均提升了约 0.23%，但在 10dB 和 -5dB 的低信噪比环境下，P2D-CNN-CBAM 的提升幅度更为显著，分别提高了 1.13% 和 5.23%，显著增强了模型的抗噪声性能。

表 5.1 不同信噪比下分类准确率及时间对比

模型	信噪比 (SNR)	40db	30db	20db	10db	-5db
P2D-CNN	准确率 (%)	95.91	95.68	95	93.64	85.91
	时间 (s)	77.14	77.47	76.16	77.05	77.35
P2D-CNN-CBAM	准确率 (%)	96.14	95.91	95.23	94.77	91.14
	时间 (s)	92.73	91.56	93.03	93.13	92.76

该结果充分验证了 CBAM 注意力模块在复杂环境中的有效性。通过引入通道注意力与空间注意力机制，模型能够更有效地聚焦于关键特征区域，抑制非判别性干扰信息，从而提升特征表达的鲁棒性和区分度。此外，虽然 P2D-CNN-CBAM 模型在测试时间方面略高于 P2D-CNN，平均增加约 15 秒，但在保障诊断精度的前提下，该计算开销是可以接受的。

尽管 CBAM 模块的引入在一定程度上增加了模型的计算复杂度，但其所带来的准确率提升，尤其是在低信噪比环境下的显著性能增强，使其具备更高的应用价值。综合考虑诊断精度、环境适应性与模型鲁棒性，P2D-CNN-CBAM 模型在电力电子系统、新能源装备及复杂工业控制等对故障识别精度与可靠性要求较高的场景中，展现出更强的工程适应性与推广潜力。

5.5 本章小结

本章在 P2D-CNN 模型的基础上，引入卷积块注意力机制 (CBAM)，构建了具备自适应特征关注能力的 P2D-CNN-CBAM 模型，进一步提升了模型对关键故障特征的响应能力与复杂环境下的鲁棒性。通过对 CBAM 中通道注意力与空间注意力模块的结构设计与作用机制进行解析，明确了其在提升特征选择性与抑制无效信息方面的优势。

实验部分以 STFT-GADF 图像组合为基础，选取多个典型信噪比场景，对 P2D-CNN 与 P2D-CNN-CBAM 模型在分类准确率与计算时间方面进行对比。结果表明，P2D-CNN-CBAM 在高信噪比条件下保持稳定优势，在低信噪比条件下表现出更为显著的识别精度提升，充分验证了注意力机制在复杂工况下的应用价

值。

P2D-CNN-CBAM 模型在结构保持轻量的前提下，实现了故障诊断精度和抗干扰能力的双重提升。实验结果表明，该模型在不同信噪比条件下均具备较强的稳定性与鲁棒性，尤其适用于电力电子系统、新能源装备及复杂工业场景等对识别精度与可靠性要求较高的应用环境，体现出良好的工程实用性与推广潜力。

第六章 总结与展望

6.1 全文总结

本文围绕三相逆变器故障诊断展开研究，构建了故障数据集，并采用多种信号转换方法提取故障特征，以提升诊断精度和特征表达能力。在此基础上，提出了一种并行二维卷积神经网络（P2D-CNN），通过双通道结构融合不同特征，提高故障分类的准确性和泛化能力。此外，为进一步优化特征提取能力，引入注意力机制（CBAM），增强模型对关键故障特征的關注，提高其抗噪性和鲁棒性。

实验通过不同信噪比条件下的分类性能对比，验证了所提出模型的有效性，结果表明 P2D-CNN-CBAM 在低信噪比环境下仍保持较高的故障识别能力。同时，分析不同信号转换方法组合对模型性能的影响，发现 STFT-GADF 组合能够提供更优的时频特征表达能力，进一步提升故障诊断的准确率。

本文的创新性成果主要包括：

- (1) 提出了双通道并行卷积的 P2D-CNN 模型架构，通过特征提取分支分别处理不同转换方法生成的二维图像，在融合层实现特征整合，避免了单通道网络的特征提取不足，提高了对不同类型故障的识别能力
- (2) 引入 CBAM 注意力机制，构建了 P2D-CNN-CBAM 混合模型，通过通道注意力模块计算特征通道权重，空间注意力模块定位关键特征区域，使模型能更精准地聚焦于故障相关特征。
- (3) 采用 STFT-GADF 联合将时频特征与角度差分特征相结合，通过二维图像转换技术，有效克服了传统一维信号和单一特征表达能力不足的局限性。

6.2 后续展望

本文提出的基于 P2D-CNN 和 P2D-CNN-CBAM 的逆变器故障诊断方法尽管在实验中表现出较高的分类准确率和良好的抗噪声能力，但在实际应用和进一步优化方面仍然存在一些问题和挑战。未来研究可以从以下几个方面进行优化和拓展，以提升逆变器故障诊断方法的适用性和工程实用价值：

- (1) 扩展故障类型识别：当前研究主要针对开路故障，未来应涵盖短路故障、器件老化及绝缘损坏等复杂故障，增强模型对多种故障的识别能力，并实现隐性

故障的早期预警。

(2) 优化模型计算效率：为降低计算复杂度并适应资源受限环境，可引入轻量级神经网络结构和在线学习机制，以提高诊断的实时性和部署灵活性。

(3) 融合多源数据提升泛化能力：结合电流、电压、温度、振动等多模态数据，利用工业物联网技术，实现更全面的故障分析，提高模型在不同工况下的适应性和准确性。

综上所述，未来研究可围绕复杂故障类型扩展、计算优化、多源数据融合等方面展开，以提升逆变器故障诊断方法的智能化水平和实际应用价值，为电力电子系统的安全稳定运行提供更可靠的技术支持。

参考文献

- [1] 张靖超, 毕贵红, 赵四洪, 等. 基于多模态融合和卷积神经网络的逆变器故障诊断[J]. 电力科学与工程, 2024, 40(3): 34-43.
- [2] 宋保业, 鲁朋, 许琳. 基于深度自编码器网络的逆变器开关管开路故障诊断[J]. 山东科技大学学报 (自然科学版), 2023, 42(6).
- [3] 绍云孙. 光伏发电系统的常见故障及其检测方法[J]. 水电科技, 2024, 7(2): 90-92.
- [4] Fallah F, Ramezani A, Mehrizi-Sani A. Integrated fault diagnosis and control design for DER inverters using machine learning methods[C]//2022 IEEE Power & Energy Society General Meeting (PESGM). IEEE, 2022: 1-5.
- [5] Aviña-Corral V, de Jesus Rangel-Magdaleno J, Barron-Zambrano J H, et al. Review of fault detection techniques in power converters: Fault analysis and diagnostic methodologies[J]. Measurement, 2024: 114864.
- [6] Jia X. Fault diagnosis method of soft-switching inverter based on deep learning[C]//Fourth International Conference on Computer Vision, Application, and Algorithm (CVAA 2024). SPIE, 2025, 13486: 282-287.
- [7] Alrifaeey M, Lim W H, Ang C K, et al. Hybrid deep learning model for fault detection and classification of grid-connected photovoltaic system[J]. IEEE Access, 2022, 10: 13852-13869.
- [8] Gonzalez-Jimenez D, del-Olmo J, Poza J, et al. Machine learning-based fault detection and diagnosis of faulty power connections of induction machines[J]. Energies, 2021, 14(16): 4886.
- [9] Sivapriya A, Kalaiarasi N. A novel enhanced deep learning-based fault diagnosis approach for cascaded multilevel inverter[J]. e-Prime-Advances in Electrical Engineering, Electronics and Energy, 2023, 5: 100253.
- [10] García-Pérez D, Saeed M, Díaz I, et al. Machine Learning for Inverter-Fed Motors Monitoring and Fault Detection: An Overview[J]. IEEE Access, 2024, 12: 27167-27179.
- [11] Estima O J, Cardoso M J A. A New Algorithm for Real-Time Multiple Open-Circuit Fault Diagnosis in Voltage-Fed PWM Motor Drives by the Reference

- Current Errors[J].IEEE Trans. Industrial Electronics,2013,60(8):3496-3505.
- [12]Khomfoi S , Tolbert M L .Fault Diagnostic System for a Multilevel Inverter Using a Neural Network[J].IEEE Transactions on Power Electronics, 2007, 22(3):1062-1068.
- [13]Patil V J, Khadake S B, Tamboli D A, et al. Review of AI in power electronics and drive systems[C]//2024 3rd International conference on Power Electronics and IoT Applications in Renewable Energy and its Control (PARC). IEEE, 2024: 94-99.
- [14]陈诗灿, 林琼斌, 陈四雄, 等. 电力电子变流器故障诊断的智能方法综述[J]. 电气技术, 2019, 20(3): 6-12.
- [15]田广强,乔珊珊,侯奥,等.基于快速傅里叶变换和改进 T-S 模糊神经网络集成模型的逆变器开路故障诊断方法研究[J].电力科学与技术学报,2023,38(06):76-86.DOI:10.19781/j.issn.1673-9140.2023.06.008.
- [16]Yang H, Peng Z, Xu Q, et al. Inverter fault diagnosis based on fourier transform and evolutionary neural network[J]. Frontiers in Energy Research, 2023, 10: 1090209.
- [17]任志玲,王兴隆.基于同步挤压小波变换的并网逆变器故障自诊断方法[J].辽宁工程技术大学学报(自然科学版),2023,42(03):345-353.
- [18]时维国,吴宁.基于小波包变换和 SVM 的三电平逆变器故障诊断[J].电机与控制应用,2021,48(02):91-95+100.
- [19]任晓红,万红,俞啸,等.基于 Park 变换的三电平逆变器开路故障诊断[J].工矿自动化,2020,46(05):82-86+93.DOI:10.13272/j.issn.1671-251x.17523.
- [20]Chen C, Chen Y, Yang X, et al. Inverter fault detection method based on park transformation and k-means clustering algorithm[C]//2021 CAA Symposium on Fault Detection, Supervision, and Safety for Technical Processes (SAFEPROCESS). IEEE, 2021: 1-6.
- [21]林茂,李颖晖,朱喜华,等.基于改进核主元分析法的三电平逆变器故障检测[J]. 电 网 技 术 ,2016,40(03):972-977.DOI:10.13335/j.1000-3673.pst.2016.03.045.
- [22]Kordestani M, Samadi M F, Saif M, et al. A new fault diagnosis of multifunctional spoiler system using integrated artificial neural network and

- discrete wavelet transform methods[J]. IEEE Sensors Journal, 2018, 18(12): 4990-5001.
- [23] Park B ,Jang J ,Kim T , et al.EKF-Based Fault Diagnosis for Open-Phase Faults of PMSM Drives[C]//China Electrotechnical society,IEEE Power Electronics Society, National Science Foundation of China.2009 IEEE 6~(th) International Power Electronics and Motion Control Conference-ECCE Asia Conference Digests.Department of Electrical Engineering, Hanyang University;Battery System R&D Research Park, LG Chem, Ltd.,;2009:5.
- [24] Nademi H, Das A, Norum L E. Modular multilevel converter with an adaptive observer of capacitor voltages[J]. IEEE Transactions on Power Electronics, 2014, 30(1): 235-248.
- [25] Jian L ,Xinxin G ,Bo L .Robust Fault Diagnosis and Adaptive Parameter Identification for Single Phase Transformerless Inverters[J].Mathematical Problems in Engineering,2018,20181-11.
- [26] Sánchez P A J , Campos-Delgado U D , Espinoza-Trejo R D , et al.Fault diagnosis in grid-connected PV NPC inverters by a model-based and data processing combined approach[J].IET Power Electronics, 2019, 12(12):3254-3264.
- [27] 许水清,黄文展,何怡刚,等.基于自适应滑模观测器的中点钳位型三电平并网逆变器开路故障诊断 [J]. 电工技术学报 ,2023,38(04):1010-1022.DOI:10.19595/j.cnki.1000-6753.tces.220423.
- [28] 陈超波,王霞霞,高嵩,等.基于区间滑模观测器的逆变器开路故障诊断方法 [J].中国电机工程学报,2020,40(14):4569-4579+4736.DOI:10.13334/j.0258-8013.pcsee.190886.
- [29] Zhan L , Hao M , Zhihong B , et al.Fast Transistor Open-Circuit Faults Diagnosis in Grid-Tied Three-Phase VSIs Based on Average Bridge Arm Pole-to-Pole Voltages and Error-Adaptive Thresholds[J].IEEE Transactions on Power Electronics, 2018, 33(9):8040-8051.
- [30] Yin H , Chen Y , Chen Z .Observer-based adaptive threshold diagnosis method for open-switch faults of voltage source inverters[J].Journal of Power Electronics, 2020, 20(6):1-10.

- [31] 韩钰.基于联合优化回声状态网络的三电平逆变器故障诊断[D].合肥工业大学,2021.DOI:10.27101/d.cnki.ghfgu.2021.001711.
- [32] 周小杰,王超,李平.一种单相并网逆变器参数在线估计方法[J].电气传动,2018,48(08):13-16.DOI:10.19457/j.1001-2095.dqcd18480.
- [33] 崔博文.基于复参数估计的逆变器故障实时检测[J].仪器仪表学报,2006,(S1):393-394+412.DOI:10.19650/j.cnki.cjsi.2006.s1.153.
- [34] Livera A, Theristis M, Makrides G, et al. On-line failure diagnosis of grid-connected photovoltaic systems based on fuzzy logic[C]//2018 IEEE 12th International Conference on Compatibility, Power Electronics and Power Engineering (CPE-POWERENG 2018). IEEE, 2018: 1-6.
- [35] Fei M, Ning L, Huiyu M, et al. On-line fault diagnosis model for locomotive traction inverter based on wavelet transform and support vector machine[J]. Microelectronics Reliability, 2018, 88-90:1274-1280.
- [36] 曹瑞钧,郭其一.基于 ICEEMDAN-FE 和支持向量机的三电平逆变器的故障诊断技术[J].机车电传动,2023,(01):97-103.DOI:10.13890/j.issn.1000-128X.2023.01.013.
- [37] Chen J, Chen X. Research on embedded airborne electronic equipment fault diagnosis expert system[C]//2010 2nd International Conference on Information Engineering and Computer Science. IEEE, 2010: 1-5.
- [38] J. G, L. C, Y. Q, et al. Fault diagnosis of subway auxiliary inverter based on EEMD, ApEn and PSO-BPNN[J]. ICIC Express Letters, Part B: Applications, 2015, 6(10):2785-2791.
- [39] Wang M, Zhao J, Wu F, et al. Transistor open-circuit fault diagnosis of three phase voltage-source inverter fed induction motor based on information fusion[C]//2017 12th IEEE Conference on Industrial Electronics and Applications (ICIEA). IEEE, 2017: 1591-1594.
- [40] Ren H P, Zhou R. Fuzzy sliding mode tracking control for DC motor servo system without uncertainty information[C]//2017 12th IEEE Conference on Industrial Electronics and Applications (ICIEA). IEEE, 2017: 1511-1515.
- [41] 赵晖,徐浩然,梅志刚,等.基于人工神经网络的逆变器开路故障诊断[J].电力电子技术,2021,55(02):45-49.

- [42]Guohua Y ,Yihuai H ,Qingguo S .A Convolutional Neural Network-Based Method of Inverter Fault Diagnosis in a Ship' s DC Electrical System[J].Polish Maritime Research,2022,29(4):105-114.
- [43]钱存元,吴昊,陈昊然.基于 EMD-BPNN 的逆变器 IGBT 开路故障诊断方法[J].电气工程学报,2024,19(03):432-442.
- [44]G T M , C A V , H G .Analysis of Total Harmonic Distortion and implementation of Inverter Fault Diagnosis using Artificial Neural Network[J].Journal of Physics: Conference Series, 2022, 2161(1):
- [45]田睿,刘维可,伍珣,等.基于 CGAN 与 LSTM 的逆变器多类型故障诊断方法研究[J].湖南电力,2023,43(06):151-158.
- [46]陈旺斌,孟献蒙,程凡永,等.基于卷积神经网络的光伏逆变器故障诊断[J].湖南工业大学学报,2021,35(01):25-30.
- [47]徐小健, 于飞. 基于输出电压轨迹的三相逆变器开关管开路故障诊断[J]. 中国电机工程学报, 2024, 44(3): 1106-1116. DOI: 10.13334/j.0258-8013.pcsee.222519.
- [48]彭柔, 荣军, 刘艳红, 等. 三相电压型逆变电路在 MATALB 中的建模与仿真[J]. 电子技术 (上海), 2015 (2): 10-12.
- [49]李宗源, 陈谦, 钱倍奇, 等. 基于格拉姆角场与并行 CNN 的并网逆变器开关管健康诊断 [J]. Electric Power Automation Equipment/Dianli Zidonghua Shebei, 2024, 44(8).
- [50]王浩, 杨东升, 周博文, 等. 基于并联卷积神经网络的多端直流输电线路故障诊断[J]. 电力系统自动化, 2020, 44(12): 84-92.
- [51]盛世龙, 王淑青, 王云鹤, 等. 基于格拉姆角场和 PCNN-BiGRU 模型的故障诊断方法及其应用[J]. China Rural Water & Hydropower, 2025 (2).
- [52]Marian P, Blaabjerg F. Control in Power Electronics: selected problems[J]. 2002.
- [53]Teodorescu R, Liserre M, Rodriguez P. Grid converters for photovoltaic and wind power systems[M]. John Wiley & Sons, 2011.
- [54]郭亮, 迟颂, 施文. 计及多重开关事件的高频电压源逆变器实时仿真[J]. 河北大学学报 (自然科学版), 2019, 39(5): 547.
- [55]赵广谦, 姜培刚, 林天然. 基于 CNN-BiLSTM 网络及注意力机制的智

- 能滚动轴承剩余寿命预测方法[J]. 机电工程, 2021, 38(10): 1253-1260.
- [56] Wang H, Zhu H, Li H. Multi-mode data generation and fault diagnosis of bearings based on STFT-SACGAN[J]. Electronics, 2023, 12(8): 1910.
- [57] Li H, Zhang Q, Qin X, et al. Fault diagnosis method for rolling bearings based on short-time Fourier transform and convolution neural network[J]. J. Vib. Shock, 2018, 37(19): 124-131.
- [58] 雷春丽, 焦孟萱, 薛林林, 等. 小样本下基于 MTF 与 SSCAM-MSCNN 的滚动轴承变工况故障诊断方法[J]. 计算机集成制造系统, 2025, 31(1): 278.
- [59] 雷春丽, 夏奔锋, 薛林林, 等. 基于 MTF-CNN 的滚动轴承故障诊断方法[J]. 振动与冲击, 2022, 41(9): 151-158.
- [60] 李敏. 基于优化并行二维卷积神经网络的滚动轴承智能故障诊断方法研究[D]. 长安大学, 2023. DOI:10.26976/d.cnki.gchau.2023.001202.
- [61] 张健飞, 黄朝东, 王子凡. 基于多头自注意力机制和卷积神经网络的结构损伤识别研究[J]. 振动与冲击, 2022, 41(24): 60-71. DOI:10.13465/j.cnki.jvs.2022.24.008.
- [62] 钱坤, 李湉雨, 李喆, 等. 基于拆分注意力残差网络的红外和可见光图像融合算法[J]. 西北工业大学学报, 2022, 40(06): 1404-1413.
- [63] 陆浩博. 基于二维卷积神经网络的逆变器故障诊断研究[D]. 兰州交通大学, 2023. DOI:10.27205/d.cnki.gltec.2023.001134.
- [64] 曹茂琨, 帕孜来·马合木提. 基于 CEEMD-SE 的三电平逆变器复杂故障诊断[J]. 现代电子技术, 2022, 45(02): 73-78. DOI:10.16652/j.issn.1004-373x.2022.02.014.
- [65] Liu Y, Wu Y. Parallel CNN three-phase Inverter Open-Circuit Fault Diagnosis based on STFT and GADF Images[C]//2024 4th International Conference on Electronic Information Engineering and Computer Science (EIECS). IEEE, 2024: 296-300.