

DOI: 10. 3969/j. issn. 2097-0706. 2026. 02. 003

基于多源特征融合去噪网络的配电网故障辨识方法研究

Research on distribution network fault identification method based on multi-source feature fusion denoising network

崔向虎¹, 徐越飞¹, 戚佳金¹, 张静¹, 陈世喆¹, 李金诺^{2*}

CUI Xianghu¹, XU Yuefei¹, QI Jiajin¹, ZHANG Jing¹, CHEN Shizhe¹, LI Jinnuo^{2*}

(1. 杭州电力设备制造有限公司, 杭州 310020; 2. 东北电力大学 机械工程学院, 吉林 吉林 132012)

(1. Hangzhou Electric Power Equipment Manufacturing Company Limited, Hangzhou 310020, China; 2. School of Mechanical Engineering, Northeast Electric Power University, Jilin 132012, China)

摘要: 针对配电网故障辨识过程中故障特征易被噪声掩盖, 单一特征难以全面反映故障信息等问题, 提出了一种多源特征融合去噪网络的配电网故障辨识方法。利用离散小波变换(DWT)对归一化处理后的零序电压与三相电流信号进行多尺度分解, 将原始信号重构为高频与低频分量, 减少特征混叠的影响。然后, 在高频分支中构建时频残差自适应去噪模块, 嵌入傅里叶卷积, 提取具有丰富频域信息的高频特征, 并结合通道注意力机制, 实现信号的精准去噪; 在低频分支中, 设计轻量级卷积网络提取低频分量的时序特征, 增强时频信息互补。引入一种时序-通道注意力机制进行自适应特征融合, 增强特征提取能力的同时抑制冗余特征, 从而实现复杂工况下故障类型的精确诊断。试验结果表明, 所提方法在仿真数据集下取得 99.12% 的准确率, 相较于现有方法显著提高了故障辨识的准确率。

关键词: 配电网故障辨识; 多源特征融合; 傅里叶卷积; 自适应去噪; 时序-通道注意力机制

中图分类号: TK 01 **文献标志码:** A **文章编号:** 2097-0706(2026)02-0027-10

Abstract: To address the issues that fault features are easily obscured by noise and single features can hardly capture comprehensive fault information during distribution network fault identification, a distribution network fault identification method based on multi-source feature fusion denoising network was proposed. The discrete wavelet transform (DWT) was used to decompose the normalized zero-sequence voltage and three-phase current signals at multiple scales, and the original signals were reconstructed into high-frequency and low-frequency components to mitigate the influence of feature aliasing. In the high-frequency component, the time-frequency residual adaptive denoising module was constructed, and Fourier convolution was embedded to extract high-frequency features with rich frequency-domain information. Combined with the channel attention mechanism, the accurate denoising of the signal was achieved. In the low-frequency branch, a lightweight convolutional network was designed to extract the temporal features of the low-frequency components to enhance the complementarity of the time-frequency information. A temporal-channel attention mechanism was introduced for the adaptive feature fusion, which enhanced the feature extraction capability while suppressing the redundant features, thus enabling the accurate diagnosis of the fault types under the complex working conditions. The experimental results showed that the proposed method achieved an accuracy of 99.12% in the simulation dataset, which significantly improved the accuracy of fault identification compared with the existing methods.

Keywords: distribution network fault identification; multi-source feature fusion; Fourier convolution; adaptive denoising; temporal-channel attention mechanism

0 引言

配电网作为连接变电站与终端用户的重要枢纽, 其运行的安全性和稳定性直接关系到整个电力供应系统的可靠性^[1-2]。然而, 配电网结构复杂、覆

盖范围广且多以架空线路为主, 长期处于复杂的工作环境, 容易发生短路、接地、断线等多种类型故障, 故障辨识技术对提高配电网的运行效率、降低运营成本具有重要研究意义^[3]。

目前, 配电网故障辨识的主流方法分为 2 种: 基

于数字继电器和基于数据驱动的检测方法^[4]。基于数字继电器的方法依赖电流互感器和电压互感器实时采集配电网的电流、电压信号,并通过分析行波、阻抗、滤波等进行故障检测。例如,文献[5]提出基于行波补偿机制的故障辨识方法,通过对异常电流行波进行调节,实现了非线性负载配电网的故障快速识别;文献[6]针对线路老化等隐蔽性故障,提出了一种新型回路阻抗辨识方法,该方法结合瞬时负荷波动特征量提取与稳态估计,有效提升了回路阻抗辨识的精度;文献[7]利用小波变换分析电流特征,完成短路故障检测。然而,基于数字继电器的故障辨识方法在特征提取过程中高度依赖人工决策和专家经验,难以适应复杂多变的工况^[8]。为克服基于数字继电器方法的局限性,基于人工智能技术(尤其是深度学习)的数据驱动故障辨识方法逐渐成为研究热点^[9]。例如,文献[10]将Transformer编码器与联邦迁移学习相结合,实现故障信号全局特征的自动提取,从而显著提升了配电网故障检测的准确率;文献[11-12]将图神经网络(GNN)与多任务学习相融合,充分利用配电网的拓扑结构信息,实现了故障定位与类型辨识的统一;文献[13]则提出了一种门控循环注意力网络,门控循环网络能够建立输入信号与故障类型概率间的关系,并引入注意力机制增强特征提取能力。尽管上述方法已取得一定进展,但在实际应用中,配电网长期运行于高噪声环境,故障特征极易被噪声掩盖,导致微弱故障信号难以被有效提取,现有模型仍普遍面临鲁棒性不足的问题^[14]。因此,如何高效分离并提取故障信号已成为当前研究中的难点。

鉴于上述挑战,文献[15]将信号处理技术与深度学习相结合,利用离散小波变换(DWT)实现故障信号的降噪;文献[16]提出了一种稀疏滤波胶囊网络,通过信号稀疏化有效分离噪声,从而提升输电线路故障诊断的鲁棒性;文献[17]则采用多尺度加权排列熵对模态分量进行自适应筛选以实现故障信号去噪,并结合协同知识蒸馏网络完成配电网故障辨识。尽管这些方法在提升鲁棒性方面取得不错的成果,但仍存在一定局限性。不同故障类型对电压、电流的敏感性存在差异,例如,在短路故障中,电流突变明显,但电压变化未必显著^[18];而在接地故障中,电流变化微弱,电压变化更为敏感^[19]。因此,处理单一特征难以全面反映故障信息。

针对上述问题,本文提出一种基于多源特征融合去噪网络的配电网故障辨识方法。本文所提出的故障识别方法属于离线识别方法,主要针对采集

的信号数据进行训练,在实际部署中可根据需求进一步拓展至在线故障诊断。首先,利用DWT对预处理后的三相电流与电压信号进行多尺度分解,并重构为高频与低频2个分支,以实现特征解耦。其次,在高频分支中引入傅里叶卷积替代传统卷积层,通过多层堆叠有效提取包含全局频域信息的高频特征,并结合压缩-激励(SE)注意力机制^[20-21]实现自适应去噪,在低频分支中设计轻量级卷积层以挖掘低频分量的时序特征,进一步强化时频特征互补。最后,引入一种新型时序-通道注意力机制,将三相电流与零序电压信号的高、低频特征进行多源特征融合,聚焦关键信息并抑制冗余特征,从而实现对故障类别的精准辨识。基于仿真数据集对所提方法进行了系统评估与验证,证明该方法具备良好的可行性与鲁棒性。

1 数据预处理

在配电网故障辨识中,不同类型故障引起的电流与电压分量动态响应特征差异显著。由于系统对称性较强,三相短路故障通常会同时导致三相电流、三相电压的大幅度突变;在单相接地故障中,系统电压对称性被破坏,表现为故障相电压明显降低、非故障相电压升高,同时零序分量不再为零^[22-24]。为兼顾不同故障类型对信号敏感性的差异,本文对采集的零序电压与三相电流信号进行预处理后同步输入至后续特征提取模块,以充分利用多源信息。

将采集的零电压信号 $\tilde{x}_{U_0}$ 以及三相电流信号 $\tilde{x}_1$ 进行数据归一化处理,将其数值映射到 $[0, 1]$ 的范围内以消除数值尺度差异,即

$$x_{U_0} = \frac{\tilde{x}_{U_0} - \min(\tilde{x}_{U_0})}{\max(\tilde{x}_{U_0}) - \min(\tilde{x}_{U_0})}, \quad (1)$$

$$x_1 = \frac{\tilde{x}_1 - \min(\tilde{x}_1)}{\max(\tilde{x}_1) - \min(\tilde{x}_1)}, \quad (2)$$

式中: x_{U_0}, x_1 为分别归一化后的零序电压信号和三相电流信号; $\min(\tilde{x}_{U_0}), \max(\tilde{x}_{U_0})$ 分别为原始零序电压信号的最小值和最大值; $\min(\tilde{x}_1), \max(\tilde{x}_1)$ 分别为原始电流信号的最小值和最大值。

鉴于噪声通常集中在信号的高频分量中,为提升后续去噪效果并降低特征混叠的影响,本文采用DWT对预处理后的 x_{U_0} 以及 x_1 进行多尺度分解^[15,25],即

$$A_n(k) = \sum_t x(t) h_n(2k - t), \quad (3)$$

$$D_n(k) = \sum_t x(t) g_n(2k - t), \quad (4)$$

式中: $x(t)$ 为输入信号(包括 x_{U_0} 和 x_1); $A_n(k)$ 为第 n 级小波分解的低频近似系数,反映信号的整体趋势;

$D_n(k)$ 为第 n 级小波分解的高频细节系数,反映信号中的高频成分; $h_n(k)$ 为低通滤波器,用于提取信号的低频信息; $g_n(k)$ 为高通滤波器,用于提取信号的高频信息; t 和 k 分别为时间和步数索引。

若 n 取3,将信号分解并进一步重构为高频分量 $x_{\text{high}}(t)$ 和低频分量 $x_{\text{low}}(t)$,为后续的精准确去噪提供基础

$$x_{\text{high}}(t) = \text{IDWT}(D_1, D_2, D_3), \quad (5)$$

$$x_{\text{low}}(t) = \text{IDWT}(A_3), \quad (6)$$

式中:IDWT为逆离散小波变换; D_1, D_2, D_3 为高频分量; A_3 为低频分量。

2 基于多源特征融合去噪网络的故障辨识

2.1 时频残差自适应去噪模块

傅里叶卷积(FC)是一种基于频域计算的卷积方法^[25],常用于处理二维图像。与传统时域卷积仅依赖局部感受野不同,FC利用快速傅里叶变换(FFT)将信号转换到频域,通过频域乘法实现全局频域依赖关系建模,再通过逆傅里叶变换(IFT)恢复到时域,从而能提取带有频率信息的时域特征。此外,FC能够有效区分不同频率成分,对噪声抑制具有天然优势。本文采用适合一维信号的一维傅里叶卷积,具体结构如图1所示。

(1)将高频信号输入至卷积核尺寸为 3×3 的卷积层中,利用激活函数ReLU以及批量归一化处理(BN)进行非线性变换,得到初步特征 X_{conv} 。

(2)通过FFT将提取的时域特征映射至频域。FFT能够将原始信号由时间维度转换为频率维度,从而有效解析信号的各类频率成分,使模型能够更全面地关注周期性特征及不同频率分量的变化模式。该过程可显著增强模型对故障信号频谱特征的感知能力。

$$F(X_{\text{conv}}) = \mathcal{F}(X_{\text{conv}}), \quad (7)$$

式中: $F(X_{\text{conv}})$ 为频域表示; $\mathcal{F}(\cdot)$ 为傅里叶变换。

FFT的具体表达为

$$F(u) = \sum_{t=0}^{N-1} X_{\text{conv}}(t) e^{-j2\pi ut/N}, \quad (8)$$

式中: u 为频率索引; N 为信号长度; j 为虚数单位。




图1 一维傅里叶卷积结构

Fig. 1 Structure of 1D Fourier convolution

(3)在频域中进行乘积操作($\cdot$ 表示逐元素相乘),即为频域卷积。与传统的卷积不同,频域中的卷积运算相当于信号频谱的加权操作,能够高效地

提取全局特征并增强不同频率分量之间的相互关系,避免时域卷积计算中的冗余计算,从而提高计算效率。

$$F_{\text{conv}}(u) = F(X_{\text{conv}}) \cdot W_f(u), \quad (9)$$

式中: $F_{\text{conv}}(u)$ 为频域特征图; $W_f(u)$ 为频域中的卷积核(可学习参数)。

(4)然后,进行IFFT。将频域卷积后的特征重新映射回时域,使模型在保留频谱特征优势的同时,进一步增强时域特征表达能力。

$$X_{\text{IFT}} = \mathcal{F}^{-1}(F_{\text{conv}}), \quad (10)$$

式中: X_{IFT} 为逆傅里叶变换后的信号; $\mathcal{F}^{-1}(\cdot)$ 为逆傅里叶变换。

(5)最后,利用卷积核尺寸为 1×1 的卷积层对逆变换回时域的特征进行进一步处理,以实现特征的非线性映射与信息整合,从而获得包含频率信息的时域特征 F 。

本文引入一维傅里叶卷积代替普通卷积层,构建时频残差自适应去噪模块(如图2所示)。该模块由零序电压高频分量、三相电流高频分量、零序电压低频分量、三相电流低频分量4个分支组成。




图2 时频残差自适应去噪模块

Fig. 2 Temporal-frequency residual adaptive denoising module

(1)在高频分支中,首先通过双层傅里叶卷积得到零序电压和三相电流信号增强后的特征。

(2)通过残差连接操作,保留一部分原始特征,融合恒等映射后的原始特征与输出特征,得到表示零序电压和三相电流的融合特征 F_1 和 F_3 。残差连接机制有助于在训练过程中保持信息流动,防止梯度消失或梯度爆炸,从而提高网络的稳定性。

(3)引入SE注意力机制,对包含频率信息的输出特征执行全局平均池化(GAP),将每个通道的全局特征压缩为一个标量 G_n ;池化后的特征经过两层全连接网络进行特征变换,利用ReLU激活函数增强特征表达能力。随后,通过Sigmoid激活函数对输出进行归一化,生成每个通道的注意力权重。将这

些权重重新分配给对应的特征通道,实现对重要特征的增强和对无关特征的抑制,从而提升模型的特征提取能力和鲁棒性。通道 N 的注意力系数表示为

$$A_N = \text{Sigmoid}(W_1 \text{ReLU}(W_2 G_N)), \quad (11)$$

式中: W_1 和 W_2 为两层全连接层生成的权重; G_N 为通道 N 特征绝对值的全局平均值。

将得到的权重应用至软阈值函数,完成自适应软阈值去噪,得到去噪后的零序电压特征 P_1 和三相电流特征 P_3 。

$$\lambda_N = G_N A_N, \quad (12)$$

$$P_1 = \text{sign}(F_1) \max(|F_1| - \lambda_N, 0), \quad (13)$$

$$P_3 = \text{sign}(F_3) \max(|F_3| - \lambda_N, 0), \quad (14)$$

式中: λ_N 为通道 N 的自适应软阈值。

在低频分支中,将零序电压和三相电流信号输入至两层卷积核尺寸为 3×3 的卷积层。同时,结合 BN 操作,消除内部协变量偏移,加速模型收敛,提高稳定性。此外,可以将非线性变换引入 ReLU 激活函数,避免梯度消失问题,并强化重要特征的表达能力,得到零序电压特征 P_2 和三相电流特征 P_4 。

2.2 时序-通道注意力(TCA)模块

为进一步整合零序电压与三相电流的特征图,实现时频信息的互补,增强特征提取能力,并充分挖掘不同故障类型对信号敏感性差异,本文提出一种针对多特征融合的 TCA 机制。

该机制通过自适应调节多尺度特征融合后各时间步的通道权重,有效抑制冗余信息,增强对关键故障特征的聚焦能力,具体方法如图 3 所示。首先,将 4 个分支输出的特征图按照通道维度进行拼接,得到融合特征 P_{1234} 。然后,通过一维轻量级卷积网络(Conv1d),在时间步数维度上针对每个时间步动态生成通道权重 w_{1234} ,以有效捕捉信号在不同时间点的变化,并突出与故障相关的脉冲特征。最后,利用自适应权重 w_{1234} 与 P_{1234} 进行加权求和,通过跨通道 GAP 提取全局空间信息,得到融合特征图 P'_{1234} ,使用反向传播(BP)算法进行反向更新,将每个特征图看为一个整体。

$$w_{1234} = \text{Sigmoid}(\text{Conv1d}(P_{1234})), \quad (15)$$

$$P'_{1234} = \frac{1}{4} \sum_{c=4}^1 (w_{1234} P_{1234})(N_k, \tau), \quad (16)$$

式中: N_k 为特征图的通道数; τ 为时间步数; c 为加权后特征图的通道数。加权特征图对空间位置 (N_k, τ) 上通道 c 的值进行平均池化,最终生成维度为 (N_k, τ) 的融合特征图,这种时序加权策略有效增强了多尺度特征的融合效果,从而更准确地提取时序




图3 时序-通道注意力机制

Fig. 3 Mechanism of the temporal-channel attention

信号中的关键脉冲特征。

2.3 基于多源特征融合去噪网络故障辨识流程

本文提出了基于多源特征融合去噪网络的故障辨识方法(如图4所示),具体检测方法如下。




图4 配电网故障辨识总体框架

Fig. 4 Distribution network fault identification framework

(1)收集数据:收集仿真模型中配电网不同故障类型的零序电压信号和三相电流信号,形成数据集,并分为训练集、测试集和验证集。

(2)数据预处理:针对训练集数据进行归一化处理,以保证数据分布的一致性,并利用DWT重构为高频分量和低频分量。

(3)模型训练:利用时频残差自适应去噪模块提取降噪后的时频特征,并引入TCA模块进行多源特征融合,得到融合特征。

(4)超参数微调:将验证集中的数据输入至模型中进行微调,以优化模型参数,并保存最优模型。

(5)故障辨识:将提取的特征输入分类器进行分类(见表1)。分类过程中采用交叉熵损失函数进行优化。最后,将测试集数据输入分类器中进行测试,完成故障类别辨识。

表 1 分类器结构
Table 1 Classifier structure

网络结构	激活函数	输出形状
线性层 1	Softmax	128
线性层 2		32
线性层 3		10

3 案例分析

本文在构建的仿真数据集上对所提出的方法进行了有效性评估与验证。实验环境配置为:Python3.11.5编程平台,操作系统为Windows11,硬件包括Intel(R)Core(TM)i7-13700H处理器及RTX4060 GPU显卡。

3.1 仿真数据集的搭建

本文基于Matlab2022b/Simulink仿真平台搭建10 kV配电网系统,其拓扑结构如图5所示。该仿真模型包括4条线路,线路类型包括架空线路、电缆线路以及混合线路。该模型采用中性点消弧线圈接地,1—8为故障发生位置。




图 5 10 kV 配电网系统拓扑结构
Fig. 5 Topology of the 10 kV distribution system

本文采用10 kHz采样频率采集配电网故障信号,单个样本包含1 024个时间步长,共设计10种故障类型样本。针对不同故障类型,分别采集零序电压与三相电流信号样本各1 000组,为后续模型训练提供了大量的数据基础。

为了模拟多种工况下的故障,本文在试验中通过随机调整不同参数进行数据采集,以提升故障辨识模型的泛化性能,具体仿真参数设置见表2。

表 2 故障样本参数设置
Table 2 Fault sample parameter setting

标签	故障类型	时间步长	故障阻抗/ Ω	初始相位角/ $^{\circ}$
AG	A相接地	1 024	0.01, 50, 100, 200, 300, 500, 1 000	0, 30, 60, 90, 120, 150, 180
BG	B相接地			
CG	C相接地			
AB	AB相短路			
AC	AC相短路			
BC	BC相短路			
ABG	AB相接地	1 024	0.01, 50, 100, 200, 300, 500, 1 000	0, 30, 60, 90, 120, 150, 180
ACG	AC相接地			
BCG	BC相接地			
ABC	ABC相短路	1 024	0.01, 50, 100, 200, 300, 500, 1 000	0, 30, 60, 90, 120, 150, 180

将收集到的样本分为测试用训练集、测试集、验证集,划分比例为8:1:1。其中训练优化器选用Adam,具体超参数设置见表3。

表 3 网络模型参数设置
Table 3 Network model parameter setting

参数	批次大小	学习率	迭代次数
数值	36	0.001	50

3.2 模型训练结果

为验证所提出方法的有效性,本节基于仿真数据集、按照前文设置的试验参数开展训练。为避免偶然性影响,试验重复进行了5次,取其平均结果作为最终指标,结果如图6所示。模型在训练集迭代29周期时收敛,而在验证集迭代24周期时达到收敛状态,表明训练过程拟合良好,未出现明显的过拟合现象;尽管在第15次迭代时验证集的Loss曲线出现短暂振荡,但模型很快恢复稳定,对后续训练过程未产生不利影响;模型在验证集上取得了99.56%的分类准确率。




图 6 模型训练结果分析
Fig. 6 Model training results analysis

各故障类别的混淆矩阵如图7所示。各类故障识别准确率均超过97%,仅在少数类别上出现轻微

误判,误差不超过 1%。试验结果充分证明了所提方法的可行性。

真实标签	AG	100	0	0	0	0	0	0	0	0	
	BG	0	100	0	0	0	0	0	0	0	
	CG	0	0	100	0	0	0	0	0	0	
	AB	0	0	0	97.5	2.5	0	0	0	0	
	AC	0	0	0	1.46	97.34	1.2	0	0	0	
	BC	0	0	0	0	0	100	0	0	0	
	ACG	0	0	0	0	0	0	98.7	0	1.3	
	ABG	0	0	0	0	0	0	0	100	0	
	BCG	0	0	0	0	0	2.3	0	97.7	0	
	ABC	0	0	0	0	0	0	0	0	100	
		AG	BG	CG	AB	AC	BC	ACG	ABG	BCG	ABC
预测标签											

图 7 各类故障准确率混淆矩阵

Fig. 7 Confusion matrix of accuracy for various fault types

为进一步评估模型的分类性能,本研究利用 t-分布随机邻域嵌入(t-SNE)算法对模型迭代 50 次后的部分样本进行可视化,每类故障各选取 100 个样本进行展示,试验结果的 t-SNE 二维分布如图 8 所示(不同颜色对应不同的故障类型)。

经过 50 次迭代后,尽管部分故障类型之间仍存在一定程度的重叠,但绝大多数样本已能够实现有效聚类,表明模型在故障类型区分方面具有较强的判别能力。出现重叠的主要原因是 AC 短路和 AB 短路均属于两相短路故障,其零序电压特征不明显,导致在特征空间上存在一定相似性。然而,重叠仅出现在极少数样本中,对整体分类性能影响较小。




图 8 50 次迭代后的分类特征可视化

Fig. 8 Feature visualization of classification results after 50 epochs

3.3 鲁棒性验证

为验证本文方法在噪声环境下的鲁棒性,基于仿真数据集开展试验,试验次数与章节 3.2 保持一致。在数据中分别加入 5, 10, 15, 20 dB 的高斯白噪声及脉冲噪声,以模拟不同噪声强度下的复杂工况。

为全面评估模型性能,将本文基于多源特征融合去噪网络的识别方法与基于以下模型的方法进行对比:DWT^[26]、支持向量机(SVM)^[27]、包含 3 层一维卷积神经网络(1D-CNN)的神经网络(卷积核尺寸为 3×3)^[28]、引入自适应软阈值函数且包含 18 个残差块的深度残差收缩网络(DRSN-CW)^[29]、具有 6 层(每层包含 8 个自注意力头)的 Transformer 编码器^[30]以及将 MexHat 小波函数嵌入卷积层中代替深度神经网络(DNN)第 1 层的 MexHat-WKN^[31]。上述方法均以电流信号为试验输入。为模拟真实应用场景,在数据中加入更为常见的脉冲噪声,不同识别方法的准确率如图 9 所示。




图 9 不同方法在噪声环境下的识别性能

Fig. 9 Performance of different identification methods in noisy environments

本文方法在 2 类噪声环境下均取得了最优的分类准确率。当加入 20 dB 高斯白噪声时,本文方法准确率相比仅采用 DWT 方法提升了 26.12 个百分点,从侧面验证了本文方法在降噪性能方面显著优于传统方法。Transformer 编码器的多头自注意力机制以及 MexHat-WKN 的时频特征提取在一定程度上提升了模型的鲁棒性,然而,由于缺乏专门的去噪机制,模型的分类准确率仍出现了一定幅度的下降。DRSN-CW 的准确率始终保持在 90% 以上,表现相对稳定,但仍不及本文方法。这主要是由于 DRSN-CW 虽然引入了自适应软阈值实现去噪,但其仅利用单一类型特征进行判别;而本文方法综合使用零序电压与三相电流信息,并通过注意力机制实现多源特征的动态融合,从而显著增强了特征表达能力和抗噪鲁棒性。

3.4 消融试验

为进一步验证 TCA 注意力机制的有效性,本节按照表 4 所示的方案开展消融试验,试验设置与上文保持一致。

结果显示,本文方法(方案 1)取得了最佳的分类性能;未采用 DWT 对分量进行重构,仅以电流信号作为输入的方法(方案 2)准确率较方案 1 下降了 2.77 百分点,验证了多源特征输入的重要性;方案 3 未引入 TCA 注意力机制、仅对特征进行简单的拼接,其准确率较方案 1 下降了 3.57 百分点,表明缺少注意力机制的特征融合会引入大量冗余信息,进一步说明 TCA 注意力机制能够有效抑制冗余特征并增强模型的特征表达能力;方案 4—6 分别使用 SE、高效通道注意力(ECA)^[32]和通道注意力机制(CAM)^[33]等其他通道注意力机制,但准确率未超过方案 1。这是因为 TCA 注意力机制能够同时在通道维度和时序维度上进行特征融合,而其他注意力机制仅在通道维度进行融合,未考虑时序信息,从而进一步验证本文所提方法的可靠性与优势。

表 4 多源特征融合去噪网络消融试验结果
Table 4 Results of ablation experiments

方案	DWT	注意力机制	准确率/%
1	√	TCA	99.12
2		TCA	96.35
3	√		95.55
4	√	SE	97.20
5	√	ECA	98.15
6	√	CAM	97.36

4 对比结果分析

为更全面地评估模型优越性,除准确率外,引入召回率、精度以及 F1 分数(精确率和召回率的调和平均数)等评价指标,从多个维度对前述模型的性能进行综合评估与分析,试验设置与章节 3 保持一致,结果见表 5。

表 5 不同方法准确率及召回率对比
Table 5 Comparison of accuracy and recall of different methods

方法	准确率	召回率
DWT	82.40	81.73
SVM	81.69	81.54
1D-CNN	88.71	88.04
DRSN-CW	96.21	96.10
Trasformer	94.56	94.35
MexHat-WKN	92.48	92.03
本文方法	99.12	98.83

由表 5 可知,本文方法在各项评价指标上均取得了最佳表现。本文方法的准确率达 99.12%,相比 DWT 方法提升了 16.72 百分点。这种显著提升主要得益于本文提出的 TCA 注意力机制能够有效融合多源特征用于故障辨识,同时结合 SE 注意力机制实现自适应去噪;而 DWT,SVM 等传统方法未包含去噪处理,因而性能较低。MexHat-WKN 相比于传统卷积方法 1D-CNN 准确率高出 3.77 百分点,充分验证时频特征提取的有效性。Transformer 编码器的准确率达到了 94.56%,这是由于多头注意力机制在全局信息建模的优势,然而较本文方法仍低 4.56 百分点,这是因为本文方法在频域内的乘积操作相当于时域内进行全局卷积,结合了丰富的多尺度信息、时频特征及动态融合机制,体现了本文方法在复杂工况下特征提取的优越性。

F1 分数作为综合了召回率和精确率的评价指标,被广泛应用于各类分类任务中。图 10 展示了不同方法的 F1 分数和精确率对比情况,可以看出,本文提出的方法在 2 项指标上均优于其他方法,进一步验证了其可行性与有效性。这也侧面证明结合多源特征进行故障辨识能够有效缓解不同故障类型对信号敏感度差异所带来的影响。




图 10 不同方法精度和 F1 分数
Fig. 10 Accuracy and F1 scores of different methods

图 11 为 6 种方法的混淆矩阵是评估分类模型,可量化模型性能。DWT 和 SVM 在几乎所有故障类型上均出现误判,说明其适用性和泛化能力较弱。尽管 DRSN-CW 的准确率达到 96.21%,但其只能提取单一类型特征,尤其面对复合故障时,整体表现仍不及本文方法。

值得注意的是,在时域中,卷积操作的计算复杂度为 $O(LK)$,其中 L 为输入信号长度, K 为卷积核大小。本文所采用的骨干网络基于傅里叶卷积,可将卷积计算复杂度变为 $O(L \lg L)$ ^[25,34]。由于本文网络结构相对浅层,当面对卷积核较小的浅层卷积(如 1D-CNN)时,傅里叶卷积在计算效率上并不表现出显著优势;然而,当网络层数增加,如深度残差




图 11 不同方法各故障混淆矩阵

Fig. 11 Confusion matrices of different methods for each fault type

收缩网络(DRSN-CW)或多层 Transformer 编码器,尤其在存在多核、多通道的卷积操作时,本文方法能够显著降低总体计算量,从而提升模型在长序列信号或复杂结构下的计算效率与实际运行速度。

5 结论

针对配电网故障辨识过程中故障特征易被噪声掩盖,单一特征难以全面反映故障信息等问题,本文提出基于多源特征融合去噪网络的配电网故障辨识方法,为配电网故障辨识提供新的研究思路,主要结论如下。

(1)构建时频残差自适应去噪模块,通过不同噪声环境下的对比,试验结果表明该方法优于其他现有模型,引入SE注意力机制实现自适应去噪,能够减轻环境因素对模型后续故障辨识的干扰,后续利用傅里叶卷积,提供了更加丰富的时频特征,完成噪声环境下的特征提取,最终在试验中达到99.12%的准确率。

(2)引入TCA注意力机制对零序电压与三相电流特征进行通道和时序两个维度的加权融合,充分挖掘多源信号间的互补性,有效抑制冗余信息。试验结果表明,TCA机制能够更精准地捕捉不同故障类型的敏感特征,从而显著提升故障辨识的准确率。

然而,该方法仍存在一定局限性。首先,在实际运行中故障样本远少于正常样本,导致存在严重

的类别不平衡问题,在本文提出的方法中并没有得到有效的解决。其次,当前试验完全基于仿真数据,尽管仿真数据考虑了多种工况、负荷变化及随机噪声与脉冲干扰,但实际运行中仍可能存在未知因素,如设备老化、电网拓扑变化、传感器误差等其他偶发干扰,从而对模型的泛化能力构成挑战。因此,未来研究将重点关注两方面:一是探索针对样本不平衡问题的新策略,二是结合真实配电网数据进行验证与微调,同时探索小样本学习以及无监督学习在该领域的应用潜力,以提升模型在实际应用中的适应性与可靠性。

参考文献:

- [1]李泽文,葛俊辰,陈思旭,等.基于VMD-MWPE和PNN的配电网故障分类辨识方法[J].江西电力,2025,49(3):28-37.
LI Zewen, GE Junchen, CHEN Sixu, et al. Fault classification and identification method of distribution network based on VMD-MWPE and PNN [J]. Jiangxi Electric Power, 2025, 49(3): 28-37.
- [2]王建,吴昊,张博,等.不平衡样本下基于迁移学习-AlexNet的输电线路故障辨识方法[J].电力系统自动化,2022,46(22):182-191.
WANG Jian, WU Hao, ZHANG Bo, et al. Fault identification method for transmission line based on transfer

- learning-AlexNet with imbalanced samples[J]. Automation of Electric Power Systems, 2022, 46(22): 182-191.
- [3] WANG J, ZHANG B, YIN D, et al. Distribution network fault comprehensive identification method based on voltage-ampere curves and deep ensemble learning[J]. International Journal of Electrical Power & Energy Systems, 2025, 164: 110403.
- [4] RIZEAKOS V, BACHOUMIS A, ANDRIOPOULOS N, et al. Deep learning-based application for fault location identification and type classification in active distribution grids[J]. Applied Energy, 2023, 338: 120932.
- [5] 李靖鑫, 李旭峰, 杨金东, 等. 非线性负载配电网异常时频电流行波辨识方法[J]. 电子设计工程, 2024, 32(24): 143-146, 151.
- LI Jingxin, LI Xufeng, YANG Jindong, et al. Nonlinear load distribution network abnormal time-frequency current wave identification method [J]. Electronic Design Engineering, 2024, 32(24): 143-146, 151.
- [6] 庄小艇, 孙蒙恩, 赖天德, 等. 基于负荷波动特征量提取和稳健估计的低压配电网回路阻抗辨识方法[J]. 供用电, 2025, 42(2): 29-37.
- ZHUANG Xiaoting, SUN Meng'en, LAI Tiande, et al. A low voltage distribution network loop impedance identification method based on load fluctuation feature extraction and robust estimation [J]. Distribution & Utilization, 2025, 42(2): 29-37.
- [7] GUO M F, YANG N C, YOU L X. Wavelet-transform based early detection method for short-circuit faults in power distribution networks[J]. International Journal of Electrical Power & Energy Systems, 2018, 99: 706-721.
- [8] JI L P, TIAN X L, WEI Z H, et al. Intelligent fault diagnosis in power distribution networks using LSTM-DenseNet network [J]. Electric Power Systems Research, 2025, 239: 111202.
- [9] SAAD M, KIM C H, MUNIR N. Single-phase auto-reclosing scheme using particle filter and convolutional neural network [J]. IEEE Transactions on Power Delivery, 2022, 37(6): 4775-4785.
- [10] 叶远波, 王吉文, 邵庆祝, 等. 配电网故障识别 Transformer-联邦迁移学习算法设计[J]. 电力系统及其自动化学报, 2025, 37(10): 120-128.
- YE Yuanbo, WANG Jiwen, SHAO Qingzhu, et al. Design of Transformer-based federated transfer learning algorithm for distribution network fault recognition [J]. Proceedings of the CSU-EPSA, 2025, 37(10): 120-128.
- [11] 梁栋, 赵月梓, 贺国润, 等. 基于图半监督与多任务学习的配电网故障区段与类型统一辨识[J]. 电力系统保护与控制, 2024, 52(12): 25-32.
- LIANG Dong, ZHAO Yuezi, HE Guorun, et al. Unified identification of fault section and type for distribution networks based on graph semi-supervised and multi-task learning [J]. Power System Protection and Control, 2024, 52(12): 25-32.
- [12] 任一鸣, 杜董生, 邓祥帅, 等. 基于GRU和GWO-KELM的电力线路故障诊断[J]. 综合智慧能源, 2024, 46(3): 54-62.
- REN Yiming, DU Dongsheng, DENG Xiangshuai, et al. Power line fault diagnosis based on GRU and GWO-KELM [J]. Integrated Intelligent Energy, 2024, 46(3): 54-62.
- [13] 陈昊蓝, 靳冰莹, 刘亚东, 等. 基于门控循环注意力网络的配电网故障识别方法[J]. 上海交通大学学报, 2024, 58(3): 295-303.
- CHEN Haolan, JIN Bingying, LIU Yadong, et al. Fault detection in power distribution systems based on gated recurrent attention network [J]. Journal of Shanghai Jiao Tong University, 2024, 58(3): 295-303.
- [14] IBRAHIM A H M, SADANANDAN S K, GHAUD T, et al. Incipient fault detection in power distribution networks: Review, analysis, challenges and future directions [J]. IEEE Access, 2024, 12: 112822-112838.
- [15] SHALBY E M, ABDELAZIZ A Y, AHMED E S, et al. A comprehensive guide to selecting suitable wavelet decomposition level and functions in discrete wavelet transform for fault detection in distribution networks [J]. Scientific Reports, 2025, 15(1): 1160.
- [16] FAHIM S R, SARKER S K, MUYEEN S M, et al. A deep learning based intelligent approach in detection and classification of transmission line faults [J]. International Journal of Electrical Power & Energy Systems, 2021, 133: 107102.
- [17] HAO S, FAN S A, MA X, et al. MKDNet: A fault detection method based on multi-scale entropy mode denoising and collaborative knowledge distillation for distribution networks [J]. Electric Power Systems Research, 2025, 249: 112003.
- [18] 卢晓强, 李刚, 周万竣, 等. 基于最小二乘双支持向量的配电网短路故障辨识方法研究[J]. 武汉大学学报(工学版), 2022, 55(4): 401-408.
- LU Xiaoqiang, LI Gang, ZHOU Wanjun, et al. Research on identification method of short-circuit fault in distribution network based on least squares twin support vector machine [J]. Engineering Journal of Wuhan University, 2022, 55(4): 401-408.
- [19] 李政洋, 曹一家, 陈春, 等. 配电网相电压不对称动态变化下的高阻接地故障辨识[J]. 中国电机工程学报, 2024, 44(22): 8744-8759.
- LI Zhengyang, CAO Yijia, CHEN Chun, et al. Identification of high-impedance ground faults under dynamic variations of voltage unbalance in distribution networks [J]. Proceedings of the CSEE, 2024, 44(22): 8744-8759.

- 8744-8759.
- [20] HU J, SHEN L, SUN G. Squeeze-and-excitation networks [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.
- [21] 冯骥, 杨国华, 史磊, 等. 基于并行融合深度残差收缩网络的有源配电网故障诊断[J]. 综合智慧能源, 2024, 46(6): 8-15.
- FENG Ji, YANG Guohua, SHI Lei, et al. Research on fault diagnosis of active distribution network based on parallel fusion deep residual shrinkage network [J]. Integrated Intelligent Energy, 2024, 46(6): 8-15.
- [22] 刘宝稳, 崔露瑶, 曾祥君, 等. 配电网两相接地零序电压空间轨迹区域特征与故障相识别[J/OL]. 电网技术, 2025: 1-15 (2025-08-04) [2025-09-22]. [https://kns.cnki.net/KCMS/detail/detail.aspx? filename=DWJS20250801007&dbname=CJFD&dbcode=CJFQ](https://kns.cnki.net/KCMS/detail/detail.aspx?filename=DWJS20250801007&dbname=CJFD&dbcode=CJFQ).
- LIU Baowen, CUI Luyao, ZENG Xiangjun, et al. Spatial trajectory characteristics of zero-sequence voltage for two-phase grounding fault and fault phase identification in distribution networks [J/OL]. Power System Technology, 2025: 1-15 (2025-08-04) [2025-09-22]. <https://kns.cnki.net/KCMS/detail/detail.aspx? filename=DWJS20250801007&dbname=CJFD&dbcode=CJFQ>.
- [23] 缪欣, 黄海悦. 基于 Δi -PCA 原理的分布式小电流接地选线保护方法研究[J]. 机电信息, 2023(4): 76-81.
- MIAO Xin, HUANG Haiyue. Research on distributed protection method of small current grounding line selection based on Δi -PCA principle[J]. Mechanical and Electrical Information, 2023(4): 76-81.
- [24] 甘捷, 姚孝庭, 于景国, 等. 变频器 10 kV 断路器柜速断保护动作故障分析及处理[J]. 东北电力技术, 2021, 42(1): 41-43.
- GAN Jie, YAO Xiaoting, YU Jingguo, et al. Analysis and treatment of Quick-Break protection fault for 10 kV switchgear in frequency converter [J]. Northeast Electric Power Technology, 2021, 42(1): 41-43.
- [25] CHI L, JIANG B, MU Y. Fast Fourier convolution [J]. Advances in Neural Information Processing Systems, 2020, 33: 4479-4488.
- [26] ATTAR M S, MIVEH M R. High - impedance fault detection in distribution networks based on support vector machine and wavelet transform approach (Case study: Markazi Province of Iran) [J]. Energy Science & Engineering, 2025, 13(3): 1171-1183.
- [27] 张灵芝, 王杨帆, 刘基典, 等. 电网故障行波传感器研究及测试[J]. 电力科学与技术学报, 2020, 35(2): 142-149.
- ZHANG Lingzhi, WANG Yangfan, LIU Jidian, et al. Research and experiments on the transmission characteristics of traveling wave sensor for power fault [J]. Journal of Electric Power Science and Technology, 2020, 35(2): 142-149.
- [28] SIDDIQUE M N I, SHAFIULLAH M, MEKHILEF S, et al. Fault classification and location of a PMU-equipped active distribution network using deep convolution neural network (CNN) [J]. Electric Power Systems Research, 2024, 229: 110178.
- [29] ZHAO M H, ZHONG S, FU X, et al. Deep residual shrinkage networks for fault diagnosis [J]. IEEE Transactions on Industrial Informatics, 2019, 16(7): 4681-4690.
- [30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. Advances in Neural Information Processing Systems, 2017, 30: 03762.
- [31] LI T F, ZHAO Z B, SUN C, et al. WaveletKernelNet: An interpretable deep neural network for industrial intelligent diagnosis [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2022, 52(4): 2302-2312.
- [32] WANG Q L, WU B G, ZHU P F, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 11534-11542.
- [33] ZHOU B L, KHOSLA A, LAPEDRIZA A, et al. Learning deep features for discriminative localization [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2921-2929.
- [34] PRATT H, WILLIAMS B, COENEN F, et al. FCNN: Fourier convolutional neural networks [C]//Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Cham: Springer International Publishing, 2017: 786-798.

(本文责编: 陆华)

收稿日期: 2025-09-22; 修回日期: 2025-10-24

上网日期: 2026-02-25; 附录网址: www.ienergy.cn

作者简介:

崔向虎(1978), 男, 高级工程师, 从事计算机应用、电力新能源通信设备、控制理论方面的研究, 99522570@qq.com;

徐越飞(1976), 男, 高级工程师, 从事电气工程及其自动化方面的研究, xu13868011898@163.com;

戚佳金(1979), 男, 高级工程师, 博士, 从事新能源、电力系统运行和控制方面的研究, qjjiajin@126.com;

张静(1974), 女, 高级工程师, 从事电力系统运行和控制方面的研究, 331029160@qq.com;

陈世喆(1990), 男, 高级工程师, 硕士, 从事电气工程及其自动化方面的研究, 370469588@qq.com;

李金诺*(1997), 男, 硕士生, 从事配电网运行状态监测与故障识别方法等方面研究, lijinnuo12@163.com。

*为通信作者。