

引用格式: 陶宏伟, 张智宏, 宋运泉, 等. 基于广义零样本学习的牵引逆变器电流传感器故障诊断研究 [J]. 北京工业大学学报, 2026, 52(5): 475-484.

TAO H W, ZHANG Z H, SONG Y Q, et al. Research on fault diagnosis of current sensors in traction inverters based on generalized zero-shot learning [J]. Journal of Beijing University of Technology, 2026, 52(5): 475-484. (in Chinese)

基于广义零样本学习的牵引逆变器电流传感器故障诊断研究

陶宏伟¹, 张智宏¹, 宋运泉¹, 陈福龙², 陈志文³

(1. 南昌大学信息工程学院, 南昌 330031; 2. 华能江西清洁能源有限公司, 南昌 330006;

3. 中南大学自动化学院, 长沙 410083)

摘 要: 电流传感器是牵引传动系统的高发故障源,但在实际应用中,故障数据往往遵循长尾类分布,难以覆盖传感器的各种故障类型。为解决故障样本不完备给传感器故障诊断带来的困难,提出一种基于广义零样本学习 (generalized zero-shot learning, GZSL) 的故障诊断方法,用于诊断牵引逆变器中电流传感器的增益和偏移故障。首先,通过快速傅里叶变换 (fast Fourier transform, FFT) 对电流故障信号进行特征提取,捕捉故障数据的频谱特征;其次,构建故障属性描述矩阵,并结合所提取特征进行语义映射与预处理,实现从已见故障到未见故障的语义知识迁移;最后,在牵引逆变系统实验平台上对所提方法的有效性进行验证。结果表明,该方法在零样本场景下仍具备较高的识别精度,为解决电流传感器故障诊断中的样本稀缺问题提供了新的技术途径。

关键词: 电流传感器; 牵引逆变器; 故障诊断; 广义零样本学习; 快速傅里叶变换; 属性描述矩阵

中图分类号: TM 464

文献标志码: A

文章编号: 0254-0037(2026)05-0475-10

doi: 10.11936/bjtxb2025090011

Research on Fault Diagnosis of Current Sensors in Traction Inverters Based on Generalized Zero-shot Learning

TAO Hongwei¹, ZHANG Zhihong¹, SONG Yunquan¹, CHEN Fulong², CHEN Zhiwen³

(1. School of Information Engineering, Nanchang University, Nanchang 330031, China;

2. Huaneng Jiangxi Clean Energy Co., Ltd., Nanchang 330006, China;

3. School of Automation, Central South University, Changsha 410083, China)

Abstract: Current sensors are a frequent fault source in the traction transmission system. However, in practical applications, fault data often follow a long-tailed distribution, making it difficult to collect all types of faults from each sensor. To address the challenge of incomplete fault samples in sensor fault diagnosis, a fault diagnosis method based on generalized zero-shot learning (GZSL) is proposed, for diagnosing gain and offset faults in current sensors of traction inverters. First, fast Fourier transform (FFT) was used to extract features from current fault signals, to capture the spectral characteristics of fault data. Second, a fault attribute description matrix was constructed, and the extracted features were combined for semantic mapping and preprocessing to enable semantic knowledge transfer from seen to

收稿日期: 2025-09-18; **修回日期:** 2025-10-31

基金项目: 江西省自然科学基金资助项目(20242BAB20055); 江西省重点研发计划资助项目(20232BBG70031)

作者简介: 陶宏伟(1990—), 男, 讲师, 主要从事复杂系统故障诊断、优化控制方面的研究, E-mail: hongweitao@ncu.edu.cn

unseen faults. Finally, the effectiveness of the proposed method was verified on a traction inverter system experimental platform. The experimental results demonstrate that this method maintains high recognition accuracy under zero-shot conditions, providing a new technical approach to address the issue of sample scarcity in current sensor fault diagnosis.

Key words: current sensors; traction inverter; fault diagnosis; generalized zero-shot learning (GZSL); fast Fourier transform (FFT); attribute description matrix

近年来,随着轨道交通的迅速发展,其可靠性受到越来越多的关注^[1-4]。逆变器为牵引电机供电,是保障轨道交通可靠运行的关键部件之一^[5-7]。目前,大多数研究集中在逆变器的功率器件故障^[8-10]。传感器作为牵引系统中检测电压、电流信号的元件^[11-12],一旦发生故障,可能导致反馈信号失真,影响系统的闭环控制性能,甚至损坏其他部件^[13-14]。因此,针对传感器故障诊断的研究对提高轨道交通的可靠运行具有重要意义^[15-18]。

当前,针对逆变器的故障诊断研究主要包括基于模型的故障诊断方法、基于信号的故障诊断方法,以及基于数据驱动的故障诊断方法。

在基于模型的故障诊断方法中,需根据诊断对象的电路拓扑与运行原理构建数学模型,利用模型中的计算变量与实际系统可获取的测量信号进行故障检测与诊断。许水清等^[19]通过构建可快速收敛的滑模观测器,利用电流残差实现对中点钳位型三电平逆变器中功率器件开路与电流传感器故障的诊断;孙源等^[20]针对非线性负载下两电平三相逆变器的故障诊断问题,设计基于复合控制的离散滑模观测体模型,结合可调节检测变量与自适应阈值,有效抑制谐波干扰,实现了逆变器功率器件开路故障与传感器故障的诊断;Yu等^[21]通过构建网侧电流估计器,计算得到电流残差用以对整流器的传感器故障进行诊断;Li等^[22]提出一种基于三次谐波空间的容错控制策略,对正弦波与梯形波五相永磁同步电机,分别采用正弦脉宽调制与坐标偏移补偿方法,重构故障相电流,应对电流传感器失效问题。然而,基于模型的故障诊断方法需要精确的数学建模,可能受到系统参数变化、多阈值约束的影响,对该类方法迁移与应用到不同平台提出挑战。

基于信号的故障诊断方法通过信号处理技术提取故障特征以区分不同故障类型。根据测量信号的不同,可分为基于电流的方法和基于电压的方法。基于电压的方法常需在系统安装额外的电压传感器,这增加了故障诊断的成本。在基于电流的方法中,需对输出电流进行信号处理以提取故障特征。

此类方法无须额外硬件,但通常受到系统运行工况的影响。此外,尽管该类方法无须依赖系统模型,但可能面临计算量大的挑战,且负载变化可能影响诊断结果。

随着人工智能技术的发展,数据驱动方法已广泛应用于故障诊断领域。该方法通过从数据库中学习测量信号的特征与故障标签之间的映射关系,经过训练得到诊断模型。Gou等^[23]利用快速傅里叶变换对信号进行分解,采用ReliefF算法选择信号特征,通过随机向量函数链路网络对历史数据集进行训练,实现了逆变器功率器件开路故障与传感器故障的诊断;针对多传感器数据关联、现有方法无法有效处理时间序列的问题,Dong等^[24]提出一种基于长短期记忆网络的自适应多传感器故障诊断方法,提升了复杂故障模式的识别精度;针对复杂的阈值选择和规则制定的问题,Xing等^[25]提出一种多模态深度残差滤波网络,实现对T型三电平逆变器多开关开路故障的高效在线诊断;针对不同工况导致逆变器开路故障诊断准确率下降的问题,Shen等^[26]提出一种改进的卷积神经网络(convolutional neural network, CNN)和样本扩增方法,实现诊断性能优于传统CNN且具有更稳定的效果;Liu等^[27]提出不平衡深度迁移网络,通过深度不平衡学习与批量核范数最大化方法,缓解了跨工况下高速列车牵引电机轴承故障诊断中因特征分布偏移引起的性能下降问题;朱琴跃等^[28]提出一种通过提取逆变器输出电压的暂态与稳态特征,结合主成分分析进行统计分析的方法,实现对绝缘栅双极晶体管微小故障的精确检测;Yang等^[29]提出动态传输损失权重-深度子域适应网络,通过动态更新传输损失权重,提升了高速列车悬挂系统变速度工况下的故障诊断精度。

与另外2类方法相比,基于数据驱动的故障诊断方法无须构建系统数学模型,但模型训练效果很大程度上依赖于故障样本质量。通常故障样本数量越大,种类越丰富,模型梯度会更稳定,收敛更平稳,进而使得模型诊断效果(如故障诊断准确率)更好。然而实际场景中,由于故障常具有破坏性,常在设备

中增加硬件保护装置,一旦检测到故障发生会立即开启保护装置(如切断电源或打开保护开关),使得部分故障数据较为稀少^[6]。此外,故障注入实验常具有破坏性,不仅提高了故障诊断研究的风险性,还增加了故障诊断技术的成本。这些原因使得部分故障数据较难获取,甚至可能出现零样本情况,即某些故障类型完全缺失样本,给传统基于数据驱动的故障诊断方法带来挑战^[1-3]。

针对上述问题,可采用零样本学习(zero-shot learning, ZSL)^[3]方法,通过构建故障种类的描述矩阵,学习故障与描述矩阵之间的映射关系。ZSL最早已在热力设备故障诊断中得到探索,通过构建专家语义知识库来表征未知故障的先验特征,实现对未见故障的识别^[34-35]。然而,早期ZSL通常在测试阶段仅包含未见故障,难以适用于实际系统中已见与未见故障共存的复杂场景。为此,相关学者提出广义零样本学习(generalized zero-shot learning, GZSL),进一步拓展了ZSL的适用范围^[6]。

GZSL旨在训练一个模型,利用已见类故障样本完成训练,对已见类故障样本和训练阶段未涉及的未见故障样本进行有效分类。目前,已有较多研究者将GZSL引入到故障诊断领域。Mou等^[7]提出一种基于分布式语义嵌入和重建变分自编码器的工业过程广义零样本故障诊断模型,实现了工业过程中广义零样本故障诊断;针对高速列车转向架因复合故障历史数据缺乏导致传统深度学习算法难以实现精确诊断的问题,Zhang等^[8]提出一种信号处理辅助的深度学习方法,将DenseNet的扩展网络整合到GZSL框架,并结合属性描述矩阵的方法,实现无须训练数据的情况下诊断复合故障;针对数据不平衡导致的已见类别与未见类别之间域偏移的问题,Yin等^[9]提出堆叠GZSL框架,结合基于属性描述的GZSL策略以及基于生成的GZSL策略,实现对列车转向架未见复合故障的诊断,且性能优于单一GZSL策略和其他经典集成模型。

然而,将ZSL应用到传感器故障诊断的研究还不多见,同时,与传统ZSL相比,GZSL支持测试阶段对已见与未见故障的联合诊断,更符合牵引逆变器系统故障诊断的实际场景。因此,本文将GZSL引入牵引逆变器电流传感器故障诊断领域,旨在面对故障样本稀缺及未见故障标注数据缺失的情形。

本文针对牵引逆变器电流传感器在故障样本稀缺甚至缺失的场景,提出了一种基于GZSL的故障

诊断方法。首先,通过快速傅里叶变换(fast Fourier transform, FFT)分析三相电流的频域特征,提取与故障状态相关的频率成分,作为故障诊断的特征。然后,基于GZSL范式,引入属性描述矩阵,建立频域特征与故障语义描述之间的映射关联模型,使模型具备对未见故障类别的泛化识别能力。最后,在牵引逆变系统实验平台上开展实验,验证方法的有效性。

1 逆变器结构拓扑与传感器故障分析

1.1 两电平牵引逆变器拓扑结构

两电平牵引逆变器的结构如图1所示,该系统主要包括直流电源 U_n 、三相逆变器和永磁同步电机M。逆变器包含3个结构相同的桥臂,由6个功率器件 $T_1 \sim T_6$ 以及6个二极管 $D_1 \sim D_6$ 构成。控制系统生成的脉宽调制信号经驱动电路放大后,得到功率器件控制信号,用于控制逆变桥中各功率器件的导通与关断,将直流电压转换为M所需的工作电压。直流电压通过三相桥臂中功率器件的有序通断,被转化为相位互差 120° 的脉冲序列,对脉冲序列进行调节得到三相交流电,通过调节输出交流电的频率和电压,控制牵引电机的转速与转矩,实现轨道交通工具启动和加速减速等运行状态的切换。在逆变器交流输出端装有电流传感器,实时采集三相输出电流信号。该信号经调制电路输入至控制系统,用于实现牵引逆变器的实时控制。




图1 两电平牵引逆变器拓扑图

Fig. 1 Two-level traction inverter topology diagram

1.2 牵引逆变器电流传感器常见故障类型

在电流传感器的各类故障中,增益故障与偏移故障较为常见,因此将这2种故障作为诊断对象。设实际电流信号为 S ,经电流传感器采集并输出的值为 yS 。在正常工作状态下, $yS = S$;当传感

器发生增益故障时, S 与 yS 呈现不为 1 的倍数关系; 当传感器发生偏移故障时, S 与 yS 之间存在固定偏差。上述 2 种故障都使得控制系统接收到的电流反馈信号偏离真实值, 2 类故障的数学公式可表示为

$$yS = kS \quad (1)$$

$$yS = S + b \quad (2)$$

式中: k 为故障增益系数; b 为故障偏移系数。

2 零样本故障诊断模型

牵引逆变器的电流传感器故障诊断方法框架如




图2 牵引逆变器电流传感器故障诊断方法框架

Fig. 2 Framework for diagnosing faults in traction inverter current sensors

图2中 b_i 为故障特征, 特征提取模块对故障电流信号进行 FFT, 将其从时域转换到频域。对于长度为 N 的故障信号, FFT 得到 $N/2 + 1$ 个独立频率分量, 每个分量包含幅值和相位等信息, 这些信息组成一个高维特征向量。利用主成分分析模块对该特征向量进行降维处理, 保留主要故障信息的同时降低数据冗余, 提升模型计算效率。由于牵引逆变器三相电流的对称性, 将特征数据输入模型前, 利用这一对称特性对输入数据进行预处理, 以加速模型对特征与属性标签间映射关系的学习。故障特征经主成分分析模块和预处理后作为 GZSL 的输入。通过引入故障描述矩阵, 模型的识别能力可从已见类故障泛化至未见类故障。采用最近邻搜索策略, 选取欧式距离最小的类别作为故障诊断结果。

2.1 特征提取模块

特征提取是故障诊断的重要环节, 目的是从采集数据中提取能够诊断故障的特征, 为后续的诊断

图2所示。首先收集电流传感器故障数据, 构建故障数据集 X , 该数据集包含所有目标故障种类, 随后将部分种类故障划分为训练集 X_1 , 作为此故障诊断方法中的已见故障数据, 剩余故障为 X_2 作为未见故障数据集与 X_1 共同作为测试数据集。在模型离线训练阶段, 对 X_1 进行 FFT 分析, 以提取故障信号的频域信息。随后提取属性相关特征, 并针对每个属性 a_i 训练对应的属性学习器 g_i , 使得 g_i 在测试阶段根据输入信息对 a_i 进行预测。最后根据测试集 X 对测试样本属性向量进行推断, 确定测试样本的最终类别。

提供特征输入。根据式(1)(2)可知: 当电流传感器发生增益故障时, 电流幅值会发生变化; 当电流传感器发生偏移故障时, 直流分量会发生变化。FFT 是一种常用的特征提取方法。本文基于 FFT 不仅提取了上述 2 个主要特征, 还提取了频谱重心、频谱峭度、频谱熵、信号总能量及最大谐波绝对幅值共 5 个辅助特征, 用于模型训练与测试。

输入的传感器故障时域信号 $x(t)$ 经离散采样后得到序列 $x[n]$ (其中 $n = 0, 1, \dots, N-1$), 其 FFT 结果为频域复数序列 $X[k]$ (其中 $k = 0, 1, \dots, N-1$), 具体表达式为

$$X(k) = \sum_{n=0}^{N-1} x(n) e^{-j2\pi kn/N} = \sum_{n=0}^{N-1} x(n) W_N^{kn} \quad (3)$$

式中: $W_N^{kn} = e^{-j2\pi kn/N}$ 为旋转因子 (j 为虚数单位); N 为采样点数; k 为频率序号。

当电流传感器发生故障时, FFT 模块以故障发生后一个完整工频周期内的采样数据作为输入。设

该信号的采样频率为 f_s , 采样时长为 T , 总采样点数为 $N = f_s \times T$ 。为提取频域特征, FFT 模块的处理流程如下:

1) 信号预处理。对原始时域信号进行预处理, 减少噪声和异常值对后续频域特征的提取造成干扰。

2) FFT。对预处理后的信号进行长度为 N 的快速傅里叶变换, 得到频域复数序列 $X[k]$ ($k = 0, 1, \dots, N-1$)。其中, 序号 k 对应离散频率点, 其对应的物理频率为 $f_k = k \cdot \Delta f$, 频率分辨率 $\Delta f = f_s / N$ 。根据奈奎斯特采样定理, 实信号的频谱具有共轭对称性, 因此仅保留正频率部分, 对应频率范围 $[0, f_s/2]$, 将其作为后续特征提取的有效频域信息。

3) 特征提取。选取正频率范围内的幅值谱 $|X[k]|$ ($k = 0, 1, \dots, N-1$) 作为原始频域特征, 计算频谱熵、频谱峭度和频谱重心等特征值。这些特征共同构成一个多维特征向量, 作为后续主成分分析模块的输入。

2.2 主成分分析模块

传统主成分分析虽能有效降维, 但其无监督特性使其忽略了类别标签的差异信息。本文采用监督主成分分析对特征进行优化。监督主成分分析通过结合类别标签信息来辅助特征降维, 处理后的低维子空间保留原始数据的方差, 更有利于不同故障类别之间的区别。主成分分析模块的实现与流程如下:

1) 计算标签相似度

以样本的类别标签为输入, 采用高斯核函数计算标签间的相似度, 构建矩阵 J 。该过程将离散的类别信息转化为连续的相似性度量, 反映故障类型间的关联性。其中矩阵 J 的计算公式为

$$J[i, j] = K(y_i, y_j) = \exp\left(-\frac{\|y_i - y_j\|^2}{\sigma^2}\right) \quad (4)$$

式中: $\|y_i - y_j\|^2 = \sum_{m=1}^M (y_{i[m]} - y_{j[m]})^2$, y_i 和 y_j 分别为训练集中的第 i 个样本的标签向量以及第 j 个样本的标签向量; $y_{i[m]}$ 和 $y_{j[m]}$ 分别为第 i 个样本标签向量的第 m 个元素以及第 j 个样本标签向量的第 m 个元素; σ 为高斯核函数的带宽。

2) 融合数据与标签信息, 计算协方差矩阵 W

首先, 对 J 添加正则项并进行 Cholesky 分解, 确保其正定性。对原始数据矩阵 $S = (s_1, s_2, \dots, s_k)$ 进行去均值和去中心化处理, 消除数据偏移影响。其中去均值处理中的均值向量 μ 计算公式为

$$\mu = \frac{1}{I} \sum_{i=1}^k s_i \quad (5)$$

对数据矩阵 S 进行去中心化处理, 计算表达式为

$$S_1 = S - \mu \quad (6)$$

随后, 将处理后的数据矩阵 S_1 与矩阵 J 进行融合, 得到受类别标签影响的矩阵 L 。通过 L 计算矩阵 W 。矩阵 W 计算公式为

$$W = \frac{1}{I} L L^T \quad (7)$$

最后, 对其进行特征值求解, 并选取前 d 个特征值对应的主成分。 W 在保留原始数据主要方差的同时, 嵌入了类别间的判别性约束, 提升了低维特征的可区分性。

3) 利用 W 实现数据降维

将高维原始特征通过 W 映射至低维子空间。该过程在降低特征维度的同时, 增强了不同故障类别之间的差异性。

2.3 构建属性描述矩阵

在 GZSL 中, 测试集的未见故障并未出现在模型训练中, 模型难以从已见类故障中提取出与未见类故障相关的信息。因此, 在广义零样本故障诊断任务中需要更有效的辅助信息, 可借助属性描述矩阵, 帮助实现模型学习能力从已见类故障泛化至未见类故障。对于诊断故障, 可以用多种属性实现对故障的描述, 包括但不限于故障引起的某信号幅值或相位变化、故障位置等属性, 每一属性在故障的描述向量上都代表一个维度, 表示为 $s \in \mathbb{R}^C$, C 为其属性维度。

对于 d 类故障, 其故障描述矩阵可表示为 $A' \in \mathbb{R}^{d \times C}$, 用独热编码对 A' 进行处理, 得到目标故障描述矩阵 $A \in \mathbb{R}^{d \times C}$ 。其中 A 既含有已见故障的故障描述信息, 也包含未见故障的故障描述信息, 即 $A = [A_{x_1}, A_{x_2}]$, 其中 A_{x_1} 代表已见故障所对应的属性描述向量, A_{x_2} 代表未见故障所对应的属性描述向量。由于已见故障与未见故障都可采用相同的属性与维度加以描述, 因此可构建一个用于属性迁移的通道。在训练阶段, 将训练集的类别标签 Y_{x_1} 与矩阵 A 中对应的已见类故障属性 A_{x_1} 进行融合, 得到具有属性信息的标签向量 $U_Z = [u_1^Z, u_2^Z, \dots, u_Q^Z] \in \mathbb{R}^{Q \times C}$, 其中 Q 代表已见类故障的数量; 在测试阶段, 将测试集的类别标签 Y_x 与矩阵 A 中对应的所有故障属性进行融合, 得到标签向量 $U_T = [u_1^T, u_2^T, \dots, u_P^T] \in \mathbb{R}^{P \times C}$, 其中 P 代表测试集故障总数。这一做法便于

属性学习器 g_i 学习故障特征与标签向量之间的关系,并使其对测试集中的故障特征进行属性预测(即 $g_i: b_z \rightarrow u_i^z, g_i: b_T \rightarrow u_i^T$)。基于牵引逆变器电流传感器故障先验知识,构建了属性描述矩阵,属性描述矩阵如表 1 所示。

表 1 属性描述矩阵

Table 1 Attribute description matrix

故障类别	U_1	V_1	W_1	U_2	V_2	W_2	U_3	V_3	W_3
G1	1	0	0	1	0	0	0	0	0
G2	1	0	0	0	1	0	1	1	0
G3	0	1	0	0	1	0	0	0	0
G4	0	1	0	0	0	1	0	1	1
G5	0	0	1	0	0	1	0	0	0
G6	0	0	1	1	0	0	1	0	1

其中 D_j (D 为 U, V, W, j 为 $1, 2, 3$) 表示故障发生的位置、波形变化以及直流分量 3 种属性描述。属性描述矩阵的每行对应一个故障类别,每列代表一个与诊断相关的语义属性,矩阵元素取值为二值变量(取值为 1 或 0),表示该故障类别是否具备相应属性(1 表示“具备”,0 表示“不具备”)。通过该矩阵,为每个故障类别分配一个唯一的属性向量,作为其在语义空间中的语义表示。

2.4 故障类型判断

在进行故障诊断时,采用最近邻搜索策略,计算测试样本的属性预测向量与属性描述矩阵中各类故障对应属性描述向量之间的欧氏距离。该距离用于衡量预测样本与各故障类别在语义特征空间中的相似程度。欧氏距离越小,表示语义匹配度越高。该方法使模型在广义零样本条件下实现对已见故障与未见故障的识别。欧氏距离的计算为

$$d_j = \sqrt{\sum_{r=1}^m (a_{ji}(r) - a_j(r))^2}, j=1, 2, \dots, q \quad (8)$$

式中: $a_{ji}(r)$ 为第 i 类故障中第 j 个样本的第 r 个属性元素值; $a_j(r)$ 为预测属性向量的第 r 个属性元素值。模型选择欧氏距离最小的故障类别作为最终预测结果,其判定规则可表示为

$$\hat{Y}_Q = \arg \min d_j \quad (9)$$

式中 $\hat{Y}_Q$ 为预测的故障类别标签。

3 实验分析

3.1 实验数据

为验证本文提出的基于 GZSL 的电流传感器故

障诊断方法有效性,采集的实验数据集包含 6 种传感器故障。该数据集涵盖 U, V, W 三相电流传感器分别发生增益故障与偏移故障,共计 6 种。类别信息如表 2 所示。

表 2 电流传感器故障类别

Table 2 Fault categories of current sensors

编号	故障类别
G1	U 相发生增益故障
G2	U 相发生偏移故障
G3	V 相发生增益故障
G4	V 相发生偏移故障
G5	W 相发生增益故障
G6	W 相发生偏移故障

3.2 实验设置

由于 GZSL 的核心挑战在于模型需在测试阶段同时识别已见类与未见类故障,本文采用仅已见类故障样本参与训练、已见类与未见类故障样本共同参与测试的标准评估范式,以检验模型的故障诊断能力。具体而言,训练集仅包含 U 相电流传感器的增益故障样本与偏移故障样本,即已见类故障样本,用于模型学习故障特征与语义属性标签之间的映射关系;测试集包含已见类故障样本与未见类故障样本(V 相与 W 相分别发生增益、偏移故障)。其中,训练集和测试集中的增益故障样本和偏移故障样本是由 10 组不同故障系数组成,以验证所提诊断方法对不同严重程度故障的适用性。

以 U 相电流传感器发生故障为例,图 3、4 分别展示了 U 相传感器发生增益故障与偏移故障时的电流波形。可以看出, U 相传感器发生增益故障后,其电流幅值明显变大,而 V 相与 W 相幅值虽有略微增加,但明显小于 U 相电流幅值。 U 相传感器发生偏移故障, U 相电流相对于故障发生之前明显上偏移,且偏移量明显大于 V 相与 W 相。

为评估所提方法的性能,本文选取随机森林(random forest, RF)、决策树(decision tree, DT)和多层感知机(multilayer perceptron, MLP)作为分类器进行实验。其中,RF 的决策树数量设为 52。MLP 采用包含 2 个隐藏层的网络结构,每层包含 64 个神经元,最大迭代次数设为 500,这些参数共同影响分类器的训练收敛特性。

在性能评估方面,采用调和平均精度(harmonic




图3 U相电流传感器发生增益故障

Fig. 3 Gain fault of U-phase current sensor




图4 U相电流传感器发生偏移故障

Fig. 4 Offset fault of U-phase current sensor

mean of accuracies, HM) 作为主要指标。HM 综合考量模型在已见类与未见类故障上的识别性能,能平衡模型在已见类与未见类上的差异,避免评估结果偏向单一类别,更适用于广义零样本故障诊断场景。其计算公式为

$$H = \frac{2 \times \text{Acc}_s \times \text{Acc}_u}{\text{Acc}_s + \text{Acc}_u} \quad (10)$$

式中: Acc_s 为模型在测试集中属于已见类故障的分类准确率; Acc_u 为模型在测试集中属于未见类故障的分类准确率。各类别的准确率按标准定义计算

$$\text{Acc} = \frac{\hat{N}_t}{N_t} \quad (11)$$

式中: $\hat{N}_t$ 为正确分类样本数; N_t 为总测试样本数。

3.3 实验结果

表3列出了所提方法在3种经典分类器下的故障诊断结果。实验结果表明,RF和DT分类器对已见类故障的诊断准确率均达到100.00%,表明模型对已见类具有良好的识别性能;而在未见类故障上,RF分类器仍保持97.14%的高准确率,优于MLP与DT分类器。综合HM来看,相较于MLP以及DT分类器,RF分类器在兼顾已见类故障与未见类故障识别方面具有最优的泛化能力。

实验结果表明,各分类器的准确率存在一定波动,其中,RF分类器的诊断准确率介于95.76%~98.91%,MLP分类器的诊断准确率介于87.67%~93.86%,DT分类器的诊断准确率介于85.67%~

95.90%,这种波动主要源于各类模型内在的随机性机制。

表3 3种分类器的诊断性能

Table 3 Diagnostic performance of the three classifiers

分类器	Acc_s	Acc_u	H
RF	100.00	97.14	98.55
MLP	94.29	92.86	93.57
DT	100.00	91.07	95.33

对各类模型内在的随机机制进行分析:对于RF分类器,其随机性体现在两方面,一是每棵决策树训练过程中的自主采样,二是节点分裂时对特征的随机选择,这两方面因素共同导致不同训练轮次生成的森林结构存在差异。对于MLP分类器,训练初期会对网络中的权重与偏置参数进行随机赋值,这种随机的初始参数状态会改变模型优化过程中参数更新的走向,进而引起最终模型分类结果的波动。而对于DT分类器,当多个特征的分裂增益差异较小时,会随机从这些近似最优的特征中选取一个进行分割,进而导致单棵树的结构不稳定,影响诊断结果。

图5展示了3种分类器对不同故障类型的诊断结果。整体来看,RF分类器综合性能最优,在各类故障识别中均表现出高准确率。此外,根据表中数据可以发现,偏移故障的诊断准确率低于增益故障,其原因是偏移故障特征差异较小,不易捕捉,且所提取特征易与噪声混淆。

从图5中能发现,分类器对故障类别存在误判。其主要原因为训练阶段仅包括已见类故障样本,而测试集中不仅包括已见类故障样本,还包括未见类故障样本,这种样本分布差异可能会导致分类器出现少量误判。此外,在本文的测试集中,传感器的故障增益系数设置范围为[0.55, 1.45],以0.1为单位选取10个不同的故障增益系数,故障偏移系数设置范围为[-9, 9],以2为单位选取10个不同的故障偏移系数。不同故障的增益和偏移系数也可能导致分类器出现少量误判。

4 结论

1) 本文提出一种基于广义零样本学习的逆变器电流传感器故障诊断方法,应对逆变器运行中电流传感器故障样本稀缺带来的诊断挑战。

2) 本文提出的方法通过特征提取模块与主成




图5 各故障类别在不同分类器下的诊断精度

Fig. 5 Diagnosis accuracy per fault category and classifier

分分析模块完成故障特征的获取与降维,并基于属性描述矩阵和最近邻搜索策略,实现了对已见类与未见类故障的统一识别,提升了对未见类故障的推理能力。

3) 实验结果表明,本文方法对可见类故障具有高诊断精度,对未见类故障也表现出较高的诊断准

确率,为解决轨道交通领域电流传感器故障样本稀缺问题提供了新的技术途径。

参考文献:

- MAO Z H, XIA M X, JIANG B, et al. Incipient fault diagnosis for high-speed train traction systems via stacked generalization [J]. IEEE Transactions on Cybernetics, 2022, 52(8): 7624-7633.
- ZHANG K, HU X S, LIU Y G, et al. Multi-fault detection and isolation for lithium-ion battery systems [J]. IEEE Transactions on Power Electronics, 2022, 37(1): 971-989.
- 陈铭芸, 何怡刚, 赵莹莹. 基于开关状态的三电平 NPC 整流器开路故障诊断 [J]. 电子测量与仪器学报, 2023, 37(7): 62-71.
CHEN M Y, HE Y G, ZHAO Y Y. Open-circuit fault diagnosis of three-level NPC rectifier based on switching states [J]. Journal of Electronic Measurement and Instrumentation, 2023, 37(7): 62-71. (in Chinese)
- 陈美霞, 梁师嵩, 胡佳乔. 基于向量自回归模型和小波分析法的列车充电机电流传感器故障检测方法 [J]. 城市轨道交通研究, 2022, 25(4): 152-155, 173.
CHEN M X, LIANG S S, HU J Q. Train charger current sensor fault detection method based on VAR model and wavelet analysis [J]. Urban Mass Transit, 2022, 25(4): 152-155, 173. (in Chinese)
- 许明夏, 李长安, 王志强, 等. 基于功率因数自适应的城轨辅助逆变器 DPWM 控制策略 [J]. 中国电机工程学报, 2021, 41(增刊1): 356-365.
XU M X, LI C A, WANG Z Q, et al. DPWM control strategy of auxiliary inverter for urban rail transit based on adaptive power factor [J]. Proceedings of the CSEE, 2021, 41(Suppl 1): 356-365. (in Chinese)
- NI Q, LI X M, CHEN Z W, et al. A mechanism and data hybrid-driven method for main circuit ground fault diagnosis in electrical traction system [J]. IEEE Transactions on Industrial Electronics, 2023, 70(12): 12806-12815.
- 卢庆, 慕芳, 王哲, 等. 地铁车辆接地回流性能动态分析与优化 [J]. 机车电传动, 2022(2): 121-128.
LU Q, QI F, WANG Z, et al. Dynamic analysis and improvement of grounding return performance of metro vehicles [J]. Electric Drive for Locomotives, 2022(2): 121-128. (in Chinese)
- 徐小健, 于飞. 基于输出电压轨迹的三相逆变器开关管开路故障诊断 [J]. 中国电机工程学报, 2024, 44(3): 1106-1116.
XU X J, YU F. A fault diagnosis method based on output voltage patterns for switch open-circuit fault of three-phase

- inverters [J]. Proceedings of the CSEE, 2024, 44(3): 1106-1116. (in Chinese)
- [6] 陶宏伟, 彭涛, 杨超, 等. 高速列车牵引整流器多类故障联合诊断方法 [J]. 自动化学报, 2019, 45(12): 2294-2302.
- TAO H W, PENG T, YANG C, et al. Joint fault diagnosis method of multiclass faults for traction rectifier in high-speed train [J]. Acta Automatica Sinica, 2019, 45(12): 2294-2302. (in Chinese)
- [7] 徐绍龙, 倪强, 李学明, 等. 自动驾驶电力机车牵引变流器中 IGBT 寿命损耗优化策略 [J]. 中国电机工程学报, 2021, 41(18): 6381-6389.
- XU S L, NI Q, LI X M, et al. Optimization strategy of IGBT life loss in traction converter of autonomous driving electric locomotive [J]. Proceedings of the CSEE, 2021, 41(18): 6381-6389. (in Chinese)
- [8] 刘增华, 马春雷, 陈洪磊, 等. 激光和压电传感器密集型矩形阵列成像质量的比较分析 [J]. 北京工业大学学报, 2018, 44(8): 1075-1081.
- LIU Z H, MA C L, CHEN H L, et al. Comparison of imaging quality of compact rectangular arrays based on laser and piezoelectric transducers [J]. Journal of Beijing University of Technology, 2018, 44(8): 1075-1081. (in Chinese)
- [9] 李学明, 刘侃, 陈志文, 等. 基于结构分析与极限学习机的牵引传动系统多传感器故障实时联合诊断方法 [J]. 控制与决策, 2025, 40(5): 1590-1598.
- LI X M, LIU K, CHEN Z W, et al. Real-time joint diagnosis method of multi sensor fault for traction drive system based on structural analysis and extreme learning machine [J]. Control and Decision, 2025, 40(5): 1590-1598. (in Chinese)
- [10] CHEN H T, JIANG B, DING S X, et al. Data-driven fault diagnosis for traction systems in high-speed trains: a survey, challenges, and perspectives [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(3): 1700-1716.
- [11] 许水清, 柴晖, 胡友强, 等. 高速列车牵引电机转子断条和速度传感器联合诊断方法 [J]. 自动化学报, 2023, 49(6): 1214-1227.
- XU S Q, CHAI H, HU Y Q, et al. Simultaneous fault diagnosis of broken rotor bar and speed sensor for traction motor in high-speed train [J]. Acta Automatica Sinica, 2023, 49(6): 1214-1227. (in Chinese)
- [12] 葛兴来, 谢东, 邓清丽. 车载牵引变流系统故障诊断与容错控制综述 [J]. 电源学报, 2020, 18(1): 28-44.
- GE X L, XIE D, DENG Q L. Overview of fault diagnosis and fault-tolerant control methods for vehicular traction converter system [J]. Journal of Power Supply, 2020, 18(1): 28-44. (in Chinese)
- [13] HUANG G, FUKUSHIMA E F, SHE J H, et al. Estimation of sensor faults and unknown disturbance in current measurement circuits for PMSM drive system [J]. Measurement, 2019, 137: 580-587.
- [14] 陈勇, 张健建, 陈章勇. 基于电流观测器的三相逆变器开路故障在线诊断 [J]. 电工技术学报, 2019, 34(增刊2): 609-617.
- CHEN Y, ZHANG J J, CHEN Z Y. A current observer based on-line open-fault diagnosis for three-phase inverter [J]. Transactions of China Electrotechnical Society, 2019, 34(Suppl 2): 609-617. (in Chinese)
- [15] 卫伟, 高瞻, 赵牧天, 等. 基于切换调制波的三电平有源中点钳位逆变器优化容错技术研究 [J]. 电工技术学报, 2022, 37(15): 3818-3833.
- WEI W, GAO Z, ZHAO M T, et al. Research on optimal fault-tolerant technique for three-level active-neutral-point-clamped inverter based on switching modulation wave [J]. Transactions of China Electrotechnical Society, 2022, 37(15): 3818-3833. (in Chinese)
- [16] 许水清, 许晓凡, 何怡刚, 等. 基于自适应滑模观测器的中点钳位型三电平并网逆变器开关管和电流传感器故障诊断 [J]. 电工技术学报, 2024, 39(13): 4066-4078.
- XU S Q, XU X F, HE Y G, et al. A diagnosis method for power switch and current sensor faults in grid-connected three-level neutral-point clamped inverters based on adaptive sliding mode observer [J]. Transactions of China Electrotechnical Society, 2024, 39(13): 4066-4078. (in Chinese)
- [17] 孙源, 陈杰, 卫梦龙, 等. 非线性负载下的三相逆变器开路故障和电流传感器同时故障的诊断 [J]. 仪器仪表学报, 2024, 45(11): 52-64.
- SUN Y, CHEN J, WEI M L, et al. Simultaneous fault diagnosis of three-phase inverter open-circuits and current sensors under nonlinear load [J]. Chinese Journal of Scientific Instrument, 2024, 45(11): 52-64. (in Chinese)
- [18] YU Y J, SONG Y Q, TAO H W. A sensor fault diagnosis method for rectifier used in traction systems [C] // 2023 International Conference on Power Energy Systems and Applications. New York: IEEE Press, 2023: 109-114.
- [19] LI J H, DU B C, ZHAO T X, et al. Current sensor fault-tolerant control for five-phase PMSM drives based on third-harmonic space [J]. IEEE Transactions on Industrial Electronics, 2022, 69(10): 9827-9837.
- [20] GOU B, XU Y, XIA Y, et al. An online data-driven method for simultaneous diagnosis of IGBT and current sensor fault of three-phase PWM inverter in induction

- motor drives [J]. IEEE Transactions on Power Electronics, 2020, 35(12): 13281-13294.
- [24] DONG H H, CHEN F Z, WANG Z P, et al. An adaptive multisensor fault diagnosis method for high-speed train traction converters [J]. IEEE Transactions on Power Electronics, 2021, 36(6): 6288-6302.
- [25] XING Z K, HE Y G, ZHANG W W. An online multiple open-switch fault diagnosis method for T-type three-level inverters based on multimodal deep residual filter network [J]. IEEE Transactions on Industrial Electronics, 2023, 70(10): 10669-10679.
- [26] SHEN H L, TANG X, LUO Y F, et al. Online open-circuit fault diagnosis for neutral point clamped inverter based on an improved convolutional neural network and sample amplification method under varying operating conditions [J/OL]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 3512612 [2025-09-18]. <https://ieeexplore.ieee.org/document/10379190>.
- [27] LIU Y L, LI X Y, ZHANG X W, et al. Imbalanced deep transfer network for fault diagnosis of high-speed train traction motor bearings [J/OL]. Knowledge-Based Systems, 2024, 293: 111682 [2025-09-18]. <https://www.sciencedirect.com/science/article/pii/S0950705124003174>.
- [28] 朱琴跃, 王颖婕, 史玉明, 等. 基于 PCA 的逆变器开关管微小故障诊断 [J]. 控制与决策, 2025, 40(10): 3167-3176.
- ZHU Q Y, WANG Y J, SHI Y M, et al. A PCA-based method for diagnosing incipient faults of IGBTs in inverters [J]. Control and Decision, 2025, 40(10): 3167-3176. (in Chinese)
- [29] YANG F N, HUA C R, MU J Y, et al. Fault diagnosis of high-speed train suspension systems under variable speeds based on dynamic transfer loss weight-deep subdomain adaptation network [J/OL]. Advanced Engineering Informatics, 2025, 64: 103091 [2025-09-18]. <https://www.sciencedirect.com/science/article/pii/S1474034624007420>.
- [30] 许家群, 李娟娟. 无刷直流电机单电流传感器同步整流制动控制 [J]. 北京工业大学学报, 2018, 44(6): 848-854.
- XU J Q, LI J J. Synchronous rectification and braking control for brushless DC motor with single current sensor [J]. Journal of Beijing University of Technology, 2018, 44(6): 848-854. (in Chinese)
- [31] 邵宇宁, 王英. 基于 Adam 优化的改进 PSO-RBF 牵引变压器故障诊断研究 [J]. 电气工程学报, 2023, 18(4): 209-216.
- SHAO N N, WANG Y. Research on PSO-RBF traction transformer fault diagnosis based on Adam optimization [J]. Journal of Electrical Engineering, 2023, 18(4): 209-216. (in Chinese)
- [32] 张国恒, 高锋阳, 石岩, 等. 基于贝叶斯网络的牵引逆变器开路故障多特征融合诊断方法 [J]. 铁道科学与工程学报, 2020, 17(3): 732-740.
- ZHANG G H, GAO F Y, SHI Y, et al. Multi-feature fusion diagnosis method of open circuit fault for traction inverter based on Bayesian network [J]. Journal of Railway Science and Engineering, 2020, 17(3): 732-740. (in Chinese)
- [33] FAN L C, CHEN X L, CHAI Y, et al. Attribute fusion transfer for zero-shot fault diagnosis [J/OL]. Advanced Engineering Informatics, 2023, 58: 102204 [2025-09-18]. <https://www.sciencedirect.com/science/article/pii/S1474034623003324>.
- [34] FENG L J, ZHAO C H. Fault description based attribute transfer for zero-sample industrial fault diagnosis [J]. IEEE Transactions on Industrial Informatics, 2021, 17(3): 1852-1862.
- [35] CHEN X, ZHAO C H, DING J L. Pyramid-type zero-shot learning model with multi-granularity hierarchical attributes for industrial fault diagnosis [J/OL]. Reliability Engineering & System Safety, 2023, 240: 109591 [2025-09-18]. <https://www.sciencedirect.com/science/article/pii/S0951832023005057>.
- [36] POURPANAH F, ABDAR M, LUO Y X, et al. A review of generalized zero-shot learning methods [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(4): 4051-4070.
- [37] MOU M, ZHAO X Q, LIU K, et al. Variational autoencoder based on distributional semantic embedding and cross-modal reconstruction for generalized zero-shot fault diagnosis of industrial processes [J]. Process Safety and Environmental Protection, 2023, 177: 1154-1167.
- [38] ZHANG Y M, QIN N, HUANG D Q, et al. Generalized zero-shot approach leveraging attribute space for high-speed train bogie [J/OL]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 3512412 [2025-09-18]. <https://ieeexplore.ieee.org/document/10445780>.
- [39] YIN Y R, HUANG D Q, QIN N, et al. A stacked generalized zero-shot learning framework for fault diagnosis of high-speed train bogies with data imbalance [J/OL]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 3536714 [2025-09-18]. <https://ieeexplore.ieee.org/document/10979538>.

(责任编辑 郑筱梅)