

基于极端树与堆栈式稀疏自编码算法的 电力电子电路故障诊断

张亚茹¹ 何怡刚¹ 杜博伦¹ 邓金华² 安宝冉²

(1.武汉大学 电气与自动化学院 武汉 430072; 2.中国工程物理研究院 计算机应用研究所 绵阳 621900)

摘要: 针对电力电子电路故障诊断问题,基于极端随机森林(ET)与堆栈式稀疏自编码(SSAE)算法提出了一种适用于开关管故障的信号识别诊断方法。以三相电压型 PWM 整流电路为例,首先建立电路仿真模型并设计电压/电流双闭环调节器;为了在输出直流侧能收集到有效的故障特征信号,选择在无负载条件下向 PWM 整流器交流侧电流 d 轴分量中注入特定频率的交流电流,此时会在 DC 输出侧产生相同频率的纹波电压/电流;接着选择直流侧输出电流为故障特征量,首先利用经验模态分解(EMD)提取前 7 阶本征模函数(IMF)分量,然后计算每阶分量的能量、复杂度以及时域特征和频域特征,获得初始故障特征数据样本,对其应用 ET-SSAE 融合算法进行降维处理,最后输入到分类器中进行识别。实验结果表明,该算法最终的故障识别准确率高达 97.62%,其中 ET 算法降维处理后得到的故障诊断准确率为 88.89%,SSAE 降维处理后得到的故障诊断准确率为 91.27%。

关键词: 故障诊断;特征降维;经验模态分解;极端树;堆栈式稀疏自编码

中图分类号: TH707 **文献标识码:** A **国家标准学科分类代码:** 470.40

Fault diagnosis of power electronic circuits based on extreme tree and stack sparse auto-encoder algorithm

Zhang Yaru¹ He Yigang¹ Du Bolun¹ Deng Jinhua² An Baoran²

(1.School of Electrical Engineering and Automation, Wuhan University, Wuhan 430072, China;

2. Institute of Computer Application, China Academy of Engineering Physics, Mianyang 621900, China)

Abstract: To solve the problem of power electronic circuits fault diagnosis, this paper presents a fault signal recognition and diagnosis method based on Extreme Tree (ET) and Stack Sparse Auto-encoder (SSAE) algorithm. In this paper, a three-phase PWM rectifier circuit is taken as an example. Firstly, the circuit simulation model is established and the voltage-current double closed-loop regulator is designed. In order to collect the effective fault signals at the output DC-side, a specific frequency AC current is injected into the d axis component of the AC-side current of the PWM rectifier without load, and the ripple voltage/current at the same frequency will be generated at the output side of the DC. In this paper, the DC-side output current is selected as the fault characteristic. The first 7 order Intrinsic Mode Function (IMF) components are extracted by Empirical Mode Decomposition (EMD), then the energy, complexity, time/frequency-domain features of each order component are calculated. And the initial fault feature data samples are obtained. Then the ET-SSAE algorithm is applied to reduce the dimension, and finally it is input into the classifier for recognition. The experimental results show that the final fault recognition accuracy of this algorithm is 97.62%, and the fault diagnosis accuracy obtained by ET algorithm is 88.89% and 91.27% after dimensionality reduction.

Keywords: fault diagnosis; dimension reduction; empirical mode decomposition; extreme tree; stack sparse auto-encoder

0 引言

电力电子技术作为一门新兴综合应用技术基础学科,

随着技术的进步与发展,其应用领域也正在日益扩大,目前在国防军事、航空航天、电能变换与传输和信息通信等领域都可见电力电子装置的使用^[1]。其中,电力电子电路作为

收稿日期:2019-05-05

* 基金项目:国家自然科学基金(51577046)、国家自然科学基金重点项目(51637004)、国家重点研发计划“重大科学仪器设备开发”项目(2016YFF0102200)资助

电力电子装置的重要组成部分,主要由主电路和控制电路两部分组成,在实际工作中,主电路发生故障的概率远远高于其他组成部分,其任何一个元器件发生故障,都有可能导导致整个系统和装置的工作状态发生异常,因此对电力电子电路和装置的工作状态进行监测和迅速的故障诊断是非常重要的。

电力电子电路的故障诊断主要是针对其主电路中的电力电子器件进行监测与诊断,然而电力电子主电路发生故障的类型比较复杂,根据故障引起的电路宏观性能的变化程度,可将电力电子电路故障分为灾难性故障和参数型故障^[2]。灾难性故障又称硬故障,是主电路的电力电子器件,如晶闸管、电力二极管等发生开路或短路而引起的电路结构性故障。硬故障具有突发性,往往导致电路功能发生急剧变化,易造成灾难性后果,因此对硬故障进行诊断是目前电力电子电路故障诊断的研究热点。

目前,电力电子故障诊断方法主要分为解析模型诊断法、信号识别法和知识融合诊断法。解析模型故障诊断方法又可分为状态估计故障诊断和参数估计得故障诊断,该方法需要精确地建立待诊断电路的故障模型^[3-4];信号识别法即基于信号处理的故障诊断法,其最大的特点是不需要建立被诊断电路准确的诊断模型,具有较强的自适应能力,选取合适的电路输出量分析其包含的故障信息,常用的处理方法包括傅里叶变换法、Park 变换法和小波变换法^[5-7],但是通过该方法进行信号处理的结果可能不具有实际物理意义,过程中可能会导致有效故障信息的丢失,或者在故障类型比较多时变换后选取的故障特征量无法有效区别不同的故障类型;与两者不同,知识融合诊断法既不需要构建模型也不需要判别信号模式,只要有充足的信号数据即可。目前,随着人工智能技术的发展,智能融合诊断算法能够提供有效的故障检测和诊断能力^[8]。

所以,本文应用智能融合诊断方法并以三相 AC/DC PWM 整流电路为例,首先从三相 PWM 整流器的控制策略入手,为了在输出直流侧能收集到有效的故障特征提取量,选择在无负载条件下向 PWM 整流器交流侧电流 d 轴分量中注入特定频率的交流电流,则会在 DC 输出侧产生相同频率的纹波电压/电流。对于由开关器件开路导致的结构型故障,本文选择直流侧输出电流为故障特征量,首先利用经验模态分解(empirical mode decomposition, EMD)提取前 7 阶本征模函数(intrinsic mode function, IMF)分量,然后计算每阶分量的能量、复杂度以及时域特征和频域特征,获得初始故障特征数据样本,然后将其应用 ET-SSAE 算法进行降维处理,最后输入到分类器中进行识别。实验结果表明,该算法最终的故障识别准确率高达 97.62%,其中 ET 算法降维处理后得到的故障诊断准确率为 88.89%,SSEA 降维处理后得到的故障诊断准确率为 91.27%。

1 基于 EMD 的信号分析方法

EMD 是一种自适应的数据处理或挖掘方法,常用于非线性、非稳定时间序列的处理,与传统信号处理方法(比如小波分析等)相比,EMD 不需要指定基函数,而是直接根据信号本身的时间尺度特征进行分解,将复杂的原始信号分解成若干完整的、几乎是正交的 IMF 分量和残余分量之和,每个 IMF 分量对应于一个离散频率的特定信号的振动模式^[9]。

EMD 的基本思想为将一个频率不规则的波从特征时间尺度角度将信号从高频至低频逐层分离,化为多个单一频率的波+残波的形式,实质就是对非线性、非平稳信号进行线性化、平稳化和单分量处理的过程。EMD 方法对原始信号 $x(t)$ 分解如式(1)所示:

$$x(t) = \sum_{i=1}^n c_i(t) + r(t) \quad (1)$$

其中,各个 IMF 分量 $c_i(t)$ 分别包含了信号不同时间特征尺度大小的成份,残余分量 $r(t)$ 代表信号的平均趋势。因此可以从电路输出信号的 IMF 分量中提取反映电力电子电路故障的特征信息。

2 基于 ET-SSAE 算法的故障特征降维处理

为了实现有效的故障诊断,需要设计出识别准确率较高的分类器,其中影响分类器准确率的重要因素之一就是故障特征数据的处理方式。虽然原始数据包含了样本最丰富的信息,能最完整地表达样本,但是应用原始数据直接训练分类器则会出现过拟合问题,另外也会由于原始数据的高维度导致训练耗时较长,所以需要对初始数据进行恰当的处理进而降低初始数据的维度。常用的降维方法可分为两类,一类是特征选择,具体包括过滤型、包裹型和嵌入式,其中嵌入式是将特征选择过程与学习器训练过程融为一体,在学习器训练过程中自动地进行了特征选择,本文选择嵌入式方法,利用 ET 算法计算特征重要性进行特征选择^[10],丢弃重要性较低的特征进而实现降维;另一类是特征提取,代表性方法是主成分分析(PCA),本文采用 PCA 的扩展方法堆栈式稀疏自编码(stack sparse auto-encoder, SSAE)实现对高维数据的降维。

2.1 特征选择:基于 ET 算法的故障特征选择

ET 算法与随机森林(random forest, RF)算法十分相似,都是由许多决策树构成,但 RF 应用的是 Bagging 模型,ET 使用的是所有的样本,只是特征是随机选取的,所以在某种程度上 ET 比 RF 得到的结果更加好。所以本文选择 ET 模型对初始数据集进行训练。与 RF 算法类似,ET 算法也可通过基尼指数(gini index, GI)计算决策树节点的纯度来衡量特征重要性,具体实现方案如下。

假设有 m 个特征 $X_1, X_2, X_3, \dots, X_m$, 每个特征的重要性评分(variable importance measure, VIM)可通过 Gini

指数评分 $VIM_j^{(Gini)}$ 表示,亦即第 j 个特征 X_j 在 ET 所有决策树中节点分裂不纯度的平均改变量。

Gini 指数的计算公式为:

$$GI_m = \sum_{k=1}^K \sum_{k' \neq k} p_{mk} p_{mk'} = 1 - \sum_{k=1}^K p_{mk}^2 \quad (2)$$

式中: K 表示有 K 个类别; p_{mk} 表示节点 m 中类别 k 所占的比例。

特征 X_j 在节点 m 的重要性,即节点 m 分枝前后的 Gini 指数变化量为:

$$VIM_{jm}^{(Gini)} = GI_m - GI_l - GI_r \quad (3)$$

式中: GI_l 和 GI_r 分别表示分枝后两个新节点的 Gini 指数。

如果特征 X_j 在决策树 i 中出现的节点在集合 M 中,那么 X_j 在第 i 棵树的重要性为:

$$VIM_{ij}^{(Gini)} = \sum_{m \in M} VIM_{jm}^{(Gini)} \quad (4)$$

假设 ET 共有 n 棵树,那么

$$VIM_j^{(Gini)} = \sum_{i=1}^n VIM_{ij}^{(Gini)} \quad (5)$$

最后做归一化处理可得该特征的重要性评分为:

$$VIM_j = \frac{VIM_j}{\sum_{i=1}^c VIM_i} \quad (6)$$

最后将计算所得的特征重要性评分降序排列,确定要剔除的比例,剔除后得到一个新的特征集,可以将得到的特征数据输入到分类器中进行分类识别。

2.2 特征提取:基于 SSAE 算法的故障特征提取

1) 自编码器

自编码器是神经网络的一种,经过训练后能从无标签的数据中提取更具代表性的分层特征并得到原始特征的分层表示,其结构如图 1 所示。其学习过程包含两个过程^[11-13]。




图1 自编码器结构

(1) 编码过程:假设输入样本数据为:

$x: \{x_1, x_2, x_3, \dots, x_n\}$, 利用编码函数对每个输入样本 x_n 进行编码转化为隐含层的矢量 $h: \{h_1, h_2, h_3, \dots, h_n\}$, 解码函数公式如下所示:

$$h_v(x) = \sigma_v(W_v \cdot x + b_v) \in R^v \quad (7)$$

式中: $\sigma_v(\cdot)$ 为网络激励函数; $\{W_v, b_v\}$ 为网络参数; W_v 为输入层与隐含层权值; b_v 是编码网络的偏置项系数; v 为隐含层单元个数。

(2) 解码过程:对解码过程得到的隐含层矢量用解码函

数进行矢量重构,得到输入样本的预测估计,解码函数公式如下所示:

$$\tilde{x} = \sigma_h(W_h \cdot x + b_h) \in R^u \quad (8)$$

式中: $\sigma_h(\cdot)$ 为网络激励函数; $\{W_h, b_h\}$ 为网络参数; W_h 为隐含层与输出层权值; b_h 是解码网络的偏置项系数; u 为输出层单元个数。

在解码过程中进行矢量重构时,会得到实际输入 x 与预测估计输出 $\tilde{x}$ 之间的误差,由于自编码网络的训练目的是保证网络的实际输入 x 与预测估计输出 $\tilde{x}$ 尽可能一致,因此需要构建误差损失函数对网络的误差进行计算,获得优化目标函数进而得到最优的输出结果。本文基于能量的损失构建的优化目标函数为:

$$\min_{\theta} J(\theta) = \frac{1}{N} \sum_{n=1}^N \|x^{(n)} - \tilde{x}^{(n)}\|_2^2 + \delta \cdot R(\theta) \quad (9)$$

其中损失项中的输出 $\tilde{x}^{(n)}$ 为输入 $x^{(n)}$ 的预测,其期望的输出为 $x^{(n)}$, 另外参数与正则项定义为:

$$\begin{cases} \theta = [W_v, b_v; W_h, b_h] \\ R(\theta) = \|W_v\|^2 + \|W_h\|^2 \end{cases} \quad (10)$$

式中: N 为输入样本的个数; δ 是衰减系数。本文是利用 BP 反向传播算法与梯度下降法进行网络权值的调整,通过迭代得到减小误差函数的值,如果最后的输出向量 $\tilde{x}$ 接近于输入向量 x , 说明在隐含层的矢量 h 存在着高维特征的相关信息,从而隐含层的输出矢量能够表示输入数据的特征。

2) 堆栈式稀疏自编码网络

在自编码器网络的训练过程中,通过隐含层中的部分网络激活状态的限制而使得与输入数据相关联的神经元节点处于激活状态,进而实现高维特征的提取。这种让部分神经网络处于未激活状态的限制称为自编码器网络的稀疏性。一般情况下当神经元的输出接近于 1 时定义它被激活,而输出接近于 0 时则定义为被抑制,那么使得神经元大部分时间都是被抑制的限制则被称作稀疏性限制。本文采取利用 KL 距离引入稀疏性约束的方式,具体如下:

首先,隐层输出每个节点的平均值为:

$$\bar{H} = \frac{1}{N} \sum_{n=1}^N h^{(n)} \quad (11)$$

期望隐层每个节点的平均输出值尽量为 0,大部分的隐层节点处于静默状态,为了量化隐层这种特性,通常假设隐层每个节点以一定的概率(本文中 $\rho = 0.05$)进行响应,且节点之间相互独立。进一步利用 KL 距离构造的稀疏正则项为:

$$\begin{aligned} KL(\rho \| \bar{H}(j)) &= \rho \cdot \log\left(\frac{\rho}{\bar{H}(j)}\right) + (1 - \rho) \cdot \\ &\log\left(\frac{1 - \rho}{1 - \bar{H}(j)}\right) \end{aligned} \quad (12)$$

式中: $\bar{H}(j)$ 为 $\bar{H}$ 的第 j 个元素,即隐层第 j 个节点响应的平均值,其中 $j = 1, 2, \dots, v$ 。在自编码网络优化目标公

式(9)的基础上,得到稀疏自编码网络的优化目标函数为:

$$\min_{\theta} J(\theta) = \frac{1}{N} \sum_{n=1}^N \| \hat{x}^{(n)} - x^{(n)} \|_2^2 + \delta \cdot R(\theta) + \mu \cdot \sum_{j=1}^v KL(\rho \| \bar{H}(j)) \quad (13)$$

式中: μ 为惩罚因子。为了得到更好的结果,利用 BP 反向传播算法与梯度下降法对网络进行微调,从而达到更新参数 θ 的目的,更新方程如下:

$$\begin{cases} W_v^{k+1} = W_v^k - \alpha \cdot \frac{\partial J(\theta)}{\partial W_v} \Big|_{w_v^k} \\ b_v^{k+1} = b_v^k - \alpha \cdot \frac{\partial J(\theta)}{\partial b_v} \Big|_{b_v^k} \\ W_h^{k+1} = W_h^k - \alpha \cdot \frac{\partial J(\theta)}{\partial W_h} \Big|_{w_h^k} \\ b_h^{k+1} = b_h^k - \alpha \cdot \frac{\partial J(\theta)}{\partial b_h} \Big|_{b_h^k} \end{cases} \quad (14)$$

为使最终得到的特征数据维度更小且更具有代表性,本文采取堆栈稀疏自编码器,将多个稀疏自编码器级联,以完成逐层特征提取的任务,如图 2 所示。




图 2 堆栈式稀疏自编码网络结构

最后获取最后一个稀疏自编码器的隐含层特征并将其输入到分类器中进行分类识别。稀疏自编码器个数过多会造成参数过多,网络训练不稳定,层数太少容易造成高维特征提取不够彻底,所以本文选择两层稀疏自编码组成的网络对电力电子电路故障数据进行训练和特征优化,然后将得到的特征数据输入到分类器中进行分类识别,本文选择的分类器为多层感知器分类器(MLPClassifier)该分类器来自于 sklearn 库中的神经网络模块。

3 故障诊断模型工作流程

基于 EMD 和特征降维处理(ET-SSAE)的电力电子电路故障诊断方法,本文采用的诊断模型为 EMD-ET-SSAE-MLPC,故障诊断流程如图 3 所示,具体步骤描述如下。

1) 信号采集与特征提取

对每一种故障状态下获得的电流信号进行 EMD 分




图 3 EMD-ET-SSAE-MLPC 故障诊断模型流程

解,本文选取前 7 阶 IMF 分量,计算每阶分量的时域、频域以及能量特征^[11],如表 1 所示共计 17 种,这样对每一个电流信号可以得到 119 种特征,即原始特征数据集。

2) 故障特征降维处理

本文采取的降维处理方式为 ET 与 SSAE 融合算法(ET-D_SAE),同时会将其与 ET 和 SSAE 单独进行故障特征降维做对比,所以经过 3 种降维处理方式最后获得 3 组不同的故障特征数据集。

3) 模式识别

对 3 组不同的故障特征数据集,设置训练集、测试集和相应的训练集标签和测试集标签,输入到分类器,本文采用的分类器为 sklearn 神经网络模块中的 MLPClassifier。

4 仿真实验及分析

4.1 仿真模型建立及故障信号采集

如图 4 所示,通过 MATLAB 建立三相电压型 PWM 整流器仿真模型,电网相电压幅值为 $220\sqrt{2}$ V,频率为 50 Hz,交流侧电感为 1 mH,电感的寄生电阻为 0.5 Ω ,直流侧电容 $C=4\ 000\ \mu\text{F}$,并联电阻为 10 Ω ,直流侧电压为 600 V,假定开关频率为 10 kHz,采样频率为 100 kHz,注入的交流电流 $i_{de,m}=5\sin 100\pi t$ 。其控制器均采用双闭环结构。在三相交流对称系统中,若只考虑交流基波分量,在 dq 坐标系下, dq 分量存在耦合,所以对电流进行解耦,则可得到独立的 dq 直流分量,从而把电流跟踪系统电流变成了恒值调节系统。使 d 轴与 U_s 轴重合,则 d 轴可以表示为有功分量参考值, q 轴表示无功分量参考值,从而便于有功、无功

表1 17种故障特征

特征	计算公式
能量	$T_1 = \sum_{i=1}^n x(i) ^2$
复杂度	$T_2 = \text{Lempel_Ziv 复杂度}$
均值	$T_3 = \sqrt{\frac{1}{n} \sum_{i=1}^n x(i)}$
均方根值	$T_4 = \sqrt{\frac{1}{n} \sum_{i=1}^n x(i) ^2}$
标准差	$T_5 = \sqrt{\frac{1}{n} \sum_{i=1}^n [x(i) - T_3]^2}$
偏度	$T_6 = \frac{1}{n-1} \sum_{i=1}^n [x(i) - T_3]^3 / T_5^3$
峰度	$T_7 = \frac{1}{n-1} \sum_{i=1}^n [x(i) - T_3]^4 / (T_5^3 - 3)$
波形指标	$T_8 = T_4 / T_3 $
裕度指标	$T_9 = \max x(i) / [1/n \sum_{i=1}^n \sqrt{ x(i) }]^2$
脉冲指标	$T_{10} = \max x(i) / T_3 $
峰值指标	$T_{11} = [\max x(i)] / T_4$
峭度指标	$T_{12} = [1/n \sum_{i=1}^n x(i)^4] / T_4^4$
重心频率	$T_{13} = \sum f \phi(f) / \sum \phi(f)$
均方频率	$T_{14} = \sum f^2 \phi(f) / \sum \phi(f)$
均方根频率	$T_{15} = \sqrt{T_{14}}$
频率方差	$T_{16} = \sum (f - T_{13})^2 \phi(f) / \sum \phi(f)$
频率标准差	$T_{17} = \sqrt{T_{16}}$




图4 三相电压型PWM整流器仿真模型

电流的独立控制。在本文中,控制 q 轴电流为0保证电源侧功率因数为1,控制 d 轴电流维持直流侧输出电压恒定。

假定在无负载条件下,输出功率为0,如果输出直流电压为定值,则此时的 d 轴电流应控制为0,整体处于平衡状态,不利于进行故障信号提取。因此,为了在直流输出侧收集到有效的故障特征提取量,选择向PWM整流器交流侧电流 d 轴分量中注入特定频率的交流电流,则会在直流输出侧产生相同频率的纹波电压。本文中选择向 d 轴注入电流 $i_{de, \text{in}} = 5 \sin(100\pi t)$ 。由于直流输出侧电容的存在,可以补偿某些故障引起的电压降和谐波的变化,从而影响故障的正常检测,所以在此选取直流侧电流信号为故障特征信号^[15]。

不同于DC侧输出电压可直接测量,DC侧输出电流很少被直接测量。相反,交流侧电流多被测量用于电流控制和过电流保护。因此,DC侧输出电流采用间接测量方式,利用AC输入电流(i_{as}, i_{bs}, i_{cs})和开关函数(S_a, S_b, S_c)重构,如下式:

$$i_{dc} = S_a i_{as} + S_b i_{bs} + S_c i_{cs} \quad (15)$$

其中,当上臂器件处于导通状态时, $S_i = 1 (i = a, b, c)$; 当上臂开关器件处于截止状态时, $S_i = 0 (i = a, b, c)$ 。

4.2 故障类型分析

本文选择失效率仅低于电解电容的开关器件IGBT为研究对象,其大多数情况是由于过电压、过电流造成其寄生体三极管或二极管不可控的导通,导致开关击穿,瞬时失效。本文主要分析开关器件IGBT的开路故障,对不同位置IGBT故障类型进行判定。针对单元器件故障,包含正常情况在内的7种故障模式,如表2所示。从每种故障模式中提取60个直流侧电流信号样本,每个样本包含10k个点。

表2 故障分类及编码

故障类型	编码	类别
正常	$[1, 0, 0, 0, 0, 0]^T$	1
VT ₁ 断路	$[0, 1, 0, 0, 0, 0]^T$	2
VT ₂ 断路	$[0, 0, 1, 0, 0, 0]^T$	3
VT ₃ 断路	$[0, 0, 0, 1, 0, 0]^T$	4
VT ₄ 断路	$[0, 0, 0, 0, 1, 0]^T$	5
VT ₅ 断路	$[0, 0, 0, 0, 0, 1]^T$	6
VT ₆ 断路	$[0, 0, 0, 0, 0, 1]^T$	7

4.3 实验结果分析

对电流信号进行EMD分解,获取前7阶IMF分量(如图5和6所示),并计算其17种特征,共计获得119种故障特征,定义此时的样本数据集为初始数据集 $A(420 \times 119)$ 。然后利用ET算法计算119种特征的重要性评分后进行降序排列,分布如图7所示。




图 5 正常运行状态下直流侧输出电流 EMD 获取的前 7 阶 IMF 分量




图 6 VT_1 断路状态下直流侧输出电流 EMD 获取的前 7 阶 IMF 分量

根据降序排列设置除的比例为 0.6, 剔除后得到一个新的数据集 B(420×48), 将新的数据集利用 t-SNE 方法进行二维可视化, 如图 8 所示。

本文选择构造一个两层的堆栈式稀疏自编码网络结构, 根据数据集 B 的维数设置堆栈稀疏自编码网络结构为 48-25-10(其中 30 为输入的特征值个数, 20 为第一个稀疏自编码器隐含层节点数, 10 为第二个稀疏自编码器隐含层节点数)。将数据集 B 进行[0,1]归一化处理, 然后对稀疏自编码器进行参数初始化设置 5, 其中网络参数正则化系数 $\delta=0.01$, 稀疏正则化系数 $\mu=5$, 利用随机梯度法对




图 7 119 种故障特征的重要性评分




图 8 ET 算法处理后所得故障特征数据集 B 可视化图

网络参数优化的学习率设置 0.01, 迭代次数设置为 500。为了验证稀疏自编码器具有提取高维数据特征的能力, 将数据集 B 利用稀疏自编码器方法降维后得到的数据集 C(10×48)进行 t-SNE 二维可视化, 如图 9 所示, 与图 8 相比, 根据数据分布变化可以看出, ET 算法处理后的数据集不能有效区分类别 4 与 5、类别 1 与 3, 经 SSAE 进一步降维处理后不同类别数据间距离增大, 同类别样本更加集聚, 所以稀疏自编码器网络具有提取高维特征的能力。另外, 为了验证 ET-SSAE 融合算法比单一降维算法效果更好, 在本文中将数据集 A 直接进行 SSAE 降维得到数据集 D, 最后应用 t-SNE 进行二维可视化处理得到图 10, 显然可知融合算法要优于另外两种单一降维算法。

最后将 B、C、D 3 组数据集进行[0,1]归一化处理, 并以 0.3 的比例将数据集划分为测试集和训练集, 分别输入到 MLPClassifier, 经试验比较各项参数设置为:

激活函数 activation='relu';

优化器 solver='lbfgs';

正则化项参数 alpha=0.01;

恒定学习率 learning_rate_init=0.001;




图 9 对数据集 B 进行 SSAE 降维处理所得故障特征数据集 C 可视化图




图 10 对初始数据集 A 进行 SSAE 降维处理所得故障特征数据集 D 可视化图

隐藏层神经元个数 $\text{hidden_layer_sizes}=(20,10)$, 其它设置均为默认值。

实验结果如图 11~14 所示。对于图 11~13, 横坐标




图 11 ET 算法降维处理后的故障诊断结果




图 12 SSAE 算法降维处理后的故障诊断结果




图 13 ET-SSAE 融合算法降维处理后的故障诊断结果




图 14 不同降维算法处理后的各类故障诊断识别准确率

表示真实故障类型,其中横坐标位于 0~1 之间的点均属于 0 类别,即正常运行状态,位于 1~2 之间的点均属于 1 类别,即开关管 S1 断路,以此类推。由图 11~13 对比可知,经 ET-SSAE 融合算法进行降维处理后,各类故障诊断准确率明显提高,尤其类别 1 与 3,类别 4 与 5、类别 6 之间的混淆明显减弱,由图 14 可知,ET-SSEA 对故障类别 1、3、5、6 的识别准确率要高于另外两种方法,最终的故障识别准确率高达 97.62%,其中 ET 算法降维处理后得到的故障诊断准确率为 88.89%,SSEA 降维处理后得到的故障诊断准确率为 91.27%。

5 结 论

针对三相电压型 PWM 整流电路的单元器件故障诊断,本文首先利用 EMD 分解方法提取前 7 阶 IMF 分量,然后计算每阶分量的能量、复杂度以及时域特征和频域特征,获得初始故障特征数据样本,然后将其应用 ET-SSAE 融合算法进行降维处理,最后输入到 MLPClassifier 分类器中进行识别。由于初始故障特征数据集特征种数较多,会产生特征冗余,则有必要对故障特征进行选择实现降维,实验数据验证经计算各特征重要性评分时,有接近一半特征其重要性趋近于 0,所以选取重要性较高的特征作为故障特征则可以有效减少算法运行计算量。采用稀疏自编码构建的堆栈式网络,能进一步有效对故障特征进行优化,获取其高维特征。由于其学习方法为无监督学习,当单独使用时效果可能欠佳,所以本文采用有监督学习与无监督学习算法融合算法,有效地提高了故障识别准确率,将容易混淆的故障类型也成功地区分开来,所以 ET-SSAE 融合算法适用于电力电子电路故障诊断。

参考文献

- [1] 王维平. 现代电力电子技术及应用[M]. 南京:东南大学出版社, 2001.
- [2] 蔡金锭. 电力电子电路及容差电路故障诊断技术[M]. 北京:机械工业出版社, 2016.
- [3] 李宁,李颖晖,朱喜华,等. 混杂系统理论及其在三相逆变电路开路故障诊断中的应用[J]. 电工技术学报, 2014,29(6):114-119.
- [4] 张志学,马皓,毛兴云. 基于混杂系统模型和事件辨识的电力电子电路故障诊断[J]. 中国电机工程学报, 2005,25(3):51-55.
- [5] 孙永奎,陈光,李辉. 基于自适应小波分解和 SVM 的模拟电路故障诊断[J]. 仪器仪表学报, 2008, 29(10): 2105-2109.
- [6] 唐静远,师奕兵,张伟. 基于支持向量机集成的模拟电路故障诊断[J]. 仪器仪表学报, 2008, 29(6): 1216-1220.
- [7] GAN C, WU J, YANG S, et al. Fault diagnosis scheme for open-circuit faults in switched reluctance motor drives using fast Fourier transform algorithm with bus current detection[J]. Iet Power Electronics, 2016, 9(1):20-30.
- [8] 罗慧,王友仁,崔江,等. 电力电子电路多源特征层融合故障诊断方法[J]. 电机与控制学报, 2010,14(4): 92-96.
- [9] HUANG N E, SHEN Z, LONG S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis [J]. Proceedings of the Royal Society. Mathematical, physical and engineering sciences, 1998, 454(1971):903-995.
- [10] 宋源,梁雪春,张然. 基于统计特性随机森林算法的特征选择[J]. 计算机应用, 2015, 35(5): 1459-1466.
- [11] 曹浩,陈里里,司吉兵,等. 奇异值分解和稀疏自编码器的轴承故障诊断[J/OL]. 计算机工程与应用: 1-13[2019-02-21]. <http://kns.cnki.net/kcms/detail/11.2127.TP.20181101.1754.049.html>.
- [12] 吴洋. 深度自编码网络在滚动轴承故障诊断中的应用研究[D].成都:电子科技大学, 2018.
- [13] 孙文琨,邵思羽,严如强. 基于稀疏自动编码深度神经网络的感应电动机故障诊断[J]. 机械工程学报, 2016, 52(9):65-71.
- [14] 俞啸,范春阳,董飞,等. 基于 EMD 与深度信念网络的滚动轴承故障特征分析与诊断方法[J]. 机械传动, 2018,42(6):157-163.
- [15] PU X S, NGUYEN T H, LEE D C, et al. Fault diagnosis of DC-link capacitors in three-phase AC/DC PWM converters by online estimation of equivalent series resistance [J]. IEEE Transactions on Industrial Electronics, 2013, 60(9):4118-4127.

作者简介

张亚茹,硕士研究生,主要研究方向为电力电子电路故障诊断与预测。

E-mail:594503147@qq.com

何怡刚(通信作者),教授,博士生导师,主要研究方向为智能测试与诊断、集成电路设计、电力规划与设计等。

E-mail:18655136887@163.com

杜博伦,博士研究生,主要研究方向为电力电子电路故障诊断与预测,深度学习等。

E-mail:bolundu93@163.com

邓金华主要研究方向为故障诊断、图像处理、机器学习等。

E-mail:jinhudeng10@163.com

安宝冉,主要研究方向为故障诊断与预测,和深度学习相关。